




UNIVERSIDAD NACIONAL DEL COMAHUE
FACULTAD DE INFORMÁTICA



TESIS DE LICENCIADO EN SISTEMAS DE INFORMACIÓN

**Un Enfoque Top-Down de Variedad de Contexto: Caso
de estudio en la ocurrencia y detección de heladas en el
Alto Valle de Río Negro y Neuquén**

Saurin, Federico Gabriel

Buccella, Agustina

NEUQUÉN

ARGENTINA

Junio 2024

PREFACIO

Esta tesis es presentada como parte de los requisitos finales para optar al grado académico de *Licenciado en Sistemas de Información*, otorgado por la Universidad Nacional del Comahue, y no ha sido presentada previamente para la obtención de otro título en esta Universidad u otras. La misma es el resultado de la investigación llevada a cabo en el Departamento de Ingeniería de Sistemas, de la Facultad de Informática, en el período comprendido entre Diciembre de 2023 y Junio de 2024, bajo la dirección de la Dra Agustina Buccella.

Saurin, Federico Gabriel
FACULTAD DE INFORMÁTICA
UNIVERSIDAD NACIONAL DEL COMAHUE
Neuquén, día de Mes de Año.



UNIVERSIDAD NACIONAL DEL COMAHUE

Facultad de Informática

La presente tesis ha sido aprobada el día, mereciendo la calificación de

AGRADECIMIENTOS

Quisiera expresar mi sincero agradecimiento a todas las personas e instituciones que contribuyeron de manera significativa a la realización de este trabajo de investigación. Sus aportaciones, apoyo y orientación fueron fundamentales para alcanzar este logro académico.

- Agradezco de todo corazón a mis padres, Vilma y Daniel, así como a mis hermanos Ale, Cesar y mi hermana Anahí, por brindarme el apoyo incondicional y el sustento necesario para iniciar y completar esta carrera.
- A mis mejores amigos Gera, Lucho y Sav, con los que he compartido momentos maravillosos. Su amistad ha sido un pilar fundamental en mi vida y en este camino.
- Quiero expresar mi más sincero agradecimiento a mi directora de tesis, Agustina, por su invaluable orientación, paciencia y dedicación a lo largo de este proyecto. Su guía experta y apoyo constante fueron fundamentales para mi desarrollo académico y la culminación exitosa de esta tesis.
- Agradezco sinceramente a todos los docentes de que me he cruzado en la universidad por su dedicación y enseñanzas que han enriquecido mi experiencia académica. Cada uno de ustedes ha dejado una huella significativa en mi camino hacia la culminación de esta etapa académica.
- Quiero expresar mi profundo agradecimiento a la universidad pública por brindarme una educación de calidad y por todas las oportunidades que me ha ofrecido durante mi carrera. En especial, estoy verdaderamente agradecido por haber sido parte de la comunidad de la Universidad Nacional del Comahue.

RESUMEN

La agrometeorología, que estudia la interacción entre los factores meteorológicos y las actividades agrícolas, enfrenta el desafío de manejar y analizar grandes volúmenes de datos (Big Data) para mejorar la toma de decisiones. Esta tesis se motiva por la necesidad de aprovechar los avances en los Sistemas de Big Data para optimizar las predicciones meteorológicas.

El objetivo principal de esta investigación es evaluar y demostrar cómo los sistemas de Big Data pueden integrarse y aplicarse eficazmente en el dominio de la agrometeorología. Para lograr esto, se investigan los componentes clave de los sistemas de big data, su ciclo de vida y las mejores prácticas en el manejo de estos datos. El trabajo se centra en casos de dominio específicos basados en información de estaciones meteorológicas para ilustrar la aplicación práctica de estas tecnologías.

La metodología utilizada se basa en un enfoque top-down propuesto en trabajos previos del grupo de investigación en la cual se enmarca esta tesis. Esta metodología permite una visión integral de cómo los datos pueden ser recolectados, preparados, analizados y visualizados para obtener información útil. Se emplean herramientas especializadas para la gestión de datos, asegurando un tratamiento eficiente y efectivo. Se desarrollan dos casos de dominio mediante una variedad de contexto basada en dos zonas: Villa Regina y Guerrico.

Los resultados de este trabajo indican que la implementación de sistemas de big data puede colaborar efectivamente en la búsqueda de patrones y causas que ayuden a la identificación y predicción de heladas. En los casos de dominio de Villa Regina y Guerrico, el análisis de grandes volúmenes de datos ha demostrado ser beneficioso permitiendo comprender mejor las relaciones entre las variables y la construcción de modelos predictivos (redes neuronales artificiales) altamente eficientes incluso en periodos de hasta 24 horas. Esto fue acompañado por la utilización de la herramienta CoVaMaT (Context-based Variety Management Tool) para crear y almacenar la variedad hallada en estos casos de dominio. Los activos almacenados en CoVaMaT pueden ser luego reusados en la construcción de nuevos casos mejorando la calidad y rapidez en la construcción de los mismos.

Palabras Clave: *Big Data, agrometeorología, predicciones de heladas, análisis de datos, redes neuronales artificiales, correlación.*

ABSTRACT

Agrometeorology, which studies the interaction between meteorological factors and agricultural activities, faces the challenge of managing and analyzing large volumes of data (Big Data) to improve decision making. This thesis is motivated by the need to take advantage of advances in Big Data Systems to optimize weather predictions.

The main objective of this research is to evaluate and demonstrate how Big Data systems can be effectively integrated and applied in the domain of agrometeorology. To achieve this, the key components of big data systems, their life cycle and best practices in managing this data are investigated. The work focuses on specific domain cases based on information from weather stations to illustrate the practical application of these technologies.

The methodology used is based on a top-down approach proposed in previous works of the research group in which this thesis is framed. This methodology allows a comprehensive view of how data can be collected, prepared, analyzed and visualized to obtain useful information. Specialized tools are used for data management, ensuring efficient and effective treatment. Two cases of dominance are developed through a variety of context based on two areas: Villa Regina and Guerrico.

The results of this work indicate that the implementation of big data systems can effectively collaborate in the search for patterns and causes that help identify and predict frosts. In the domino cases of Villa Regina and Guerrico, the analysis of large volumes of data has proven to be beneficial, allowing a better understanding of the relationships between variables and the construction of highly efficient predictive models (artificial neural networks) even in periods of up to 24 hours. . This was accompanied by the use of the CoVaMaT tool (Context-based Variety Management Tool) to create and store the variety found in these domain cases. The assets stored in CoVaMaT can then be reused in the construction of new cases, improving the quality and speed in their construction.

Keywords: *Big Data, agrometeorology, frost prediction, data analysis, artificial neural networks, correlation.*

Índice general

1. Introducción	1
1.1. Motivación	1
1.2. Alcance y Limitaciones	3
1.3. Objetivos	3
1.3.1. Objetivos específicos	3
1.4. Metodología	4
1.5. Estructura	5
2. Sistemas de Big Data y Dominio de Aplicación	7
2.1. Sistemas de Big Data	7
2.2. Estándares en Big Data	8
2.2.1. ISO/IEC JTC1/SC42	9
2.2.2. NIST Big Data Public Working Group (NBD-PWG)	10
2.2.3. Comité Internacional de Estándares de Tecnología de la Información (IN-CITS)	10
2.3. Ciclo de vida de Big Data	11
2.3.1. Evaluación del caso de negocio	11
2.3.2. Identificación y recolección de datos	12
2.3.3. Preparación de los datos	12
2.3.4. Análisis de datos	14
2.3.5. Modo de análisis	16
2.3.6. Visualización y utilización de los datos	16
2.4. El dominio de la agrometeorología	17
2.5. Trabajos relacionados	18
2.5.1. Trabajo presentado por Verdes et al.	18
2.5.2. Trabajo presentado por Ding et al.	20
2.5.3. Trabajo presentado por Ding et al.	21
2.5.4. Trabajo presentado por Zhou et al.	23
2.5.5. Trabajo presentado por Kotikot et al.	24
2.5.6. Trabajo presentado por Gobbett et al.	26
2.5.7. Trabajo presentado por Diedrichs et al.	27
2.5.8. Trabajo presentado por Talsma et al.	29
2.5.9. Resumen de trabajos relacionados	29
2.6. Trabajos previos dentro del Proyecto de Investigación	33
2.6.1. El concepto de variedad	34
2.6.2. El Proceso de Big Data	34
2.6.3. Enfoques Top-Down y Bottom-up para identificar la variedad	35
2.6.4. Herramienta para la Gestión de la Variedad basada en Contexto (CoVaMaT)	36
2.7. Resumen del capítulo	38

3. Aplicación del Enfoque Top-Down para la creación de Casos de Dominio	39
3.1. Enfoque Top-Down para el desarrollo de casos de dominio	39
3.1.1. Caso de Dominio 1: Villa Regina	39
3.1.2. Caso de Dominio 2: Guerrico	63
3.2. Resumen del capítulo	80
4. Conclusiones y Trabajo Futuro	83
4.1. Resumen del Trabajo	83
4.2. Limitaciones y Trabajos Futuros	85
A. Apéndice	87
A.1. Resultados del análisis de correlación Villa Regina.	87
A.2. Configuración de la Red Neuronal Artificial	90
A.3. Resultados de las ejecuciones de las redes neuronales artificiales Villa Regina. . .	90
A.4. Resultados del análisis de correlación Guerrico.	94
A.5. Resultados de comparación entre Villa Regina y Guerrico	96

Índice de figuras

1.1. Enfoques Top-Down y Bottom-up para el desarrollo de Big Data considerando variedad.	3
2.1. Ciclo de Vida para Sistemas de Big Data	12
2.2. Resumen de los trabajos relacionados.	32
2.3. Enfoques Top-Down y Bottom-up para el desarrollo de SBD considerando variedad.	33
3.1. Enfoque Top-Down aplicado a dos casos de dominio	40
3.2. Estaciones meteorológicas junto con el área que abarcan	40
3.3. Proceso P-1 donde documentamos la variedad de contexto como un nuevo <i>activo de dominio de agrometeorología</i> en CoVaMaT	41
3.4. Proceso P-1 donde documentamos la variedad de las fuentes dentro del <i>activo de dominio de agrometeorología</i> en CoVaMaT	42
3.5. Proceso P-1 donde documentamos la variedad de contenido como <i>activo de dominio de agrometeorología</i> en CoVaMaT	46
3.6. Resultados del análisis de correlación para el <i>Conjunto de Datos Original Regina</i> con los métodos de Pearson, Spearman y Kendall	47
3.7. Diagramas de dispersión y densidad entre <i>Velocidad del Viento (WindSpeed)</i> y <i>Temperatura Mínima (LowTemp)</i>	48
3.8. Diagramas de dispersión y densidad entre <i>Aire Desplazado por el Viento (WindRun)</i> y <i>Temperatura Mínima (LowTemp)</i>	49
3.9. Diagramas de dispersión y densidad entre <i>Presencia de Lluvia (Rain)</i> y <i>Temperatura Mínima (LowTemp)</i>	49
3.10. Diagramas de dispersión y densidad entre <i>Promedio de Lluvia (RainRate)</i> y <i>Temperatura Mínima (LowTemp)</i>	50
3.11. Resultados del análisis de correlación para los <i>Conjuntos de Datos Dinámico Regina (n)</i> desde $n = 0$ hasta $n = 138$ con los métodos de Pearson, Spearman y Kendall	51
3.12. Resultados del análisis de correlación considerando el valor promedio de cada variable para los métodos de Pearson, Spearman y Kendall.	52
3.13. Gráfico de líneas entre <i>Velocidad el Viento (WindSpeed)</i> y <i>HeladaCont</i>	54
3.14. Gráfico de líneas entre <i>Aire Desplazado por el Viento (WindRun)</i> y <i>HeladaCont</i>	54
3.15. Gráfico de líneas entre <i>Promedio de Lluvia (RainRate)</i> y <i>HeladaCont</i>	55
3.16. Métricas derivadas de las matrices de confusión para cada modelo creado	57
3.17. Comportamiento de las métricas derivadas de la matriz de confusión para la nueva configuración de 32 unidades ocultas y 6 variables.	59
3.18. Comparación de las métricas derivada de las matrices de confusión para la configuración de 13 variables y 32 unidades ocultas (<i>Configuración13</i>), y la configuración de 6 variables y 32 unidades ocultas (<i>Configuración6</i>).	60
3.19. Proceso P-1 donde documentamos la variedad de procesos como <i>activo de dominio de agrometeorología</i> en CoVaMaT	61

3.20. Formulario para predecir la ocurrencia o no de heladas en n horas posteriores . . .	61
3.21. Resumen de las variedades para cada clase, almacenadas como un activo de dominio de agrometeorología	64
3.22. <i>Caso de dominio VR</i> creado a partir de las instanciaciones del <i>activo de dominio de agrometeorología</i>	64
3.23. Caso de Dominio 2 para el área que incluye la Estación Meteorológica Guerrico .	65
3.24. Creación de una nueva variedad de contexto para el área de Guerrico y de un nuevo caso reusable <i>Caso reusable Guerrico</i>	65
3.25. Creación de una nueva variedad de fuentes instanciada al <i>Caso reusable Guerrico</i>	66
3.26. Instanciación de las variables climáticas asociadas con el <i>activo de dominio de agrometeorología</i> al <i>Caso reusable Guerrico</i>	67
3.27. Resultados del análisis de correlación para el <i>Conjunto de Datos Original Guerrico</i> con los métodos de Pearson, Spearman y Kendall	67
3.28. Diagramas de dispersión y densidad entre <i>Velocidad del Viento (WindSpeed)</i> y <i>Temperatura Mínima (LowTemp)</i> en Guerrico	68
3.29. Diagramas de dispersión y densidad entre <i>Aire Desplazado por el Viento (WindRun)</i> y <i>Temperatura Mínima (LowTemp)</i> en Guerrico	69
3.30. Diagramas de dispersión y densidad entre <i>Presencia de Lluvia (Rain)</i> y <i>Temperatura Mínima (LowTemp)</i> en Guerrico	69
3.31. Diagramas de dispersión y densidad entre <i>Promedio de Lluvia (RainRate)</i> y <i>Temperatura Mínima (LowTemp)</i> en Guerrico	70
3.32. Resultados del análisis de correlación para los <i>Conjuntos de Datos Dinámico Guerrico</i> (n) desde $n = 0$ hasta $n = 138$ con los métodos de Pearson, Spearman y Kendall	71
3.33. Resultados del análisis de correlación considerando el valor promedio de cada variable para los métodos de Pearson, Spearman y Kendall.	72
3.34. Gráfico de líneas entre <i>Velocidad del Viento (WindSpeed)</i> y <i>HeladaCont</i>	73
3.35. Gráfico de líneas entre <i>Aire Desplazado por el Viento (WindRun)</i> y <i>HeladaCont</i> .	73
3.36. Gráfico de líneas entre <i>Promedio de Lluvia (RainRate)</i> y <i>HeladaCont</i>	74
3.37. Instanciación de las variedades de procesos asociadas con el <i>activo de dominio de agrometeorología</i> al <i>Caso reusable Guerrico</i>	74
3.38. Porcentaje de cambio entre los diferentes métodos de correlación para Villa Regina y Guerrico en el análisis de correlación con los conjuntos de datos originales. . . .	75
3.39. Porcentaje de cambio entre los diferentes métodos de correlación para Villa Regina y Guerrico en el análisis de correlación con los conjuntos de datos dinámicos. . .	76
3.40. Porcentaje de cambio de las variables relacionadas con el viento y la lluvia en el periodo de 24 horas para que no ocurran heladas.	78
3.41. Proceso P-1 donde documentamos la nueva variedad de procesos para la comparación como <i>activo de dominio de agrometeorología</i> en CoVaMaT	79
3.42. <i>Caso reusable Guerrico</i> creado a partir de las instanciaciones del <i>activo de dominio de agrometeorología</i>	80

Índice de tablas

2.1. Cuadro comparativo de trabajos relacionados	30
3.1. Tabla descriptiva de las variables seleccionadas.	43
3.2. Representación del conjunto de datos antes (a) y después (b) de la imputación de valores nulos.	44
3.3. Ejemplo del nuevo <i>Conjunto de Datos Dinámico</i> (con la variable <i>HeladaCont</i>) con un $n = 6$	44
3.4. Ejemplos de los conjuntos de datos dinámicos con (a) $n = 6$, (b) $n = 12$, y (c) $n = 138$	45
3.5. Ejemplo de registros con la variable <i>HeladaCat</i> imputados con valores categóricos.	46
3.6. a) Resultados de VIF antes y b) después de la regularización L2 Ridge.	56
3.7. Variables seleccionadas para la hipótesis $H4$	59
3.8. Predicciones de heladas para 20 filas del <i>Conjunto de Datos Original Regina</i> en 2 horas posteriores utilizando el modelo predictivo de $H4$	62
A.1. Resultados de la correlación de Pearson en un periodo de 24hs (Villa Regina). . .	87
A.2. Resultados de la correlación de Spearman en un periodo de 24hs (Villa Regina). .	88
A.3. Resultados de la correlación de Kendall en un periodo de 24hs (Villa Regina). . .	88
A.4. Promedios parciales y generales de las correlaciones de Pearson, Spearman y Kendall (Villa Regina).	88
A.5. Tabla de valores mínimos de <i>Velocidad del Viento (WindSpeed)</i> para que no ocurran heladas (Villa Regina).	88
A.6. Tabla de valores mínimos de <i>Aire Desplazado por el Viento (WindRun)</i> para que no ocurran heladas (Villa Regina).	89
A.7. Tabla de valores mínimos de <i>Promedio de Lluvia (RainRate)</i> para que no ocurran heladas (Villa Regina).	89
A.8. Resultados promediados de la Matriz de Confusión y métricas derivadas para 8 unidades ocultas.	91
A.9. Resultados promediados de la Matriz de Confusión y métricas derivadas para 16 unidades ocultas.	91
A.10. Resultados promediados de la Matriz de Confusión y métricas derivadas para 32 unidades ocultas.	92
A.11. Resultados promediados de la Matriz de Confusión y métricas derivadas para 64 unidades ocultas.	92
A.12. Resultados promedios de la Matriz de Confusión y métricas derivadas para 32 unidades ocultas y conjunto de datos reducido.	93
A.13. Resultados de la correlación de Pearson en un periodo de 24hs (Guerrico).	94
A.14. Resultados de la correlación de Spearman en un periodo de 24hs (Guerrico). . . .	94
A.15. Resultados de la correlación de Kendall en un periodo de 24hs (Guerrico).	95
A.16. Promedios parciales y generales de los coeficientes de correlación de Pearson, Spearman y Kendall (Guerrico).	95

A.17.Tabla de valores mínimos de <i>Velocidad del Viento (WindSpeed)</i> para que no ocurran heladas (Guerrico).	95
A.18.Tabla de valores mínimos de <i>Aire Desplazado por el Viento (WindRun)</i> para que no ocurran heladas (Guerrico).	95
A.19.Tabla de valores mínimos de <i>Promedio de Lluvia (RainRate)</i> para que no ocurran heladas (Guerrico).	95
A.20.Resultados del porcentaje de cambio entre los diferentes métodos de correlación para Villa Regina (V. Regina) y Guerrico, para los conjuntos de datos originales.	96
A.21.Resultados del porcentaje de cambio entre los diferentes métodos de correlación para Villa Regina (V. Regina) y Guerrico, para los conjuntos de datos dinámicos.	96
A.22.Porcentaje de cambio de las variables relacionadas con el viento y la lluvia de Guerrico en comparación con Villa Regina en un periodo de 24 hs.	97

Capítulo 1

Introducción

En este capítulo describimos el contexto en el cual se enmarca este trabajo de tesis y la motivación de la realización del mismo. Además, se describen los objetivos, la metodología empleada para su desarrollo y su estructura.

1.1. Motivación

Las metodologías para el desarrollo de Sistemas de Big Data (SBDs) han ido evolucionando en los últimos años para incluir, además de las actividades para llevarlos a cabo, un conjunto de técnicas y recursos que soportan los desarrollos. Los SBDs no son sistemas tradicionales, sino que se basan en un conjunto de requerimientos diferentes y por lo tanto los recursos conocidos no son ya aplicables a los mismos. Por ejemplo, estos sistemas poseen requerimientos de gestión de grandes volúmenes de datos, datos variados en cuanto a su estructura, crecimiento exponencial de datos, necesidad de procesamiento eficientes, entre otros [1, 2]. Al mismo tiempo, los SBDs se pueden enmarcar dentro de sistemas orientados al dominio, ya que es posible enfocarse en dominios particulares y crear sistemas que posean partes comunes y variantes según los requerimientos específicos del caso de dominio a desarrollar. En este contexto, en esta tesis se plantea trabajar en el dominio de la agronomía digital y más específicamente en la *agrometeorología* o meteorología agrícola. En particular, en este dominio se estudia la influencia de las variables meteorológicas, climáticas e hidrológicas y su interacción con los procesos y prácticas relacionadas con la producción agrícola [3]. Por ejemplo, se estudia la importancia de los factores climáticos en los rendimientos de las plantaciones, mecanismos para mejorar situaciones climáticas adversas que suceden en las zonas analizadas, etc. En este trabajo nos centramos principalmente en el problema de las heladas, ya que debido a la zona en la que nos encontramos, las mismas, cuando son tardías, generan grandes daños en la producciones, lo que se traduce en grandes pérdidas socioeconómicas.

Existen varios trabajos en la literatura que desarrollan SBD para estudiar diferentes aspectos de este fenómeno [4, 5, 6, 7, 8, 9, 10]. Por ejemplo, la propuesta presentada en [4] tiene como objetivo desarrollar un sistema de predicción empírica para la protección contra heladas de frutas y hortalizas en el sur de la provincia de Santa Fe en Argentina. También, el trabajo presentado en [5] se enfoca en la predicción de heladas utilizando modelos de causalidad en lugar de simplemente asociaciones. Los autores buscaron identificar un modelo causal entre las heladas y determinados factores ambientales. En el trabajo de Zhou et al. [7] los autores utilizaron variables climáticas a partir de sensores de estaciones con el objetivo de desarrollar un método basado en redes neuronales recurrentes (RNN) [11] para analizar la frecuencia de predicción de eventos de heladas, pasando de una vez cada 12 a 24 horas a predicciones minuto a minuto. Por último, podemos citar el trabajo presentado en [8], que en conjunto con factores climáticos, utiliza datos topográficos para identificar zonas de heladas y estimar la probabilidad de ocurrencia de las mismas.

En el trabajo propuesto para esta tesis nos basamos en una metodología de desarrollo de SBDs realizada en trabajos previos del grupo de investigación en donde esta enmarcado el mismo; cuyas actividades no sólo involucran aquellas ya reconocidas en la literatura para estos sistemas, sino además actividades específicas en pos de crear sistemas que puedan ser reusados. Particularmente, en trabajos previos [12, 13, 14, 15], hemos propuesto dos perspectivas de desarrollo de SBD basados en la identificación de la *variedad*: top-down (T-VIP) y bottom-up (B-VIP) [12, 13] (Figura 1.1). El concepto de *variedad* fue creado como un eje fundamental para proveer flexibilidad y adaptabilidad en la generación de SBDs (o casos de dominio particulares); y los enfoques propuestos permiten su identificación, definición y aplicación. En la parte superior de la Figura 1.1 podemos observar cómo estas perspectivas dividen el proceso de desarrollo de SBD en dos partes. En el enfoque T-VIP (lado izquierdo) se comienza desde una hipótesis la cual debe ser corroborada con los datos disponibles, es decir, el sistema se construye hacia abajo. En cambio, en el enfoque B-VIP (lado derecho) se realiza un estudio exploratorio comenzando desde las fuentes de información disponibles y construyendo un sistema hacia arriba. Al mismo tiempo, ambos enfoques deben realizar las actividades definidas en todo proceso de desarrollo de big data como [16]: la *colección* de datos de origen (ingesta de datos), la *preparación* y transformación de esos datos para aplicarse dentro de la actividad de *análisis* de datos y determinación del tipo de procesamiento (por lotes, en tiempo real, etc.), la *visualización* del análisis resultante y el *acceso* de los consumidores de datos a estos resultados. Ahora, con la inclusión del concepto de *variedad*, estas actividades se ven influenciadas en las decisiones de diseño que se lleven a cabo durante su realización involucrando alguna de las siguientes categorías de la variedad: (1) *variedad de fuentes* durante la *colección* de los datos, ayuda a detectar diferentes estructuras de datos, técnicas de adquisición, etc., (2) *variedad de contenido* se enfoca en la forma en que los datos deben transformarse de acuerdo con variables relevantes para lograr los objetivos, principalmente considerando variaciones de fuentes durante la actividad de *preparación*, (3) *variedad de procesos* ayuda a detectar variaciones en las técnicas de análisis de datos y está particularmente involucrada en *analítica* y *visualización*, y (4) *variedad de contexto* permite a los desarrolladores identificar variaciones de dominio que pueden limitar o afectar los resultados del análisis durante todo el desarrollo de SBD. De esta forma, estas variedades deben identificarse durante el desarrollo de este tipo de sistemas de forma de encontrar puntos en común y diferencias que puedan documentarse y reusarse luego en futuros desarrollos. Así, en la parte derecha de la Figura 1.1 podemos observar los activos a ser creados, en donde destacamos la base de conocimiento denominada CoVaMaT (Context-based Variety Management Tool) [12, 17]. Esta base se crea mediante una herramienta de software que permite modelar la variedad de los casos desarrollados identificando las variaciones en cada uno. De esta forma, se crean un conjunto de activos que pueden ser reusados en futuros desarrollos.

Considerando dichos enfoques, en esta tesis realizamos la aplicación de un proceso T-VIP que comienza desde hipótesis definidas por los usuarios expertos y por los trabajos en la literatura y realiza las actividades necesarias para la verificación de las mismas. En particular, nos centramos en el análisis de la detección y ocurrencias de las heladas tardías en el Alto Valle de Río Negro y Neuquén, las cuales son las que realmente producen daños en las plantaciones. Para realizar este trabajo se cuenta con la colaboración de personal experto del INTA que nos brindan los datos y sus conocimientos para que se pueda llevar a cabo.

De esta forma, esta tesis tiene como objetivo aplicar el enfoque T-VIP identificando las variedades existentes durante el desarrollo de casos de dominio. Al mismo tiempo, las variedades encontradas deben almacenarse utilizando la herramienta CoVaMat, de manera que puedan reusarse en el desarrollo de otros casos. El resultado de los casos de dominio creados son utilizados por expertos del INTA de modo de analizarlos para la comprensión y estudio de los factores climáticos con respecto a las heladas en la región.




Figura 1.1: Enfoques Top-Down y Bottom-up para el desarrollo de Big Data considerando variedad.

1.2. Alcance y Limitaciones

Este trabajo se enmarca en tareas de investigación del proyecto 04/F019 *Modelado de Variedad en Sistemas de Big Data* y se establece confidencialidad con respecto a todo dato que sea utilizado en los casos de dominio desarrollados.

1.3. Objetivos

El objetivo general de esta tesis es:

Desarrollar casos de dominio para el análisis de ocurrencia y detección de heladas tardías mediante la aplicación de un enfoque top-down que identifique y almacene las variedades encontradas.

1.3.1. Objetivos específicos

Del objetivo general se desprenden los siguientes objetivos específicos:

- *01 - Modelar el contexto para el análisis y definir hipótesis:* recolectar información de casos y elaborar una clasificación del contexto de acuerdo a usos, variables y modelos de análisis apropiados para la ocurrencia y detección de heladas tardías en la zona del Alto Valle de Río Negro y Neuquén. Se deben definir las hipótesis e identificar las variedades.
- *02 - Instanciar el modelo de contexto:* diseñar el modelo de datos necesario para adecuar los datos recolectados al procesamiento requerido por el desarrollo de los casos de dominio, de acuerdo a la clasificación realizada en O1. A su vez se deben modelar las variedades

encontradas y crear así los activos de dominio necesarios que deben documentarse en CoVaMat.

- *03 - Verificar las hipótesis:* verificar las hipótesis mediante la instanciación de los activos de dominio creados en O2. Es decir, se deben crear casos de dominio que utilicen el modelo común creado y pueda instanciar variedades de contexto para la creación de nuevos casos. Esto mostrará variaciones en los resultados que deberán analizarse por expertos. Los casos de dominio creados e instanciados deben también documentarse en CoVaMat ya que retroalimentarán la creación de nuevos casos.

1.4. Metodología

Este trabajo se enmarca tanto en revisiones de la bibliografía, como en modelado de dominio para SBDs. Asimismo, incluye necesidades específicas del caso de estudio y la instanciación del modelo en dicho caso. Para esto, se preveen reuniones con expertos del dominio (Del INTA Alto-Valle), así como el uso de frameworks de referencia existentes. Para el desarrollo basado en el modelado y documentación de la variedad (Figura 1.1), se aplicará un enfoque top-down que consiste de 5 pasos [13], como podemos observar en la Figura 1.1. El paso (1) comienza con la formulación de hipótesis por parte de un experto en el dominio, basadas en su conocimiento previo, lo que guía el análisis posterior de datos para validar esas suposiciones. Luego, (2) los analistas se sumergen en actividades de Big Data (3) para analizar los datos. Más tarde, estos resultados son devueltos para validar la hipótesis (4), posiblemente visualizando los resultados de diferentes maneras; y permitir la reformulación de hipótesis o la finalización del proceso, alternativamente (5). Como resultado de este enfoque, se generan casos específicos que encapsulan las variaciones identificadas, los cuales pueden ser reutilizados en instancias futuras, promoviendo así la eficiencia y la consistencia en futuros análisis dentro del mismo dominio. Al mismo tiempo, tanto el modelado de la variedad como los casos deben documentarse en CoVaMat.

De los objetivos planteados, se desprenden las siguientes actividades a ser terminadas en el transcurso de seis meses desde el comienzo de esta tesis:

- A1. Clasificación de elementos del contexto. Para esto se analizará el estado de la práctica (incluso en la Institución del caso de estudio), y las formas en que los expertos y los trabajos relacionados de la literatura hacen frente al problema de las heladas, en todos sus aspectos. Corresponde al objetivo O1.
- A2. Modelado del contexto. Se modelarán relaciones entre usos, variables, parámetros e indicadores, con los modelos de detección y ocurrencia de heladas y resultados alcanzados, según el estado de la práctica analizado en A1. A su vez se identificarán posibles variedades según la clasificación de la Figura 1.1. Corresponde al objetivo O1.
- A3. Recolección y preparación de datos. Se analizarán los datos de entrada de los casos de dominio, enfocando en aspectos de calidad como completitud, correctitud, etc. A su vez, se modelarán las variedades. Corresponde al objetivo O2.
- A4. Análisis de datos. Se utilizarán técnicas de análisis de estadísticas básicas para comprender las fuentes de datos y sus relaciones. Los datos provienen de estaciones meteorológicas de la región con una gran variedad de variables climáticas para analizar. Al mismo tiempo, se aplicarán técnicas de clasificación u otras sugeridas en la instanciación para realizar los análisis para cada uno de los casos de domino desarrollados. Corresponde al objetivo O3.
- A5 Documentación de los casos. Consiste en la documentación del modelo de variedad definido, junto con las variantes encontradas y su posterior instanciación en forma de casos de dominio dentro de la herramienta CoVaMat. De esta forma dicha documentación quedará

disponible para la realización de nuevos casos en este contexto y en otros. Corresponde a los objetivos O2 y O3.

- A6. Redacción del Reporte de la Tesis.

1.5. Estructura

La tesis se organiza de la siguiente manera:

- En el Capítulo 2 se presenta una descripción completa de los fundamentos relacionados con los SBDs, el dominio de aplicación, los trabajos relacionados en el mismo, y una descripción de los trabajos previos del grupo de investigación.
- En el Capítulo 3 se describe la aplicación del enfoque top-down para la construcción y documentación de dos casos en el dominio de agrometeorología.
- En el Capítulo 4 se presentan las conclusiones y trabajos futuros destacando las contribuciones y limitaciones de esta tesis.

Capítulo 2

Sistemas de Big Data y Dominio de Aplicación

En este capítulo se abordan los aspectos generales de los Sistemas de Big Data y su rol en la gestión de datos a gran escala. A continuación, se analizan los estándares en big data y se explora el ciclo de vida asociado a estos datos. Dentro del contexto de la agrometeorología, se analiza el impacto de este tipo de sistemas en la predicción de heladas a través del análisis de trabajos relacionados. Finalmente se describen los trabajos previos en los cuales se enmarca esta tesis, presentando sus avances, recursos propuestos y desarrollados.

2.1. Sistemas de Big Data

Los SBDs hacen referencia a sistemas informáticos diseñados específicamente para manipular y procesar conjuntos de datos que son difíciles de gestionar y analizar con herramientas tradicionales debido a su volumen, velocidad y variedad [1].

El crecimiento exponencial de datos estructurados y no estructurados ha impulsado el potencial de big data en aplicaciones inteligentes. Los dominios en los que se aplica big data son diversos, como Web, comercio minorista, banca, salud, medio ambiente, etc. Para abordar el desarrollo de SBDs se requieren herramientas y frameworks especializados debido a factores como el volumen masivo de datos (que pueden llegar al orden de exabytes), la velocidad en tiempo real, la variedad de datos y la necesidad de realizar diferentes tipos de análisis. El ciclo de vida de big data implica la recopilación de datos de diversas fuentes (como redes sociales, sensores, transacciones y otras actividades digitales), el almacenamiento en soluciones especializadas, el procesamiento y la visualización de datos. Al mismo tiempo, los SBDs utilizan una serie de tecnologías como la computación en la nube, frameworks de procesamiento paralelo y distribuido, bases de datos no relacionales, computación en memoria, etc.

A su vez, los SBD se basan en las llamadas 5' Vs, como conjuntos de características a cumplir:

- *Volumen*: Se refiere a conjuntos de datos tan grandes que no pueden ser procesados en una sola máquina, lo que requiere herramientas y frameworks especializados. Aunque no hay un umbral fijo para considerar los datos como big data, generalmente se refiere a datos a gran escala que son difíciles de almacenar, administrar y procesar con herramientas tradicionales.
- *Velocidad*: Hace referencia a la rapidez con la que se generan los datos. Fuentes como las redes sociales y los sensores pueden generar datos a alta velocidad, lo que contribuye al crecimiento exponencial de los datos. Esta alta velocidad resulta en grandes volúmenes de datos acumulados en poco tiempo. Algunas aplicaciones requieren análisis en tiempo real debido a plazos estrictos, como el comercio y la detección de fraudes en línea.

- *Variedad*: Hace referencia a las diferentes formas en las que se presentan, como estructurados, no estructurados o semi-estructurados. Esto incluye datos de texto, imágenes, audio, vídeo, etc.
- *Veracidad*: En el contexto de los datos, la veracidad hace referencia a la precisión y confiabilidad de los mismos. Es fundamental limpiar y normalizar los datos para eliminar el ruido y asegurar que sean significativos, precisos, y que provengan de fuentes confiables.
- *Valor*: Se refiere a la utilidad del dato para el propósito deseado. El objetivo principal del análisis en SBD es extraer valor de los datos. Este valor está vinculado a su veracidad y precisión. Además, en algunas aplicaciones, el valor también depende de la velocidad de procesamiento de los datos.

Es importante destacar que además de las características fundamentales enunciadas previamente, se pueden derivar otros atributos a tener en cuenta [1]:

- *Escalabilidad*: Se refiere a la capacidad para manejar un aumento en el volumen de datos o la carga de trabajo sin una degradación significativa del rendimiento. Es la capacidad de crecer o reducirse según sea necesario.
- *Distribución*: Es la práctica de dividir y distribuir los datos y tareas de procesamiento en múltiples servidores o nodos en un clúster¹. Cada nodo procesa una parte del trabajo de manera independiente.
- *Flexibilidad*: Se refiere a la capacidad de los SBDs para adaptarse a diferentes tipos de datos y cargas de trabajo. Esto incluye la capacidad de procesar datos estructurados y no estructurados y de ejecutar una variedad de operaciones de análisis.
- *Economía*: Se refiere al costo total de propiedad y la relación costo-efectividad de la plataforma. Los SBDs a menudo son más rentables en comparación con las soluciones tradicionales de gestión y análisis de datos.

En resumen, un SBD es una infraestructura tecnológica diseñada para trabajar con grandes cantidades de datos y obtener provecho de ellos. Esto es fundamental en ámbitos como empresas, investigación científica, gobierno y otros, para tomar decisiones informadas y extraer información valiosa de los datos.

2.2. Estándares en Big Data

Los estándares en el campo de big data son conjuntos de directrices técnicas y especificaciones que se desarrollan y adoptan para garantizar la interoperabilidad, calidad, seguridad y eficiencia de las soluciones y tecnologías relacionadas con el procesamiento y el análisis de grandes volúmenes de datos. Estos estándares son esenciales para que las organizaciones puedan aprovechar al máximo el potencial de big data de manera coherente y efectiva, independientemente de la plataforma, el proveedor, o la aplicación que utilicen. Estos estándares son una parte fundamental de la infraestructura tecnológica moderna que impulsa la analítica y la toma de decisiones basada en datos.

En esta sección, se exploran los estándares para big data creados específicamente por tres organizaciones normalizadoras: (1) el comité ISO/IEC JTC1/SC 42² que se dedica a la estandarización de la inteligencia artificial y la automatización; (2) el Grupo de Trabajo Público de big

¹Un clúster es un grupo de computadoras que trabajan juntas para mejorar el rendimiento, la disponibilidad y la tolerancia a fallos en aplicaciones y servicios.

²<https://www.iso.org/committee/6794475.html>

data del NIST (NBD-PWG)³, que se dedica a la estandarización y promoción de mejores prácticas en big data; y (3) el comité INCITS (InterNational Committee for Information Technology Standards)⁴ que propone estándares y normas en el campo de la tecnología de la información.

2.2.1. ISO/IEC JTC1/SC42

La ISO/IEC (JTC1/SC42) es un comité técnico internacional de estandarización especializado que opera dentro de la Organización Internacional de Normalización (ISO) y la Comisión Electrotécnica Internacional (IEC). Su enfoque principal se centra en la estandarización de tecnologías relacionadas con los campos de la inteligencia artificial (IA) y el aprendizaje automático (AA).

El JTC1/SC42 desempeña un papel crítico al establecer normas técnicas y directrices para una variedad amplia de aspectos dentro de los campos mencionados. Esto incluye áreas como el procesamiento de lenguaje natural (NLP), la visión por computadora, robótica, automatización cognitiva, ética en la IA y muchas otras. Estas normas tienen como objetivo facilitar la interoperabilidad, la seguridad, la calidad y la confiabilidad de las tecnologías de IA y AA.

La importancia del JTC1/SC42 radica en su capacidad para impulsar la adopción global de estas tecnologías al establecer un framework común de referencia. Esto es esencial ya que la IA y el AA se utilizan en una amplia variedad de aplicaciones. El contar con estándares internacionales sólidos, los fabricantes, los desarrolladores y los usuarios pueden confiar en que los sistemas y productos relacionados con la IA funcionarán de manera coherente y segura en todos los ámbitos.

JTC1/SC42 también trabaja en estrecha colaboración con otros comités técnicos de ISO/IEC para garantizar la coherencia entre los estándares de IA y AA y otros estándares técnicos, como los relacionados con la seguridad de la información, la ciberseguridad, la gestión de datos y más. Esto asegura que los campos de IA y AA se integren adecuadamente en una amplia gama de aplicaciones y sectores industriales.

En la actualidad, el comité ha publicado 20 estándares y 32 se encuentran en desarrollo. Además, tienen un total de 37 países miembros. Entre las normas publicadas podemos nombrar⁵:

- *Norma ISO/IEC TS 4213:2022*⁶: establece métodos para evaluar el rendimiento de modelos y algoritmos de aprendizaje automático para la clasificación.
- *Norma ISO/IEC 20546:2019*⁷: se enfoca en definir los términos y conceptos claves en el campo del big data, proporcionando una visión conceptual general y promoviendo la interoperabilidad y entendimiento común en esta área tecnológica.
- *Norma ISO/IEC TR 20547-1:2020*⁸: describe un marco de arquitectura de referencia para big data y cómo los usuarios pueden aplicarlo a sus necesidades específicas. Proporciona una guía para diseñar soluciones de big data adaptadas a problemas individuales.
- *Norma ISO/IEC TS 4213:2022*⁹: establece la Arquitectura de Referencia de Big Data (BDRA), que incluye dos puntos de vista arquitectónicos: una vista de usuario que define funciones y actividades en un entorno de big data, y una vista funcional que detalla las capas y componentes funcionales en esas capas.

³<https://bigdatawg.nist.gov/>

⁴<https://www.incits.org/>

⁵Datos obtenidos el 11 de noviembre de 2023

⁶<https://www.iso.org/standard/79799.html?browse=tc>

⁷<https://www.iso.org/standard/68305.html?browse=tc>

⁸<https://www.iso.org/standard/71275.html?browse=tc>

⁹<https://www.iso.org/standard/71277.html?browse=tc>

2.2.2. NIST Big Data Public Working Group (NBD-PWG)

El Instituto Nacional de Estándares y Tecnología (NIST, por sus siglas en inglés) es un organismo de los Estados Unidos dedicado a la especificación de pautas y modelos desarrollados para ayudar en el diseño, la implementación y la gestión de sistemas de tecnología de la información y comunicación, así como para crear mecanismos que permitan abordar problemas de seguridad cibernética y protección de la información.

Para afrontar estos desafíos y aprovechar las oportunidades de big data, en el año 2012 se implementó la Iniciativa de Investigación y Desarrollo de Big Data por parte de la Casa Blanca. Esta iniciativa busca acelerar el descubrimiento científico, fortalecer la seguridad nacional y transformar la educación mediante la mejora de la extracción de conocimiento de grandes cantidades de datos digitales. El NIST se involucró en esta iniciativa y creó un grupo de trabajo público llamado “NIST Big Data Public Working Group” (NBD-PWG) con la participación de la industria, la academia y el gobierno para desarrollar un “Framework de Interoperabilidad de Big Data”. Este framework busca establecer definiciones, taxonomías, arquitecturas de referencia, seguridad, y privacidad por medio de la definición de estándares para big data. El objetivo es proporcionar un framework tecnológico y de infraestructura neutra (independiente de las tecnologías) que permita a las partes interesadas identificar y utilizar las mejores herramientas de análisis para los requerimientos planteados. El framework se divide en 9 volúmenes, que tratan temas específicos relacionados con big data. Podemos nombrar algunos de ellos como¹⁰:

- *Volumen 1: Definiciones*[18]: proporciona definiciones y conceptos claves relacionados con big data, lo que establece una base común para comprender y hablar sobre el tema.
- *Volumen 2: Taxonomía*[19]: introduce una taxonomía que organiza y categoriza los términos y conceptos relacionados con big data, lo que facilita la comunicación y el entendimiento común.
- *Volumen 3: Casos de Uso y Patrones de Implementación*[20]: ofrece ejemplos de casos de uso de big data y patrones de implementación que ayudan a aplicar eficazmente tecnologías de big data.
- *Volumen 4: Seguridad y Privacidad*[21]: aborda aspectos de seguridad y privacidad en el contexto de big data, proporcionando recomendaciones para proteger los datos y garantizar el cumplimiento normativo.

2.2.3. Comité Internacional de Estándares de Tecnología de la Información (INCITS)

El Comité Internacional de Normas de Tecnología de la Información (INCITS) es un organismo que se dedica a la creación y gestión de estándares en el ámbito de la Tecnología de la Información y las Comunicaciones (TIC). Fundado en 1960, su enfoque abarca la definición de normas y productos relacionados con el almacenamiento, procesamiento, transferencia, visualización, gestión y recuperación de datos. El comité opera bajo las regulaciones del American National Standards Institute (ANSI) y recibe respaldo financiero del Information Technology Industry Council (ITI).

INCITS ha contribuido al desarrollo de estándares ampliamente reconocidos y su comité de trabajo se enfoca en una amplia variedad de dominios tecnológicos, como seguridad, lenguajes de programación, bases de datos, almacenamiento, servicios de información, gobierno de TI y sostenibilidad de TI. Se han creado y aprobado más de 1200 estándares, con otros más continuando en desarrollo. Estos estándares son voluntarios, y su obligatoriedad depende de su adopción por parte del gobierno o de las fuerzas del mercado. Este comité también respalda las actividades

¹⁰Datos obtenidos el 11 de noviembre de 2023

de estándares internacionales y participa como miembro de varios comités de la ISO, lo que representa un apoyo al trabajo técnico a nivel internacional. La política de INCITS es adoptar como Normas Nacionales Estadounidenses “Idénticas” todas las normas ISO/IEC o ISO que caen dentro de su programa de trabajo, lo que facilita la armonización de estándares a nivel global y nacional. Además, se compromete a retirar cualquier estándar nacional estadounidense adoptado que haya sido retirado como estándar internacional.

Específicamente, INCITS ha colaborado estrechamente junto al comité técnico JTC1/SC42 para el desarrollo de estándares en inteligencia artificial y big data. Entre estos estándares se encuentran los mencionados en la Sección 2.2.1 y otros como¹¹:

- *Norma: INCITS/ISO/IEC 23053:2022[2022]*¹²: establece un marco para la IA y AA describiendo un marco genérico utilizando ambas. Este marco detalla los componentes del sistema y sus funciones dentro del ecosistema de la IA.
- *Norma: INCITS/ISO/IEC 38507:2022[2022]*¹³: ofrece orientación a los miembros del cuerpo directivo de una organización para facilitar y regir el uso de IA, con el objetivo de garantizar su uso efectivo, eficiente y aceptable dentro de la organización.
- *Norma: INCITS/ISO/IEC TR 24027:2021[2022]*¹⁴: se enfoca en abordar sesgos en sistemas de IA, particularmente en cuanto a las decisiones asistidas. Describe técnicas y métodos de medición para evaluar sesgos con el objetivo de identificar y mitigar vulnerabilidades relacionadas con los mismos. Cubre todas las fases del ciclo de vida de un sistema de IA, desde la recolección de datos, el entrenamiento, el aprendizaje continuo, el diseño, la prueba, la evaluación y el uso.
- *Norma: INCITS/ISO/IEC TR 24029-1:2021[2022]*¹⁵: ofrece información introductoria acerca de los métodos ya existentes para evaluar la robustez de las redes neuronales.

2.3. Ciclo de vida de Big Data

En ciclo de vida de big data presentado en [1] describe los pasos necesarios para implementar un caso de aplicación de big data junto con las opciones disponibles en cada uno.

Como se puede observar en la Figura 2.1 este ciclo de vida consta de 5 etapas, las cuales son: (1) evaluación del caso de negocio, (2) identificación y recolección de datos, (3) preparación de los datos, (4) análisis de los datos, (5) modo de análisis y, (6) visualización y utilización de los datos. En las siguientes subsecciones se describirán cada una de estas etapas en forma detallada.

2.3.1. Evaluación del caso de negocio

La evaluación del caso del negocio representa la fase inicial de un proyecto en la que se busca crear una visión general del ámbito de aplicación. Para esto se requiere una investigación previa para recopilar datos e información pertinentes en el dominio correspondiente. En esta etapa, se procede a la selección de técnicas y herramientas que se utilizarán en el proyecto, tomando en consideración la visión, misión y comprensión del dominio del proyecto, con el fin de identificar las más apropiadas para alcanzar los objetivos. Además, esta fase se centra en justificar la implementación de un SBD, lo que conlleva la identificación y comunicación clara de las razones y motivaciones detrás del proyecto. Por último, se procede a la definición de los objetivos del proyecto, los cuales deben cumplir con criterios específicos, medibles, relevantes y alcanzables en un tiempo razonable.

¹¹Datos obtenidos el 11 de noviembre de 2023

¹²https://standards.incits.org/apps/group_public/project/details.php?project_id=3737

¹³https://standards.incits.org/apps/group_public/project/details.php?project_id=3736

¹⁴https://standards.incits.org/apps/group_public/project/details.php?project_id=3741

¹⁵https://standards.incits.org/apps/group_public/project/details.php?project_id=3740



Figura 2.1: Ciclo de Vida para Sistemas de Big Data

2.3.2. Identificación y recolección de datos

Antes de que los datos puedan ser analizados, deben ser recopilados y almacenados en un repositorio central. La elección de las herramientas y frameworks para llevar a cabo esta recopilación depende en gran medida de la fuente de datos y de los tipos de datos que se están incorporando.

Existen varios tipos de conectores que pueden utilizarse en el proceso de recopilación de datos, y la elección de uno en particular depende de las necesidades del sistema. Algunos de estos conectores incluyen frameworks de mensajería de publicación-suscripción, colas de mensajería o bases de datos. Es importante considerar el tipo de fuente de datos al seleccionar un conector de datos. Las fuentes de datos pueden variar desde archivos y registros hasta bases de datos relacionales, como también incluir máquinas que generan datos de sensores en tiempo real o retroalimentación de redes sociales.

La velocidad de los datos es otro factor crucial a tener en cuenta. Algunos datos se generan y actualizan a alta velocidad, como los datos en tiempo real, lo que requiere mecanismos de comunicación con baja sobrecarga y latencia. Para este tipo de aplicaciones, se pueden utilizar por ejemplo, frameworks de mensajería distribuida de publicación-suscripción.

2.3.3. Preparación de los datos

Este paso es esencial antes de llevar a cabo cualquier análisis, ya que los datos suelen estar contaminados con diversos problemas que deben resolverse previamente. Estos problemas pueden incluir registros corruptos, valores faltantes, duplicados, abreviaturas inconsistentes, unidades dispares, errores tipográficos, ortografía incorrecta y/o formatos incorrectos. En este paso se deben realizar tareas de limpieza que permitan solucionar estos tipos de problemas. Al mismo tiempo se deben realizar tareas como:

- *Manipulación de datos*: se refiere a la transformación de los datos desde un formato sin procesar a otro. Esto puede ser necesario cuando los datos se recopilan de diferentes fuentes y presentan inconsistencias. La manipulación se encarga de unificar estos formatos para garantizar la consistencia en los datos procesados.
- *Normalización*: es esencial cuando los datos provienen de diversas fuentes que utilizan diferentes unidades, escalas o abreviaturas para representar la misma información. Por ejemplo, algunos datos meteorológicos pueden informar la temperatura en grados Celsius, mientras que otros utilizan grados Fahrenheit. La normalización permite estandarizar los datos para que sean coherentes y comparables.
- *Muestreo y filtrado*: son útiles cuando se desea procesar solo los datos que cumplen con ciertas reglas o criterios. El filtrado también puede utilizarse para eliminar registros incorrectos

o valores atípicos que puedan afectar la calidad del análisis.

Técnicas para la preparación de los datos

Para la preparación de los datos existen muchas técnicas, métodos y herramientas que dan soporte a esta actividad. En particular, cada problema asociado a los datos posee un conjunto de técnicas que pueden ser aplicadas. Por ejemplo, para el caso de valores nulos o faltantes se pueden eliminar directamente estos registros o sólo las eliminar las columnas que los poseen. Estas son técnicas simples que pueden utilizarse cuando dichos registros o columnas no representan pérdidas de información o no son de interés para el estudio. Sin embargo, cuando estas técnicas no son una opción, existen otras técnicas como la regresión lineal, estadísticas resumidas como la media o la mediana, etc. [22, 23, 24, 25, 26].

En particular, la técnica KNNImputer, utiliza el método k-NN para rellenar los valores vacíos en el conjunto de datos. Las ventajas de usar esta técnica son :

1. *Preservación de la distribución de los datos:* k-NN considera la distribución de los datos en su conjunto y reemplaza los valores faltantes observando los valores de sus k vecinos más cercanos. Esto significa que es más probable que los valores imputados se parezcan a la distribución de datos real.
2. *Manejo de la no linealidad:* puede manejar relaciones lineales y no lineales en los datos. Si los datos tienen patrones o relaciones complejas que no pueden capturarse eficazmente mediante métodos de imputación lineal, k-NN puede proporcionar mejores resultados.
3. *Sin supuesto de linealidad:* a diferencia de los métodos de imputación basados en regresión lineal, k-NN no supone una relación lineal entre variables, por lo que puede capturar asociaciones complejas y no lineales entre variables.
4. *Robustez ante los valores atípicos:* k-NN es menos sensible a los valores atípicos en comparación con otros métodos de imputación. No se basa en estadísticas resumidas como la media o la mediana que pueden verse muy influenciadas por valores atípicos.
5. *Imputación multivariada:* k-NN puede realizar imputación multivariada, lo que significa que considera múltiples características al imputar un valor faltante. Esto es valioso cuando la falta de una variable depende de los valores de muchas otras variables.

La aplicación de esta técnica de imputación de datos requiere la selección adecuada del número de vecinos (k) la cual puede obtenerse mediante la validación cruzada (cross-validation) utilizando el error cuadrático medio (MSE). El MSE [1] se calcula como la media de los cuadrados de las diferencias entre las predicciones del modelo y los valores reales en el conjunto de datos de prueba. De esta manera, se penaliza más fuertemente los errores más grandes, ya que los cuadrados amplifican las diferencias más grandes entre los valores predichos y los valores reales. Por lo tanto, cuanto menor sea el MSE, mejor será el modelo.

A su vez existen técnicas para el manejo de valores atípicos como:

- El *agrupamiento* suaviza los datos al considerar los valores cercanos, agrupándolos en contenedores o “cubos”. Esto resulta en un suavizado local, ya que se basa en la vecindad de los valores para ajustarlos.
- La *regresión lineal* busca encontrar la línea que mejor se ajuste a dos variables para predecir una a partir de la otra. En la regresión lineal múltiple, se consideran más de dos variables, y los datos se ajustan a una superficie en múltiples dimensiones para realizar predicciones más complejas.

2.3.4. Análisis de datos

El proceso de análisis implica determinar el tipo de análisis que se aplicará a los datos. Este paso consiste en seleccionar la técnica de análisis más adecuada para abordar las preguntas o problemas específicos que se desean resolver con los datos preparados. Puede implicar desde análisis descriptivos simples hasta análisis más avanzados como la minería de datos o el aprendizaje automático; dependiendo de los objetivos y de la naturaleza de los datos disponibles. La elección del tipo de análisis y los algoritmos es fundamental para obtener resultados significativos y tomar decisiones a partir de los datos. Para esto se deben tener en cuenta los siguientes puntos:

- *Naturaleza de los datos:* El tipo de análisis que se elige debe estar en línea con la naturaleza de los datos disponibles. Por ejemplo, si se trata de datos estructurados en forma de tablas, es posible realizar análisis estadísticos, consultas SQL u otros métodos específicos para datos tabulares.
- *Objetivos del análisis:* Los objetivos del análisis son un factor fundamental en la elección del tipo de análisis. Por ejemplo, si se busca describir patrones en los datos, el análisis descriptivo podría ser suficiente.
- *Complejidad de los algoritmos:* Algunos tipos de análisis pueden requerir algoritmos altamente complejos, mientras que otros pueden ser más simples. La elección depende de la capacidad de procesamiento y la disponibilidad de recursos computacionales. En los entornos de big data, donde la escala y la velocidad de los datos son significativas, es importante considerar la eficiencia y la escalabilidad de los algoritmos.
- *Herramientas y frameworks de trabajo:* La elección del tipo de análisis también puede estar influenciada por las herramientas y frameworks de trabajo disponibles.
- *Validación y evaluación:* Una vez que se ha aplicado el análisis, es esencial llevar a cabo procesos de validación y evaluación para asegurarse de que los resultados sean confiables y útiles. Esto puede implicar la comparación de diferentes algoritmos o enfoques para determinar cuál produce los mejores resultados.

Las técnicas de análisis de los datos van desde las más simples exploraciones de los datos, como sus distribuciones, comportamiento y correlaciones, como técnicas más complejas de la inteligencia artificial y aprendizaje (*machine learning*). Podemos englobar las técnicas y/o métodos de analítica de datos en 4 tipos de categorías que dependen de los resultados que producen [1]:

- *Descriptiva:* Implica resumir datos pasados para entender qué ocurrió utilizando estadísticas como recuentos, máximo, mínimo y media. Por ejemplo, se puede calcular la cantidad total de “Me gusta” en una publicación o la precipitación mensual promedio. En esencia busca responder a la pregunta “¿Qué sucedió?”.
- *Diagnóstica:* Examina datos pasados para entender por qué ocurrieron eventos específicos, buscando patrones que expliquen las fallas. Por ejemplo, en sistemas de monitoreo de máquinas, ayuda a identificar las razones detrás de una falla específica al analizar datos de sensores. En esencia busca responder a la pregunta “¿Por qué sucedió?”.
- *Predictiva:* Implica predecir eventos futuros basándose en datos pasados. Se entrena con datos existentes y se utiliza para predecir fallas, diagnósticos médicos, emergencias naturales y más. La precisión depende de la calidad de los datos. Se utilizan algoritmos de clasificación y regresión y se validan con datos de prueba. Responde a la pregunta “¿Qué es probable que suceda?”.

- *Prescriptiva*: Va más allá del análisis predictivo al sugerir la mejor acción entre varias opciones. Utiliza múltiples modelos de predicción para anticipar diferentes resultados. Por ejemplo, puede recomendar el mejor tratamiento para un paciente o el plan de datos más adecuado para un cliente. Responde a la pregunta “¿Qué podemos hacer para que esto suceda?”.

En forma general hay dos grandes formas de iniciar un proceso de análisis, ya sea mediante:

- *Aprendizaje supervisado*: Implica utilizar ejemplos etiquetados en el conjunto de datos de entrenamiento para enseñar al modelo a asignar categorías a nuevos datos. En otras palabras, se proporcionan entradas junto con las salidas deseadas para que el modelo aprenda a predecir las salidas correctas.
- *Aprendizaje no-supervisado*: Implica procesar datos sin etiquetar para encontrar patrones o clases dentro de ellos. Sin embargo, dado que los datos no están etiquetados, el modelo no puede proporcionar el significado semántico de los grupos encontrados. Este enfoque es útil para descubrir estructuras ocultas en los datos cuando no se dispone de información previa sobre las clases.

Considerando ambos tipos de aprendizaje, existen métodos o técnicas que se ajustan a cada uno de ellos e incluso técnicas que se pueden ajustar a ambos.

Para un análisis del tipo descriptivo, se pueden utilizar los coeficientes de correlación los cuales son utilizados cuando poseemos variables numéricas. Algunos de los coeficientes mas conocidos son [27]:

- *Correlación de Pearson*: evalúa la correlación lineal entre variables continuas, es sensible a la magnitud y la dirección de la relación lineal. En general se utiliza para medir la correlación entre dos variables continuas, por ejemplo, genero y peso.
- *Correlación de Spearman*: evalúa la correlación monótona, es decir, si cuando una variable aumenta, la otra tiende a aumentar o disminuir. Se utiliza para medir la correlación entre dos variables clasificadas, por ejemplo, rango de la calificación de un hotel frente al rango de edad de los que califican.
- *Correlación de Kendall*: evalúa la correlación de orden, es decir, se basa en la concordancia de los rangos entre las observaciones de dos variables. Se utiliza cuando se desea usar la correlación de Spearman, pero el tamaño de la muestra es pequeño y hay muchos rangos similares.

Los tres métodos pueden producir resultados similares cuando las relaciones entre las variables son lineales o monótonas, cuando no hay valores atípicos que afecten significativamente la relación entre las variables y, con respecto a Kendall, cuando la cantidad de datos es relativamente baja. En tales casos, los tres coeficientes de correlación pueden converger hacia valores cercanos entre sí.

Luego, para los tipos de análisis predictivos/diagnósticos, tenemos otro conjunto de técnicas que se puede aplicar. En nuestro caso, aplicamos redes neuronales con el fin de clasificación/predicción.

Las redes neuronales artificiales [28] son eficaces para tareas de predicción y diagnóstico debido a su capacidad para aprender y modelar relaciones no lineales entre variables. En análisis predictivo, las ANN pueden identificar patrones y tendencias en datos históricos, facilitando pronósticos precisos sobre eventos futuros o comportamientos. En el diagnóstico, analizan características y señales para detectar anomalías o condiciones específicas. Su flexibilidad y capacidad de adaptación a nuevos datos, por su capacidad de aprendizaje, las hacen herramientas valiosas de predicción y diagnóstico. Sin embargo, a pesar de su potencia, las ANN requieren grandes volúmenes de datos para el entrenamiento y pueden ser vistas como cajas negras por su falta de transparencia en el proceso de toma de decisiones.

2.3.5. Modo de análisis

El proceso de análisis de datos no solo implica la selección del tipo de análisis adecuado, sino también la determinación del modo de análisis. Esta elección se basa en los requisitos específicos de la aplicación y tiene un impacto significativo en cómo se procesan y entregan los resultados del análisis. La elección del modo de análisis influye en el patrón de procesamiento de datos que se utiliza. Los modos de análisis se definen como:

- *Por Lotes:* Se utiliza cuando los resultados del análisis no requieren actualizaciones frecuentes y pueden generarse en intervalos más largos, como diariamente o mensualmente. Es eficaz para aplicaciones que no tienen la necesidad de responder en tiempo real, lo que puede incluir informes históricos, análisis de tendencias a largo plazo o procesamiento de grandes volúmenes de datos que no cambian rápidamente.
- *En Tiempo Real:* Se aplica cuando los resultados deben actualizarse de manera constante o en cortos intervalos de tiempo, como cada pocos segundos o minutos. Es esencial para aplicaciones que requieren información al instante, como sistemas de monitoreo en tiempo real, detección de fraudes, seguimiento de flujos de datos en tiempo real o cualquier escenario donde las decisiones deben tomarse de inmediato.
- *Interactivo:* Se utiliza cuando la aplicación necesita la capacidad de realizar consultas a pedido sobre los datos en tiempo real o en lotes. Es especialmente útil cuando se trata de aplicaciones donde los usuarios desean explorar y obtener información específica a través de consultas interactivas. Esto puede incluir paneles de control en tiempo real o herramientas de análisis de datos interactivos.

2.3.6. Visualización y utilización de los datos

La elección de las herramientas de visualización, bases de datos de servicio y frameworks Web en una aplicación de análisis depende en gran medida de los requisitos específicos de esa aplicación. Las herramientas de visualización desempeñan un papel esencial en la presentación de los resultados del análisis. La elección de la herramienta depende del tipo de visualización que se requiere y de la forma en que se presentarán los datos. Hay tres tipos principales de visualizaciones:

- *Visualizaciones estáticas:* Se utilizan cuando los resultados del análisis están almacenados en una base de datos y solo se desean mostrar tal como están. Son útiles cuando no es necesario que los datos se actualicen con frecuencia.
- *Visualizaciones dinámicas:* Se emplean cuando la aplicación exige que los resultados se actualicen periódicamente. Pueden incluir gráficos en vivo o indicadores en tiempo real que reflejan cambios continuos en los datos. Son adecuadas para aplicaciones que requieren seguimiento en tiempo real o supervisión constante.
- *Visualizaciones interactivas:* Estas son necesarias cuando la aplicación debe permitir a los usuarios interactuar con los datos y realizar consultas o análisis personalizados. Las visualizaciones interactivas permiten a los usuarios explorar los datos y obtener información específica según sus necesidades.

También la elección de la base de datos de servicio depende de cómo se almacenan y gestionan los datos utilizados en la aplicación. Las bases de datos pueden ser SQL o NoSQL, y la elección depende de la estructura y la naturaleza de los datos. SQL se utiliza para datos estructurados, mientras que NoSQL se adapta mejor a datos no estructurados o semiestructurados. También es importante considerar la escalabilidad y el rendimiento de la base de datos para cumplir con los requisitos de la aplicación.

Por último los frameworks Web son esenciales para construir la interfaz de usuario de la aplicación y poder habilitar la presentación de visualizaciones y resultados al usuario final. La elección del framework puede depender de la tecnología preferida, el lenguaje de programación y los recursos disponibles.

2.4. El dominio de la agrometeorología

Según la Organización Mundial de Meteorología [3], la agrometeorología o meteorología agrícola es la ciencia que aplica la meteorología, hidrología y edafología para estudiar la interacción entre la agricultura y el medio ambiente. Su propósito es reducir los impactos climatológicos y ayudar al sector agrícola a prepararse mediante la aplicación de estos conocimientos e información. Esta disciplina se extiende desde la capa del suelo hasta la atmósfera, considerando aspectos como la producción agrícola, la silvicultura, la cría de animales, la pesca y otros tipos de producción al aire libre e interior.

La agricultura es una actividad altamente dependiente del clima, incluso con los avances tecnológicos en las últimas décadas; difícilmente exista otra actividad que dependa tanto del clima como la agricultura. A su vez, la meteorología agrícola desempeña un papel importante en la comprensión de las emisiones y la contaminación asociadas con sistemas de producción no sostenibles, así como en la gestión del agua y la aplicación de técnicas de acuicultura y pesca. Esto incluye el diseño de sistemas de riego y drenaje, decisiones de uso de la tierra, selección de cultivos y animales, y elección de maquinaria agrícola. En la agricultura moderna, la ecología y la economía son igualmente importantes, y los problemas ambientales están interconectados.

Por otro lado, para que los cultivos se desarrollen de manera óptima, se requieren ciertas condiciones climáticas [29]. Es por esto que la agrometeorología es una ciencia crucial para el sector agrícola, ya que se encarga de descubrir y definir los efectos de los fenómenos meteorológicos e hidrológicos que afectan a los cultivos y aplicar ese conocimiento. Entre sus actividades se encuentra el estudio de la atmósfera en las capas cercanas al suelo, precipitaciones, temperatura, vientos, etc. Un gran porcentaje de las pérdidas que sufren los cultivos es causada por efectos climatológicos como la contaminación del suelo y el aire, la incidencia y los efectos de la sequía, crecimiento de cultivos, producción animal, la incidencia, frecuencia y extensión de las heladas, por nombrar algunos. Es la agrometeorología la encargada de encontrar las soluciones a estos problemas o de hallar diferentes métodos para poder aprovechar el potencial del clima.

La adaptación de la información y los conocimientos generados por la agrometeorología a las necesidades agrícolas contribuye a generar nuevas prácticas agrícolas o mejorar las ya existentes. Entre estas prácticas se encuentran la sostenibilidad de la industria, el mejoramiento de los cultivos, el aumento en la producción, la reducción de costos y riesgos, la reducción del impacto ambiental y la disminución de pérdidas ocasionadas por el clima. Para lograr esto, es fundamental interpretar correctamente los datos meteorológicos, lo que incluye estrategias de riego, asignación de agua, cuidados contra el viento, selección de lugares, protección contra la erosión, climas artificiales, medidas contra las heladas, entre otros.

En este trabajo nos centramos en el problema de las heladas, las cuales son un fenómeno climático que plantea una amenaza constante para los cultivos en todo el mundo. Es fundamental entender las diferencias entre dos tipos de heladas que afectan a los cultivos: (1) la helada por radiación y (2) la helada por advección. La primera ocurre en noches despejadas y calmas propiciando la formación de una inversión térmica donde las temperaturas cerca de la superficie caen por debajo del punto de congelación. Existen diversos métodos para proteger a la planta de este tipo de helada. En cambio, la segunda se produce cuando una masa de aire frío invade repentinamente una zona más cálida, la cual puede estar acompañada también de vientos y nubes. En este caso, existe una protección limitada contra este tipo.

Para mitigar los daños causados por las heladas, es crucial prevenir y predecir este fenómeno climático. La prevención y la predicción de las heladas implican el uso de información de alerta

temprana sobre las condiciones meteorológicas que conducen a las heladas, lo que permite a los agricultores tomar medidas de protección de manera oportuna. Al recibir alertas tempranas, los agricultores pueden tomar decisiones informadas que pueden marcar la diferencia entre pérdidas catastróficas y una cosecha exitosa. Por lo tanto, comprender las características de las heladas y tomar medidas proactivas es esencial para garantizar la seguridad alimentaria y el bienestar económico en las regiones afectadas por este fenómeno climático.

2.5. Trabajos relacionados

En la literatura existen varios trabajos dentro del dominio de agrometeorología que realizan análisis de detección y/o predicción de heladas. A continuación describimos un conjunto de ellos.

2.5.1. Trabajo presentado por Verdes et al. [4]

En el artículo presentado por Verdes et al. [4] los autores se centran en la importancia de la temperatura en la agricultura y la horticultura, y en especial en el impacto que las heladas pueden tener en la producción de cultivos. En particular analizan la región sur de la provincia de Santa Fe en Argentina. Para describir el contexto, definen los diferentes tipos de heladas, las cuales pueden ser de *advección* o *radiación*. Como describimos previamente, las primeras ocurren como resultado del ingreso a gran escala de aire frío provenientes de regiones polares, y su característica principal son los vientos moderados o fuertes. Además, suelen tener temperaturas muy inferiores a los 0°C por lo que llevar a cabo acciones de protección no siempre es factible. Este tipo de heladas genera muchos problemas en regiones de latitudes altas y/o de gran altura. Por otro lado, las heladas de *radiación* ocurren de noche como resultado de un gran enfriamiento por radiación de onda larga en condiciones atmosféricas tranquilas, claras y secas. Estas heladas suelen afectar más a las regiones que se encuentran entre 15°S y 40°S y entre 12°N y 40°N.

Al mismo tiempo, en la región analizada se utiliza una variedad de técnicas para optimizar el entorno físico del cultivo y actuar previo a la aparición de heladas. Sin embargo, los métodos para contrarrestar las consecuencias de las heladas tienen grandes requerimientos de energía, por lo que proponer mecanismos para la predicción de las temperaturas pueden ayudar a ahorrar horas de consumo de combustible o agua. En consecuencia, en este trabajo plantearon el objetivo de desarrollar un sistema de predicción empírica para la protección contra heladas de frutas y hortalizas.

En primer lugar, definieron un análisis de serie temporal de temperatura mínima, en el cual se eliminaron las variaciones estacionales a través de la onda media anual, y buscaron determinar si la serie residual tiene un componente determinista o si es puramente estocástica. Se ajustaron las series empleando una onda sinusoidal que sigue aproximadamente el comportamiento de la radiación solar.

Para determinar la naturaleza de la serie residual, se generaron 19 series sustitutas con espectro de potencia idéntico pero fases aleatorias. Se utilizó un estadístico discriminante basado en el error de predicción de un predictor vecino más cercano en espacios de pseudofase de diferentes dimensiones. Si el error de predicción para la serie original era menor que para las sustitutas, se rechazaba la hipótesis de un proceso estocástico simple, perdiéndose esta propiedad para dimensiones mayores. Esto indicó que la serie no pudo ser considerada como una clara señal de determinismo. Por lo tanto, se asumió que el registro de temperatura mínima correspondía a algún proceso estocástico y se buscaron identificar variables predictoras adecuadas. Así pues, se estudió la correlación entre las temperaturas mínimas y otras cuatro variables superficiales disponibles y fueron seleccionadas las variables que tenían correlaciones de n pasos con las temperaturas mínimas superiores a 0,2. Estas variables incluyeron la temperatura de bulbo húmedo y seco, nubosidad y las temperaturas mínimas de los días anteriores. Sin embargo, se aclara que el análisis se basa en una correlación lineal entre las series temporales y se sugiere que un análisis

más sofisticado debería considerar criterios no lineales, como la información mutua.

A su vez el trabajo remarca la diferencia entre los métodos empíricos y teóricos. Las fórmulas empíricas se proponen cuando existe una gran correlación entre la temperatura mínima nocturna y ciertas variables meteorológicas medidas varias horas antes. Para esto, utilizaron antecedentes de temperatura del aire, varias medidas de humedad, velocidad del viento y nubosidad, tomados en momentos fijos. Por otro lado, los métodos teóricos se obtuvieron a través de un análisis del balance de energía y los procesos de transferencia de calor.

Posteriormente presentaron tres métodos diferentes para predecir la ocurrencia de heladas: Redes Neuronales Artificiales (ANN), clasificadores Simple Bayes (SB) y k-Nearest Neighbors (k-NN) [22]. Para ello, utilizaron las mismas variables predictoras seleccionadas (temperatura mínima, temperatura de bulbo húmedo y seco, nubosidad y las temperaturas mínimas de los días anteriores) e intentaron pronosticar si por la noche la temperatura bajaba de los 0°C o no, es decir, una tarea de clasificación binaria. En todos los casos se utilizaron 2601 registros diarios de temperaturas mínimas y otras variables superficiales correspondientes al periodo mayo-septiembre de los años 1973-1989 (de una estación meteorológica en Zavalla), dividiendo el registro aleatoriamente en conjuntos de entrenamiento (75 %) y prueba (25 %).

Se implementó la ANN con 5 unidades de entradas (correspondientes a cada variable predictora), 1 unidad de salida (para el pronóstico), y entre 2 y 50 unidades ocultas¹⁶, utilizando el error cuadrático como función de costo para el aprendizaje. También, se entrenó una ANN con función de activación softmax¹⁷ en las unidades de salida y la función de costo de entropía cruzada.

Por otra parte, para k-NN se buscaron los estados pasados mas cercanos al presente de dos formas: (i) un enfoque estándar donde le dieron el mismo peso a todos los predictores; y (ii) ponderaron los pesos de las variables predictoras según su correlación con la temperatura mínima. Por este motivo normalizaron los registros con media 0 y desvío estándar $\sigma=1$. En consecuencia, se reconocieron buenos resultados con $k \sim 100$. Sin embargo, los mejores resultados se obtuvieron con la ponderación equitativa de las variables predictoras con un $k \sim 1000$, lo que es similar a los resultados de regresión multivariada estándar.

En referencia a los resultados del estudio, el trabajo indicó que era necesario utilizar una medida económica que considere el costo de proteger las plantas y la pérdida estimada de cultivos debido a la falta de protección en caso de heladas. Así presentaron tablas de contingencia y valores de índices de desempeño para diferentes métodos de clasificación, incluyendo el predictor persistente (PP), que asume que la temperatura mínima de mañana será igual a la observada hoy, como línea de base. Por otra parte, se observó que todos los métodos de clasificación mejoraron en gran medida el PP, que a pesar de su simplicidad, establece una condición estricta para evaluar el desempeño de los métodos de aprendizaje. En particular, para la predicción estricta de heladas, SB tuvo una ventaja en términos del índice POD¹⁸, mientras que ANN y k-NN produjeron menos falsas alarmas (índice Probability Of False Detection (POFD) más pequeño). Se observó que establecer el umbral de indicación de alarma en 1°C mejoró el rendimiento de ANN y k-NN, pero ligeramente empeoró sus índices POFD.

También se presentaron curvas ROC¹⁹ para los métodos de clasificación, donde se introdujo una función de riesgo que modifica la importancia relativa de los eventos de heladas más escasos pero dañinos frente a gran cantidad de ejemplos de eventos sin heladas. Por consiguiente, se concluyó que todos los métodos de clasificación considerados tienen un buen rendimiento en la predicción de heladas, y que la introducción de una función de riesgo puede mejorar su rendimiento.

¹⁶Una unidad oculta se encuentra entre las capas de entrada y salida, reciben entradas ponderadas y generan salidas utilizando una función de activación.[22]

¹⁷Softmax es una generalización de la función logística a múltiples variables.[30]

¹⁸Probability Of Detection

¹⁹Las curvas características de funcionamiento del receptor son una herramienta visual para comparar dos modelos de clasificación.[22]

Posteriormente tras aplicar las diferentes técnicas, los resultados indicaron una estructura ruidosa de los datos, lo que sólo permitió una ligera mejora en el rendimiento de algunas técnicas no lineales más sofisticadas en comparación con las ecuaciones de regresión multivariadas estándar. Por esta razón, sugirieron que las investigaciones adicionales deberían incluir el uso de datos más recientes y nuevas variables predictoras para extraer información no lineal más precisa. También se propuso la exclusión de patrones obvios de no heladas en el conjunto de entrenamiento para permitir que los diferentes métodos se centren en la discriminación de situaciones cercanas de heladas y no heladas. Además, se implementó una ANN con un número mayor de unidades ocultas para reducir el error al maximizar la varianza del conjunto. Por otra parte, se concluyó que las pruebas de las predicciones de SB superaron a ANN y a k-NN en la probabilidad de detección. Sin embargo, los SB tuvieron una mayor probabilidad de falsa detección.

2.5.2. Trabajo presentado por Ding et al. [5]

Este trabajo describe la importancia de predecir las heladas y proteger los cultivos de los daños causados por este fenómeno climático. Se mencionan, además, estudios previos que utilizan técnicas de aprendizaje automático (Machine Learning - ML) para predecir las heladas basándose en la temperatura pronosticada. Sin embargo, se señala que la temperatura no es el único factor que contribuye a las heladas, ya que la humedad, la radiación y el viento también desempeñan un papel. Se destaca la necesidad de una detección temprana y confiable de las heladas en áreas locales específicas para una protección eficaz de los cultivos. Se menciona el uso de tecnologías avanzadas de sensores para recopilar datos detallados de temperatura, humedad, radiación y velocidad del viento, con el objetivo de aplicar técnicas de ML en el pronóstico de heladas con alta resolución espacial y temporal. De esta forma, el artículo propone una metodología de modelado para el pronóstico de heladas, que incluye el análisis de datos, la selección de variables, la elección de modelos de ML y la interpretación de la incertidumbre. También se describen experimentos y resultados para evaluar diferentes variables y períodos de pronóstico. El objetivo planteado es el de capturar la posible relación causal entre los factores ambientales (temperatura, humedad y radiación) y la ocurrencia de heladas en el futuro.

En primer lugar, los autores describen el estudio y la construcción y prueba de los modelos de predicción de heladas utilizando datos recolectados por equipos de sensores instalados en un área local. Utilizaron dos conjuntos de datos: (1) *data-B*, que cubre un período específico de tiempo (del 29/12/2016 17:08hs al 08/01/2017 12:19hs) y se utiliza para discusión y análisis, y (2) *data-0*, que representa un subconjunto de datos del primero, y lo utilizaron para la construcción y prueba de modelos (del 30/12/2016 00:00hs al 08/01/2017 11:59hs). A su vez, establecieron conjuntos de datos de entrenamiento y prueba²⁰, llamados *data-train* y *data-test* respectivamente, para la construcción del modelo predictivo. Luego, utilizaron una serie de datos más grande para confirmar la representabilidad de los datos de muestra (del 29/12/2016 17:08hs al 31/01/2017 23:59hs con un total de 47.932 registros) llamado *data-R*. Los factores ambientales que analizaron son la temperatura del aire (A), la humedad relativa (H), la radiación neta (R) y la velocidad del viento (W) y observaron que los datos de helada (F) son simbólicos, mientras que los datos de A, H, R y W tienen un impacto continuo y acumulativo en las heladas es decir, se comportan como series de tiempo.

Con estos datos realizaron un análisis de correlación entre las variables A, H, R y W con respecto a F, utilizando el modelo aditivo de Holt Winter²¹ para las variables A, H y R en los cuatro conjuntos de datos. Se observó que *data-0* mostró un comportamiento razonablemente consistente en comparación con *data-R*. Además, hallaron correlación entre las cuatro variables candidatas, y se notó que A tiene el mayor impacto en F. No obstante, la correlación de W con A, H, R y F en *data-test* fue inconsistente con los otros conjuntos de datos. De esta manera, se

²⁰subconjuntos del segundo conjunto de datos, del 30/12/2016 3:00hs al 07/01/2017 19:59hs; y del 07/01/2017 21:00hs a 8/1/2017 08:59hs

²¹Holt-Winters es un método de proyección simple para la tendencia y la variación estacional.[31]

seleccionó a A como una variable a incluir en todos los modelos. A su vez, dado que la serie de tiempo de W fue ruidosa y presentó un comportamiento inconsistente en *data-test*, se decidió excluir a W en las pruebas. Por otra parte, como F es simbólico (sí/no), los datos de heladas estaban desequilibrados, con más registros de no heladas que de heladas, lo que dificultó la construcción de un clasificador binario equilibrado (ya que podía tender a generar más “no” que “sí”); y se buscó reflejar la posibilidad y el riesgo de heladas mediante valores continuos entre 0 y 1. Para abordar esto, se decidieron utilizar modelos de máquinas de vectores de soporte para regresión (SVR)²². Los datos de heladas se utilizaron como valores numéricos 1 (Sí) y 0 (No) para entrenar el SVR, y el resultado de la predicción se interpretó como la posibilidad de heladas en un período futuro.

Con los modelos SVR se realizaron una serie de experimentos para predecir las heladas utilizando diferentes variables. Dichas pruebas fueron llevadas a cabo utilizando diferentes configuraciones de las variables, como promedios móviles de A, H y R, en diferentes ventanas de tiempo. También se comparó el rendimiento de la predicción en un punto de tiempo futuro con el de un período de tiempo futuro. En la primer prueba, se utilizó solo A como variable para predecir F en diferentes ventanas de tiempo y se observó que A era importante para predecir F en las próximas horas. En la segunda y tercer prueba, se agregaron variables adicionales como la R y H para mejorar la sensibilidad y precisión de la predicción de F. En la cuarta y quinta prueba, se probaron diferentes combinaciones de variables para predecir F en diferentes ventanas de tiempo. En las pruebas 6, 7 y 8, se comparó el rendimiento de modelos individuales con diferentes ventanas de tiempo de pronóstico y se examinaron diferentes combinaciones de variables. Al finalizar, se encontró que H podía ayudar a una alarma temprana en un período de tiempo más largo, mientras que R era capaz de mejorar la sensibilidad de respuesta a cambios locales en un período de tiempo corto. Además, se propuso una estrategia de decisión práctica basada en los resultados de los modelos para establecer diferentes etapas de alarma antes de una helada. Se concluye que el enfoque de utilizar múltiples modelos con diferentes ventanas de tiempo y variables puede proporcionar un pronóstico más preciso de las heladas, y se sugiere la posibilidad de involucrar más modelos múltiples con diferentes conjuntos de variables para mejorar aún más la predicción. Sin embargo, se señala la necesidad de una medida de rendimiento más adecuada que se centre en el inicio y el final de las heladas, ya que son los momentos de mayor interés en la predicción.

Tras los experimentos hallaron que el modelo propuesto logró tasas de recuperación del 100 %, 99,3 % y 99,8 % en términos de predicción positiva de heladas en las próximas 1, 2 y 3 horas, con tasas de falsa alarma del 18,9 %, 20,1 % y 9,6 %, respectivamente. Además, los experimentos mostraron que la combinación de variables adecuada puede mejorar la capacidad de predicción de heladas y, al mismo tiempo, determinaron que A es el factor clave para los modelos predictivos de heladas, mientras que H y R también son importantes.

2.5.3. Trabajo presentado por Ding et al. [6]

Mas tarde, en el año 2020, los mismos autores publicaron un nuevo artículo presentado en [6]. En este trabajo centran sus esfuerzos en el modelado causal para la predicción de heladas mediante la utilización de técnicas de ML que utilizan la observación temprana de factores ambientales. Introducen el concepto de causalidad de Granger [32], la cual investiga la causalidad entre variables en una serie temporal utilizando regresiones con retraso en el tiempo. Así pues, se plantea la importancia de comprender la causa-efecto en ML y el objetivo de desarrollar métodos de modelado causal para la predicción de heladas en un futuro próximo.

Para ello, se utilizó una función que relaciona el conjunto de variables predictivas A, H, R y W con las heladas, con el propósito de obtener una ecuación adecuada que permita pronosticarlas

²²Una máquina de vectores de soporte transforma los datos de entrenamiento en una dimensión superior, donde encuentra un hiperplano que separa los datos por clase utilizando tuplas de entrenamiento esenciales llamadas vectores de soporte [22]

hasta un nivel temporal satisfactorio, considerando relaciones de subcausa-efecto. Al igual que en el artículo anterior, se observó que la correlación entre W y F no fue estable, por lo que se excluyó de los modelos, y se incorporó una variable adicional X para indicar los factores faltantes que no se pudieron observar, describir o seleccionar para los modelos de aprendizaje. Gracias a esto, nuevamente concluyeron que los modelos predictivos para el pronóstico de heladas no podrían funcionar sin A .

A su vez utilizan un modelo causal estructural (SCM)[33], para describir los mecanismos causales de un sistema. Para esto, definieron un conjunto de variables cuyos valores fueron determinados por factores ajenos al modelo (U), un conjunto de variables cuyos valores estaban definidos por factores dentro del modelo (V) y un conjunto de ecuaciones (E) que indicaban el valor de cada variable U en función de las variables V . Cada modelo SCM se asoció con un modelo gráfico causal que consistía en un conjunto de nodos (que representan variables) y aristas entre los nodos (que representan las funciones entre las variables). En particular, aplicaron un grafo dirigido, es decir, si existe una relación $A \rightarrow B$ entonces B es causada por A .

Luego, se entrenaron los modelos predictivos utilizando observaciones sincronizadas de las variables con el objetivo de capturar la asociación y/o correlación y de realizar una serie de predicciones. En primer lugar, se realizó la predicción separada de los valores futuros de los factores ambientales. Luego, se utilizó un modelo predictivo entrenado para predecir las heladas en el futuro. La predicción final del evento de heladas se llevó a cabo considerando los valores de las variables en el tiempo futuro, obtenidos a través del pronóstico de series temporales. Además, se utilizó un modelo gráfico para reflejar la relación entre los factores ambientales y el objetivo, mediante observaciones sincronizadas. En este modelo destacaron la existencia de una correlación significativa entre los valores iniciales y posteriores de las variables ambientales. También se sugirió el uso de variables sustitutas que compartían algunos patrones con las variables anteriores. Sin embargo, los modelos predictivos en el pronóstico de heladas presentaron una característica clave que los diferencia de las tareas de predicción habituales: la conciencia del tiempo en la suposición detrás del modelado. Esto quiere decir que aunque generalmente no se incluye una participación explícita del tiempo en el modelado, se requiere establecer un patrón de entrenamiento con observaciones sincronizadas de las variables y el objetivo, considerando el resultado de la predicción. Además, se mencionan cinco grupos de métodos de modelado para el pronóstico de heladas, en los cuales se utilizaron diferentes variables objetivo y variables derivadas de F . Estos grupos se consideraron casos especiales de un modelo general. Algunos grupos utilizaron promedios de valores de F en intervalos de tiempo específicos, mientras que otros introdujeron períodos de alarma explícitos antes de la ocurrencia de una helada. En cuanto a los datos, se utilizaron los mismos que en su trabajo anterior.

Más adelante se concluyó que la relación entre los factores ambientales y las heladas se considera una relación causa-efecto que se desarrolla en el tiempo. Para capturar esta relación, se propuso el uso de objetivos derivados que permitieron capturar el impacto ambiental relevante antes de que ocurra una helada y brindar una alarma temprana. Sin embargo, se señalaron algunas deficiencias en este enfoque, como la dificultad para encontrar el método de granularidad óptimo.

Además, se realizaron pruebas para el uso e interpretación de datos etiquetados, donde F se etiquetó con 1 y 0 para indicar la ocurrencia real de heladas. Se planteó la posibilidad de tratar la predicción como una tarea de clasificación o una tarea de regresión, dependiendo de cómo se manejen los valores 1 y 0. También concluyeron que los modelos que utilizaron directamente los valores brutos de las variables de entrada generaron resultados con más ruido, por lo que la granularidad de las variables de entrada ayudó a suavizar los datos y mejorar el rendimiento de los modelos. A su vez, se presentaron dos grupos de métodos de modelado. El primero utilizó objetivos derivados F sin un retraso de tiempo explícito, y el segundo objetivos derivados de F con dicho retraso. Después se compararon los resultados de predicción de ambos grupos, así como de otros métodos propuestos, utilizando métricas, como la precisión, y se observó que los modelos con retraso de tiempo explícito superaron a los modelos sin retraso en ciertos aspectos.

En consecuencia se desarrolló un modelo causal general aplicando un modelo SCM y SVR, y llegaron a las siguientes conclusiones: (i) el ajuste de curvas puede reducir la sensibilidad del modelo; (ii) la inclusión de demoras (tiempo) en los modelos puede ser desventajosa en algunos casos; y (iii) se debe tratar a la helada como una variable categórica y el aprendizaje como una clasificación. En resumen, los modelos con SVM y el uso explícito de las probabilidades de clasificación proporcionaron un rendimiento razonable en términos de la predicción de heladas.

2.5.4. Trabajo presentado por Zhou et al. [7]

Este artículo se enfoca en la utilización de redes neuronales recurrentes (RNN)[11]²³ incluyendo variantes como LSTM²⁴ y GRU²⁵ para mejorar factores como la velocidad de procesamiento del modelo, la precisión a largo plazo y la disponibilidad limitada de datos para los sistemas de Internet de las Cosas (Internet of Things - IoT) utilizados en la agricultura. Todo esto con el objetivo de desarrollar un método basado en redes neuronales recurrentes para aumentar la frecuencia de predicción de eventos de heladas, pasando de una vez cada 12 a 24 horas, a predicciones minuto a minuto para eventos de la hora siguiente.

El conjunto de datos utilizado, corresponde a los meses de junio, julio y agosto del 2016 y 2017. Estos datos (de acceso público) fueron obtenidos a partir de sensores en 30 estaciones meteorológicas de Nueva Gales del Sur y el Territorio de la Capital Australiana. Para estos datos se llevaron a cabo varias actividades de preprocesamiento antes de la construcción de los modelos con el propósito de extraer y seleccionar las variables requeridas. Las variables extraídas fueron la marca de tiempo, temperatura del aire, punto de rocío, humedad relativa, y velocidad y dirección del viento. El preprocesamiento incluyó la transformación de valores, el manejo de valores nulos, el ajuste de valores para el modelo objetivo y el ajuste a una configuración de modelos más específicos. A su vez, la variable del viento fue transformada en “*viento N*” y “*viento E*” (indicando vientos del norte y del este respectivamente) para así poder evitar los errores posiblemente obtenidos de los diferentes valores generados por la dirección del viento (entre 0 y 359 grados). También se crearon series de datos para adaptarlos a las estructuras de las redes neuronales.

Luego, para la construcción y prueba del modelo, se utilizó el conjunto de datos del 2016 para construir el modelo “actual” y el conjunto de datos del 2017 como pruebas finales, de tal modo que represente el “futuro” para las predicciones. Entonces para cada conjunto de datos de cada estación meteorológica, el 80 % de los datos se asignó aleatoriamente al conjunto de datos de entrenamiento y el otro 20 % al conjunto de datos de prueba. A su vez, fue creada una división adicional del 20 % del conjunto de datos de entrenamiento para usarlos como datos de validación. El conjunto de datos de entrenamiento fue utilizado para ajustar los parámetros de los modelos y con el conjunto de datos de validación ajustaron los parámetros durante el proceso de entrenamiento. Finalmente, con el modelo se realizaron predicciones de prueba con el conjunto de datos de prueba, proporcionando una métrica de error del modelo, y se compararon los errores generados a partir de los conjuntos de datos de prueba de 2017.

Se llevaron a cabo tres experimentos. El primero comparó el MSE entre los modelos basados en ANN y RNN; el segundo evaluó el MSE de modelos RNN con diferentes longitudes de secuencia; y el tercero analizó los factores relacionados con el tiempo de procesamiento para diferentes longitudes de secuencia, brindando una visión general de las capacidades de cálculo en tiempo real de los modelos. Además, se comparó la precisión de los modelos RNN basados en LSTM, GRU y ANN utilizando conjuntos de datos de prueba del mismo año y se encontró que LSTM tuvo la menor pérdida de MSE y superó la precisión de los modelos ANN. Los modelos LSTM

²³Los RNN son un tipo de modelo de ML supervisado, hechos de neuronas artificiales con uno o más circuitos de retroalimentación.

²⁴Las LSTM (long short-term memory) son ANN que reemplazan las unidades ocultas por celdas de memoria.

²⁵Las GRU (gated recurrent unit) tienen unidades recurrentes que capturan las dependencias de diferentes escalas de tiempo mediante conexiones recurrentes.

tuvieron la mayor precisión entre los modelos RNN.

Tras los experimentos, descubrieron que los modelos basados en RNN, especialmente LSTM, son más precisos que los modelos ANN cuando se prueban con conjuntos de datos del año actual. Al probar con conjuntos de datos del próximo año, los modelos basados en RNN tuvieron una pérdida mayor que los modelos ANN, lo que indica que los modelos ANN fueron más precisos en ese escenario. Aumentar la longitud de la secuencia de datos no redujo la pérdida promedio en la mayoría de los modelos RNN, excepto para LSTM que mostró una ligera disminución en la pérdida. Al comparar con los modelos ANN, algunos modelos LSTM y GRU con longitudes de secuencia de 20, 40, 80 y 100 tuvieron una pérdida menor, lo que demostró que la elección de la longitud de la secuencia de datos puede influir en la precisión del modelo. Los tiempos de entrenamiento y de inferencia fueron mayores en los modelos RNN en comparación con los modelos ANN, especialmente a medida que aumentó la longitud de la secuencia de datos. Los modelos LSTM tuvieron la mayor precisión entre los modelos RNN debido a las puertas adicionales para memorizar patrones de secuencia. Sin embargo, fueron más susceptibles al cambio de patrones climáticos en el próximo año, lo que afectó su precisión. Los modelos basados en RNN requirieron entradas en el orden de minutos lo que generó un impacto potencialmente alto en el consumo de energía. En contraste, los modelos ANN solo requirieron un conjunto de datos climáticos como entrada y pudieron adaptarse a diferentes intervalos de tiempo según los requisitos del sistema, lo que los hizo más adecuados para sistemas de predicción de heladas.

Todos estos resultados y comparaciones de este trabajo proporcionan información sobre la eficacia y las limitaciones de los modelos utilizados en la predicción de heladas en la agricultura, así como sugerencias para futuras investigaciones y mejoras en la precisión de los modelos.

En conclusión, los autores destacan que los modelos basados en RNN, especialmente LSTM, tuvieron una mayor precisión con los conjuntos de datos actuales, pero disminuyeron en los conjuntos de datos del próximo año, mientras que los modelos ANN mostraron una precisión constante en ambos conjuntos. Las longitudes de secuencia no afectaron significativamente la precisión de los modelos RNN, pero aumentaron el tiempo de entrenamiento e inferencia. Los modelos ANN fueron más rápidos y precisos, por lo que se destaca que serían más adecuados a largo plazo.

2.5.5. Trabajo presentado por Kotikot et al.[8]

Este trabajo posee como objetivo identificar zonas de heladas en las plantaciones de té en Kenia. Para esto, se describen los peligros naturales que se ven agravados por el cambio climático, los cuales representan una amenaza importante para el sector agrícola en esa región. También las heladas son muy perjudiciales para la productividad agrícola en esa zona y la falta de sistemas de alerta temprana deja a los agricultores desprevenidos. La temporada de heladas ocurre entre diciembre y marzo, durante la temporada seca, lo que se suma al impacto negativo debido a la falta de nubes. Los autores discuten sobre los mecanismos de formación de heladas, su relación con la topografía y las características de la superficie terrestre, y la importancia de considerar estos factores al evaluar el riesgo de heladas.

Como en el artículo presentado por Verdes et al. [4] (Subsección 2.5.1), aquí se menciona que las heladas pueden ser causadas por la radiación continua de energía superficial, la advección de aire frío o una combinación de ambos. Asimismo destacan que la superficie terrestre influye en la aparición de las heladas, y que las zonas bajas y los fondos de los valles tienden a ser más propensos a la formación de estos eventos debido a la acumulación de aire frío. Así pues, en base a estudios realizados en Australia e Irán, destacan que la elevación es un factor clave que influye en la frecuencia de las heladas. Además describen trabajos en donde se han encontrado correlaciones entre variables topográficas y la ocurrencia de heladas y que, en general, los modelos para la predicción de heladas varían desde categorizaciones simples hasta modelos multivariados.

De esta forma, en este estudio se integraron factores climáticos y topográficos para caracterizar las heladas en las tierras altas de Kenia, utilizando imágenes de teledetección y desarrollando

un modelo logístico para describir los factores que las afectan. A su vez, se hace una descripción muy detallada del área de estudio, la cual se encuentra en los condados de Kericho y Nandi en Kenia. Estas áreas tienen una topografía ondulada con altitudes de 1500 a 2400m sobre el nivel del mar. Los suelos son volcánicos y tienen una fertilidad de moderada a alta, y a su vez las precipitaciones son escasas. Para el estudio se obtuvieron un total de 282 observaciones, de las cuales 190 fueron de eventos de heladas y 82 de eventos de no heladas, en un periodo de 5 días entre los años 2011 y 2012. Estas observaciones fueron obtenidas mediante un estudio de campo en el que se realizaron encuestas por diferentes expertos para identificar y geolocalizar estos eventos. Es importante destacar que los eventos de no heladas fueron recopilados de lugares en los que los eventos de heladas no sucedieron pero si estaban sucediendo en otros sectores. Además utilizaron datos de teledetección, que incluían datos de elevación del producto SRTM²⁶ (shuttle radar topography mission) y datos de temperatura de la superficie terrestre (LST) del sensor MODIS²⁷. Asimismo, utilizaron datos del sistema de asimilación de datos y modelado de la superficie terrestre de la NASA (NASA-LIS²⁸) para obtener información sobre la humedad del suelo, velocidad del viento y humedad específica.

Luego, para llevar a cabo el estudio, se realizaron experimentos de regresión logística para estimar la probabilidad de ocurrencia de heladas. Para ello el modelo estimó la probabilidad de ocurrencia de una helada en función de las variables independientes, como la temperatura de la superficie terrestre, humedad específica, velocidad del viento, humedad relativa del suelo, convexidad (que mide la curvatura de la superficie terrestre), pendiente, elevación, distancia a un cuerpo de agua y longitud del flujo de pendiente ascendente (que mide la distancia promedio desde la cumbre más cercana). Más tarde se realizaron pruebas estadísticas para poder descartar variables poco relevantes y ajustes en los modelos de regresión. Además, se realizaron pruebas estadísticas para seleccionar las variables más relevantes para el modelo de regresión logística a través de métodos de selección de variables como mejores subconjuntos y el método paso a paso. A su vez, se complementaron estas pruebas con métodos automáticos de selección de variables, como mejores subconjuntos²⁹ y el método “stepwise”³⁰ para determinar las variables más significativas en el modelo. La selección se basó en criterios de bondad de ajuste, como el criterio de información de Akaike[34]³¹ (AIC), y la prueba de razón de verosimilitud³².

La primera prueba realizada fue un ajuste del modelo para evaluar su rendimiento y capacidad predictiva. La siguiente se efectuó para hallar dependencia lineal entre las variables predictoras teniendo en cuenta la intensidad de la varianza. Luego se compararon los coeficientes obtenidos de la regresión logística utilizando la variable original con los coeficientes obtenidos al incluir una variable transformada de la variable original. Tras estas pruebas preliminares, se dividió el conjunto de datos, un 75 % de los datos fue destinado al entrenamiento y un 25 % fue utilizado para probar el modelo. Similar a lo presentado por Ding et al., probaron el modelo con diferentes conjuntos de datos y verificaron que eran intercambiables con desvíos estándar bajos y baja variabilidad en la probabilidad de ocurrencia de heladas.

Para evaluar el rendimiento del modelo, se realizaron pruebas de ajuste que evaluaron el patrón de los residuos, su variación y variabilidad de acuerdo con los supuestos del modelo. También se calcularon medidas de ajuste del modelo como la proporción de la varianza de las variables predictivas o pruebas predictivas con tiempos de espera para el evento de heladas.

²⁶<https://www2.jpl.nasa.gov/srtm/>

²⁷<https://modis.gsfc.nasa.gov/>

²⁸<https://lis.gsfc.nasa.gov/>

²⁹El método mejores subconjuntos implica examinar todos los modelos para todas las combinaciones posibles de variables predictoras y determina el mejor conjunto de predictores para cada tamaño de subconjunto.

³⁰Stepwise es una construcción iterativa paso a paso de un modelo de regresión que implica la selección de variables independientes que se utilizarán en un modelo final.

³¹AIC proporciona una estimación simple de la desviación promedio fuera de la muestra

³²La prueba de razón de verosimilitud es una prueba de la suficiencia de un modelo más pequeño frente a un modelo más complejo. <https://www.ibm.com/docs/es/spss-statistics/saas?topic=measurements-likelihood-ratio-test>

Estas medidas evaluaron la capacidad predictiva del modelo y su asociación con los valores observados. Además, se evaluó el rendimiento de clasificación del modelo utilizando la tasa de clasificación correcta (CCR)[22], que es el porcentaje de tuplas del conjunto de prueba que el modelo clasifica correctamente, y se estableció un umbral de corte en 0,5 para discretizar las estimaciones continuas del modelo en dos grupos: ocurrencia y no ocurrencia de heladas. Se utilizó, a su vez, una muestra de prueba que representa el 25 % de las observaciones para evaluar la precisión del modelo en muestras no utilizadas en el entrenamiento. Más tarde se aplicó la técnica de validación cruzada de submuestreo aleatorio[22] para estimar la precisión promedio del modelo. Por último, se probó la sensibilidad del modelo a cambios en el umbral de corte de probabilidad y se calcularon las clasificaciones correctas, falsos positivos y falsos negativos para diferentes umbrales.

Se compararon dos modelos, uno univariable (que utiliza sólo la variable LST) y otro multivariable. Tras los experimentos con el modelo univariable descubrieron que varias de las variables analizadas estaban asociadas con la ocurrencia de heladas, excepto la velocidad del viento y la pendiente que no mostraron asociaciones significativas. Por otro lado, con el modelo multivariable, seleccionaron cinco variables (LST, convexidad, elevación, aspecto y longitud del flujo de pendiente ascendente) como las más importantes y descubrieron que la LST y la convexidad tenían una asociación negativa con la ocurrencia de heladas, mientras que la elevación y la longitud del flujo de pendiente ascendente tenían una asociación positiva. Por otro lado, se desarrolló una ecuación de regresión lógica que utiliza esas variables para predecir la probabilidad de ocurrencia de heladas cuyo modelo resultante tuvo un buen ajuste y buena capacidad predictiva. En cuanto a la curva de ROC del modelo univariable fue de 0,69, mientras que para el modelo multivariable fue de 0,88 mostrando así un mejor rendimiento. Gracias a esto se pudo obtener una CCR del 81,57 % utilizando el umbral de corte de probabilidad de 0,5. Además, se probó la sensibilidad del modelo evaluando el CCR en diferentes umbrales de corte y se observó que los falsos negativos aumentan a medida que se incrementa el dicho umbral, mientras que los falsos positivos disminuyen. De esta forma, el modelo construido pudo identificar las zonas de alta susceptibilidad a las heladas mediante un umbral basado en la probabilidad del modelo logístico, lo que fue particularmente útil para gestionar los esfuerzos de mitigación de daños por las heladas. A su vez, se pudo ajustar el modelo utilizando la temperatura cercana a la superficie o datos de LST pronosticados en lugar de LST derivados, permitiendo así la implementación de un sistema de alerta temprana de heladas en la región.

2.5.6. Trabajo presentado por Gobbett et al. [9]

En este trabajo se analiza la necesidad de comprender las heladas y su impacto en la agricultura, horticultura y viticultura ya que es crucial debido al daño potencial a los cultivos. También se remarca que el cambio climático afecta la viticultura, y que los modelos climáticos existentes no pueden capturar las interacciones a escala fina que influyen en las heladas. Plantean que es necesario tomar decisiones estratégicas basadas en el riesgo de heladas, y que el cambio climático hace que se requiera un mejor entendimiento de las mismas para tomar decisiones mas informadas. El objetivo de este trabajo es comprender las heladas en terrenos variables y evaluar los posibles cambios en el uso de la tierra para el cultivo de la vid en escenarios climáticos futuros.

Los datos utilizados abarcan un área de 41.600 hectáreas en el valle de Yarra, una región vitivinícola en Victoria, Australia. De esta área se obtuvieron datos locales de una estación meteorológica entre los años 1965 y 2017. También se incluyeron datos de las estaciones meteorológicas de BoM³³ y de las estaciones meteorológicas de los viñedos. A su vez se indica que existe una “línea de heladas” de unos 90 metros de elevación, según productores y agrónomos, en la cual las heladas son particularmente peligrosas si ocurren por debajo de esta línea.

³³Australian Bureau of Meteorology <http://www.bom.gov.au/>

Para el análisis se empleó el método de regresión adaptativa multivariante (MARS) [35]³⁴ para modelar la temperatura mínima diaria en el valle de Yarra. Se utilizaron varias variables predictoras, incluida la elevación del terreno o datos de temperatura nocturna MODIS LST³⁵. Se generaron, a su vez, conjuntos de datos de escenarios climáticos diarios para los años 2030 y 2050 utilizando diferentes modelos de cambio climático. Estos incluyeron un modelo de elevación derivado de SRTM para representar la topografía del suelo y predecir la ocurrencia de heladas. Se utilizaron también varios índices topográficos secundarios y datos climáticos para capturar los factores que influyen en las heladas. No obstante, debido a la limitada disponibilidad de datos meteorológicos, combinaron registros de temperatura mínima de diferentes estaciones para calcular una compensación. Para ello usaron el generador de escenarios OzClim³⁶ para obtener escenarios climáticos futuros basados en diferentes modelos climáticos globales y proyecciones de emisiones de gases de efecto invernadero.

El análisis mostró algunos datos interesantes como que la probabilidad de que haya días con temperaturas por debajo de 2°C en agosto es del 50 %, con un 22 % de probabilidad de que haya más de 3 días; en septiembre hay un 28 % de probabilidad de al menos un día con temperaturas por debajo de 2°C y un 7 % de probabilidad de más de 2 días con estas temperaturas, etc. Sin embargo, no se detectaron cambios significativos en las tendencias de ocurrencia de heladas en agosto, septiembre u octubre para el período de 1965 a 2017. Se utilizó, también, un modelo de referencia que incluyó tres variables predictoras: T_SCORESBY (que representa la temperatura de las estaciones meteorológicas de BoM), DOY (día del año) y ELEV (variable de elevación). Este modelo se aplicó a elevaciones por debajo de los 300 m, que abarcan la mayoría de las áreas de cultivo de vid. Se hizo uso de un modelo para predecir las temperaturas mínimas (Tmin) diarias utilizando datos de MODIS LST para los meses de agosto, septiembre y octubre en el período de 1975 a 2004. Luego se realizó un ajuste entre los valores de MODIS LST y los datos de Tmin, obteniendo un ajuste promedio de 1,93°C y un error cuadrático medio de 4,1°C. También seleccionaron dos modelos climáticos para representar la incertidumbre y observaron diferencias en las temperaturas mínimas proyectadas para la región. Aunque los autores esperaban un aumento general de las temperaturas mínimas, observaron un aumento en la ocurrencia de heladas en algunas áreas, lo que va en contra de las tendencias de temperaturas mínimas proyectadas.

Tras los experimentos y a pesar de que el modelo tuvo limitaciones, se encontró que la altitud y la época del año eran factores importantes. Se proyectó una disminución en las heladas bajo escenarios climáticos futuros, lo que sugiere la posibilidad de expandir el cultivo de vid en áreas de menor elevación. Sin embargo, se menciona que existen incertidumbres en las predicciones climáticas y que otros factores como la fenología de la vid y los cambios en los patrones de precipitación también pueden afectar los sistemas agrícolas. Se destaca la importancia de realizar un modelado detallado y considerar tendencias históricas al planificar para el cambio climático.

2.5.7. Trabajo presentado por Diedrichs et al. [10]

Este trabajo se centra en Mendoza, Argentina, donde las heladas causan una gran pérdida en la producción y afectan miles de hectáreas de viñedos. A su vez se indica que esta región es una de las más vulnerables debido al clima extremo y la variación de las temperaturas, y es por esta razón que es fundamental predecir estos eventos con precisión para evitar pérdidas económicas. Se resalta la importancia de la predicción precisa con anticipación para permitir a los agricultores tomar medidas oportunas y mitigar los efectos de las heladas. El objetivo de este estudio es

³⁴Multivariate Adaptive Regression Splines (MARS) es un método estadístico y de aprendizaje automático utilizado para modelar relaciones complejas entre variables de entrada y una variable de respuesta.

³⁵<https://modis.gsfc.nasa.gov/data/dataproduct/mod11.php>

³⁶OzClim es un sistema de información climática para Australia desarrollado por el CSIRO que proporciona datos climáticos históricos y proyecciones climáticas. <https://www.vegetableclimate.com/tools/forecastingweathertools/ozclim/>

predecir la temperatura mínima del día siguiente utilizando información de días previos. De esta forma, los autores proponen un sistema basado en IoT para predecir las heladas, utilizando algoritmos de ML como SB y Random Forest[22](RF). El sistema consta de tres etapas integradas. En la primera etapa, se utilizan estaciones meteorológicas para recopilar datos históricos y generar nuevos datos para la mejora continua del modelo. En la segunda etapa, se utiliza un motor de predicción entrenado con los datos recopilados de las estaciones meteorológicas. Este motor de predicción utiliza técnicas y resultados para realizar las predicciones. En la tercera etapa, se utiliza un módulo de previsión de heladas basado en el modelo obtenido. Este módulo obtiene datos de una red de sensores basada en IoT diferente a las estaciones meteorológicas. Cabe destacar que este artículo se centra en la segunda etapa del trabajo realizado.

También se hace mención de diferentes métodos utilizados en la predicción de heladas, cómo métodos empíricos basados en fórmulas algebraicas o simulaciones numéricas para predecir el comportamiento del clima. Estos modelos requieren medidas y parámetros específicos que no siempre están disponibles para los productores.

El conjunto de datos utilizado fue proporcionado por la Dirección de Agricultura y Contingencias Climáticas³⁷ (DACC) de Mendoza, Argentina. Los datos provienen de cinco estaciones meteorológicas ubicadas en la provincia de Mendoza, y se registraron mediciones de temperatura y humedad relativa desde 2001 hasta 2016. Para cumplir con el objetivo propuesto, se transformó el conjunto de datos para que incluya variables de hasta cuatro días anteriores. Cada punto de datos etiquetado contiene las variables correspondientes a los días anteriores, así como la temperatura mínima del día siguiente en la ubicación de la estación (para el conjunto de entrenamiento). Fueron considerados dos casos: (i) en el que sólo se utilizaron las variables de la estación en cuestión (configuración local), y (ii) en el que se incluyeron variables de todas las demás estaciones (configuración global). Además, se discretizó la variable objetivo (temperatura mínima) en dos clases: helada o no helada, definiendo una helada como una temperatura por debajo de 0°C.

Luego, se aplicaron diferentes técnicas de ML como redes neuronales, regresión lineal, regresión lógica, RF y C5.0 [22], etc. Entre las variables utilizadas se encuentran la temperatura, humedad relativa y velocidad del viento.

En cuanto a los modelos de regresión, se utilizaron SB y RF. Se dividió el conjunto de datos en conjuntos de entrenamiento y prueba para entrenar los modelos. El conjunto de entrenamiento se utilizó para ajustar los parámetros del modelo, mientras que el conjunto de prueba se utilizó para evaluar el rendimiento de los mismos. Se utilizó una división del 68 % en la primera parte del conjunto de datos para la fase de entrenamiento y el restante 32 % para las pruebas. Dado que había escasez de eventos de heladas, se evaluaron conjuntos de datos con un número aumentado de estos eventos utilizando la metodología de remuestreo SMOTE[22]. Este método involucra un sobremuestreo de la clase minoritaria y un submuestreo de la clase mayoritaria para equilibrar el conjunto de datos. Se utilizó un sobremuestreo de tres veces de la clase minoritaria para triplicar el número de heladas. La selección de los valores óptimos de los parámetros se realizó mediante la validación cruzada de series de tiempo. Se utilizó una ventana de tamaño 300 y un horizonte de 100 para el procedimiento de validación cruzada de series de tiempo.

Los resultados mostraron que la incorporación de información de estaciones cercanas mejoró el rendimiento de los modelos de regresión demostrando el mejor desempeño en términos de errores. Tanto para configuraciones locales como para la configuración total, los errores fueron inferiores a 3°C, lo cual es significativo considerando la variabilidad térmica en la región de estudio. En cuanto a los modelos de clasificación, se encontró que Random Forest y regresión logística superaron a otros algoritmos en términos de puntaje F1[22], que combina precisión y sensibilidad. Sin embargo, se observó que el uso de la técnica de sobremuestreo SMOTE aumentó la sensibilidad pero redujo la precisión en los modelos de clasificación. Estos resultados variaron entre las diferentes estaciones debido a las distintas zonas microclimáticas en las que se encon-

³⁷<https://www.mendoza.gov.ar/contingencias/>

traban ubicadas. En conclusión, se sugiere que una combinación de configuraciones y técnicas de sobremuestreo como SMOTE podría ser beneficiosa para mejorar el rendimiento de los modelos de pronóstico ajustados a las condiciones específicas del estudio.

2.5.8. Trabajo presentado por Talsma et al. [36]

Este trabajo plantea la necesidad urgente de anticiparse y mitigar los impactos negativos del clima en la agricultura, un sector esencial para la seguridad alimentaria y la economía global. Los autores exponen a las heladas como un fenómeno climático particularmente perjudicial, ya que pueden causar daños significativos en los cultivos y afectar la producción agrícola. Ante este desafío, los objetivos principales de la investigación se centran en evaluar y mejorar la capacidad predictiva de los modelos de aprendizaje automático (ML) para la temperatura, así como en comparar diferentes enfoques de modelado y explorar la viabilidad de la transferencia de conocimientos entre ubicaciones geográficas.

Para abordar estos objetivos, se recurrió a datos recopilados de dos estaciones meteorológicas ubicadas en entornos geográficos y climáticos diversos: Alcalde y Freshies Farm, en Nuevo México. Estos conjuntos de datos comprenden una amplia gama de variables meteorológicas, incluida la temperatura del aire, la humedad relativa, la velocidad y dirección del viento, entre otras. La selección de estas estaciones permitió un análisis comparativo exhaustivo y proporcionó perspectivas valiosas sobre cómo los modelos de ML responden a diferentes condiciones ambientales.

El análisis se llevó a cabo mediante la implementación y comparación de varios modelos de ML, incluyendo Random Forest (RF), Convolutional Neural Network (CNN) y Fully Connected Deep Neural Network (DNN). Se aplicó una metodología rigurosa de validación cruzada para evaluar el rendimiento de los modelos en la predicción de la temperatura en diferentes horizontes temporales. Se utilizaron métricas estándar de evaluación de modelos, como Root Mean Square Error (RMSE), F1 score y coeficiente de determinación (R^2), para cuantificar la precisión y fiabilidad de las predicciones.

Los resultados revelaron que tanto los modelos CNN como DNN exhibieron un rendimiento ligeramente superior al modelo RF en términos de precisión de predicción de temperatura. Sin embargo, se observaron disparidades significativas en el rendimiento de los modelos entre las ubicaciones Alcalde y Freshies Farm, lo que sugiere que la transferencia de conocimientos entre ubicaciones puede ser un desafío debido a las diferencias en las características climáticas y geográficas.

Además, se identificaron áreas clave para futuras investigaciones, como la inclusión de datos topográficos y espaciales para mejorar la precisión de las predicciones, especialmente en áreas con topografía compleja como Freshies Farm. Se destacó la importancia de la cantidad y calidad de los datos en el desarrollo y mejora de los modelos de ML para la predicción meteorológica.

Este estudio resalta el potencial de los modelos de aprendizaje automático para mejorar la precisión de las predicciones de temperatura y mitigar los daños causados por las heladas en la agricultura. Se enfatizó la necesidad de continuar investigando y mejorando estos modelos, así como de explorar su integración en sistemas de alerta temprana para agricultores.

2.5.9. Resumen de trabajos relacionados

En la Tabla 2.1 presentamos un resumen de las propuestas descriptas previamente en relación a la predicción de heladas. Por ejemplo, podemos observar que la propuesta presentada en [4] tiene como objetivo desarrollar un sistema de predicción empírica para la protección contra heladas de frutas y hortalizas en el sur de la provincia de Santa Fe en Argentina. Para esto, se utilizaron las variables de temperatura del aire, temperatura de bulbo húmedo y seco, temperaturas mínimas de los días anteriores, velocidad del viento y nubosidad, y se analizaron con técnicas de series temporales y diferentes algoritmos de aprendizaje automático, como ANN, SB y k-NN.

Se encontró que la inclusión de información de estaciones cercanas mejoró el rendimiento de los modelos de regresión, mientras que los modelos de clasificación tuvieron buenos resultados en la predicción de heladas. Se sugirió la exploración de datos más recientes y variables predictoras adicionales para obtener información más precisa, así como el ajuste de los modelos para reducir el error. Se concluyó que SB superó a ANN y k-NN en la probabilidad de detección, pero tuvo una mayor probabilidad de falsa detección.

Propuesta	Objetivos	Fuentes/Periodo	Análisis	Resultado
Verdes et al.[4] 2000 (Rosario)	Desarrollar un sistema de predicción empírica para la protección contra heladas	2601 registros de una estación meteorológica en Zavalla entre 1973 y 1989	ANN SB k-NN	SB superó a ANN y k-NN en probabilidad de detección pero tuvo mayor probabilidad de falsa detección
Ding et al.[5] 2019 (Japón)	Construir un modelo de causalidad para la predicción de heladas	Sensores en un área local desde el 29/12/2019 al 31/01/2017	Correlación, SCM, SVR	La temperatura es el factor más importante. La humedad ayuda a emitir una alarma temprana (2-3 horas antes). La radiación mejora la sensibilidad de respuesta en un período corto.
Ding et al.[6] 2020 (Japón)	Desarrollar un modelo de causalidad para la predicción de heladas en un futuro razonable	Sensores en un área local desde el 29/12/2019 al 31/01/2017	SVM SCM	Los modelos con SVM y el uso de probabilidades de clasificación tuvieron buen rendimiento en predecir heladas.
Zhou et al.[7] 2022 (Australia)	Aumentar la frecuencia de predicción de heladas de una vez cada 12 a 24hs a predicciones minuto a minuto	Sensores de 30 estaciones meteorológicas desde 2016 a 2017	RNN, LSTM, GRU y ANN	LSTM tuvo mayor precisión con datos actuales y menor en datos futuros. ANN mostró precisión constante y rapidez.
Kotikot et al.[8] 2020 (Kenia)	Integrar las características locales de la superficie terrestre con las variables climáticas para mapear los puntos críticos de heladas.	282 observaciones durante época de heladas en los años 2011 y 2012. Radar Topográfico, Sensor MODIS y datos de NASA-LIS	Regresión lógica, Multicolinealidad	El modelo identificó áreas de alta susceptibilidad a las heladas utilizando un umbral basado en la probabilidad del modelo logístico. Fue útil para gestionar los esfuerzos de mitigación de daños por heladas.
Gobbett et al.[9] 2020 (Australia)	Generar escenarios climáticos futuros para predecir temperaturas mínimas nocturnas	Sensores estación meteorológica entre 1965 y 2017 y sensores remotos MODIS LST	Regresión lineal y no lineal	La altitud y la época del año afectan a la ocurrencia de heladas.
Diedrichs et al.[10] 2018 (Mendoza)	Predecir heladas hasta 24hs antes.	Estaciones meteorológicas entre 2001 y 2006	RF, SB, C5.0, ANN	Incorporar datos cercanos mejora el rendimiento. RF Y regresión logística fueron mejores clasificando.
Talsma et al.[36] 2023 (Alcalde)	Application of regression models to predict temperature and not just the occurrence of frost	10 years of historical data from the Natural Resource Conservation Service weather station	Random Forest (RF) Deep Neural Network (DNN) Convolution long-short term memory Neural Network (CNN).	CNN showed the better results and the use of soil temperature is a key parameter in longer term predictions application (>24 h)

Tabla 2.1: Cuadro comparativo de trabajos relacionados

A continuación, el trabajo presentado en [5] se enfocó en la predicción de heladas utilizando modelos de causalidad en lugar de simplemente asociaciones. Los autores buscaron identificar un modelo causal entre las heladas y determinados factores ambientales. Para esto, utilizaron varios conjuntos de datos que fueron variando para entrenamiento y representatividad. Los factores ambientales que analizaron fueron la temperatura del aire, la humedad relativa, la radiación neta y la velocidad del viento. Se construyeron modelos SRV para regresión y en sus estudios observaron que los datos de las heladas fueron simbólicos, mientras que los datos de las otras variables tuvieron un impacto continuo y acumulativo en las heladas.

Los mismos autores presentaron un segundo trabajo [6] en donde se enfocaron en el modelado causal para la predicción de heladas utilizando técnicas de ML. Introdujeron el concepto de causalidad de Granger y propusieron desarrollar métodos de modelado causal para la predicción de heladas. Utilizaron una función que relacionaba las variables ambientales (las mismas que en el artículo anterior) con las heladas y aplicaron un modelo SCM (structural causal model en ingles) para describir los mecanismos causales. Entrenaron modelos predictivos utilizando observaciones sincronizadas de las variables y realizaron predicciones de heladas considerando los valores futuros de las mismas. Además, sugirieron el uso de variables sustitutas y diferentes grupos de métodos de modelado. Utilizaron una clasificación, al que llamaron modelo etiquetado, para indicar la presencia o no de heladas. Concluyeron que los modelos con SVM y el uso explícito

de probabilidades de clasificación ofrecieron un rendimiento razonable en la predicción de heladas.

En el trabajo de Zhou et al. [7] (cuarta fila de la tabla) los autores utilizaron variables como temperatura del aire, punto de rocío, humedad relativa, velocidad del viento y dirección del viento extraídas de un conjunto de datos correspondiente a los meses de junio, julio y agosto del 2016 y 2017. Estos datos (de acceso público) fueron obtenidos a partir de sensores en 30 estaciones meteorológicas de Nueva Gales del Sur y el Territorio de la Capital Australiana. Utilizaron el conjunto de datos del 2016 para construir el modelo “actual” y el conjunto de datos del 2017 como pruebas finales, de tal modo que represente el “futuro” para las predicciones. El objetivo fue desarrollar un método basado en RNN para aumentar la frecuencia de predicción de eventos de heladas, pasando de una vez cada 12 a 24 horas a predicciones minuto a minuto. Para esto, se llevaron a cabo tres experimentos para evaluar la precisión y el tiempo de procesamiento de los modelos. En particular, se centraron en el uso de ANN y RNN, incluyendo variantes como LSTM y GRU, para mejorar la predicción de heladas en la agricultura a través de sistemas de Internet de las Cosas (IoT). Descubrieron que los modelos RNN, especialmente LSTM, fueron más precisos en conjuntos de datos actuales, pero menos precisos en conjuntos de datos futuros. La longitud de la secuencia de datos no afectó significativamente la precisión de los modelos RNN, pero aumentó el tiempo de entrenamiento e inferencia. Los modelos ANN mostraron una precisión constante y fueron más rápidos, lo que sugirió que son más adecuados a largo plazo.

Luego, en la quinta fila podemos observar el trabajo presentado en [8], el cual posee como particularidad el uso de la geografía de las zonas estudiadas; es decir, en conjunto con factores climáticos, utilizaron datos topográficos para caracterizar las heladas en las tierras altas de Kenia. Los datos topográficos fueron obtenidos de imágenes satelitales o radares topográficos y se seleccionaron cinco variables, LST, convexidad, elevación, aspecto y longitud del flujo de pendiente ascendente. En particular el objetivo del estudio fue identificar zonas de heladas en las plantaciones de té, y para esto realizaron experimentos de regresión lógica para estimar también la probabilidad de ocurrencia de heladas. De esta forma, utilizando imágenes de teledetección y desarrollando un modelo logístico, se integraron factores climáticos y topográficos para caracterizar las heladas en la región estudiada. El modelo identificó las variables más relevantes para predecir la ocurrencia de heladas logrando una alta precisión en la clasificación.

Luego, en el trabajo presentado en [9], se analizó el Valle de Yarra en Australia (con un área de 41.600 hectáreas) con datos de una estación meteorológica entre los años 1965 y 2017. Luego, se empleó un método de regresión adaptativa multivariante (MARS) para modelar la temperatura mínima diaria y predecir la ocurrencia de heladas en escenarios climáticos futuros. Se utilizaron diversas variables predictoras, como la elevación del terreno y datos de temperatura nocturna, y se generan conjuntos de datos de escenarios climáticos utilizando diferentes modelos climáticos globales. Aunque no se observaron cambios significativos en las tendencias de ocurrencia de heladas en el período analizado, se proyectó una disminución en las heladas bajo escenarios climáticos futuros, lo que podría permitir la expansión del cultivo de vid en áreas de menor elevación. No obstante, los autores mencionan la importancia de considerar otras variables y tendencias históricas, así como la incertidumbre asociada a las predicciones climáticas, al planificar para el cambio climático en la agricultura.

Continuando, el trabajo de Diedrichs et al. [10], abarca una región ubicada en Mendoza, Argentina, y aborda el problema de las heladas en los viñedos. Se propone un sistema basado en IoT y algoritmos de ML para predecir la temperatura mínima del día siguiente. El sistema consta de tres etapas integradas: la recopilación de datos históricos de estaciones meteorológicas, el uso de un motor de predicción entrenado con esos datos y un módulo de previsión de heladas basado en una red de sensores IoT. Se aplicaron diferentes técnicas de ML como redes neuronales, regresión lineal, regresión logística, Random Forest y C5.0, utilizando variables como temperatura, humedad relativa y velocidad del viento. Se construyó un conjunto de datos que incluyó variables de hasta cuatro días anteriores, y se discretizó la variable objetivo en dos clases: helada o no helada. Se evaluaron modelos de regresión y clasificación, y se encontró que Random Forest




Figura 2.2: Resumen de los trabajos relacionados.

y regresión logística tuvieron un mejor desempeño en términos de puntaje. La incorporación de información de estaciones cercanas mejoró el rendimiento de los modelos de regresión, y el uso de la técnica de sobremuestreo SMOTE aumentó la sensibilidad pero redujo la precisión en los modelos de clasificación. En el trabajo se concluyó que una combinación de configuraciones y técnicas de sobremuestreo puede mejorar el rendimiento de los modelos de pronóstico ajustados a las condiciones específicas del estudio.

Por último, el trabajo presentado en [36] se enfoca en mejorar la predicción de las heladas en la agricultura, crucial para la seguridad alimentaria y la economía global. Utilizando datos de dos estaciones meteorológicas diferentes, se compararon varios modelos ML para predecir la temperatura. Se encontró que los modelos CNN y DNN superaron ligeramente al RF, aunque la transferencia de conocimiento entre ubicaciones presentó desafíos debido a disparidades en los datos. Se destacó la importancia de la cantidad y calidad de los datos, sugiriendo que la inclusión de datos topográficos y espaciales podría mejorar la precisión de las predicciones, especialmente en áreas con topografía compleja. Este estudio destaca el potencial de los modelos de ML para mitigar riesgos climáticos en la agricultura y sugiere áreas clave para futuras investigaciones.

Para un análisis general, en la Figura 2.2 mostramos un resumen de las fuentes de datos utilizados (satélites, estaciones meteorológicas y geográficos), las formas de extracción (tiempo real y/o en lotes), las variables utilizadas (como una taxonomía de factores), y las técnicas de análisis aplicadas en las propuestas analizadas.

Como podemos observar, se han utilizado diversas técnicas y métodos para abordar el desafío de la predicción de heladas. Algunas de las técnicas más utilizadas incluyen clasificación y regresión, así como análisis de series temporales. En cuanto a la clasificación, los métodos más utilizados son las redes neuronales artificiales y las redes bayesianas. En cuanto a la regresión, se destaca el uso de la regresión lineal. También es importante destacar el proceso de preprocesamiento de datos realizado en estos trabajos y la consideración del concepto de “futuro” al evaluar los datos. La importancia del concepto de futuro radica en la necesidad de proporcionar pronósticos precisos y oportunos para proteger los cultivos y tomar decisiones informadas en la

agricultura. Estos estudios también destacan la relevancia de considerar variables climáticas, topográficas y geoespaciales en la predicción de heladas, lo que demuestra la diversidad de enfoques utilizados para abordar este problema en diferentes contextos geográficos y climáticos.

2.6. Trabajos previos dentro del Proyecto de Investigación

El trabajo de esta tesis se enmarca dentro Proyecto de Investigación denominado *Modelado de Variedad en Sistemas de Big Data* (ORD 0084/22). En el mismo, se han realizado varios avances dentro del proceso de desarrollo de big data [12, 13, 14, 37]. En particular se ha propuesto el concepto de *variedad* como eje fundamental para proveer flexibilidad y adaptabilidad en la generación de Sistemas de Big Data (o casos de aplicación particulares). Al mismo tiempo, para dar soporte a este nuevo concepto se han definido dos enfoques (Top-Down y Bottom-up) para la identificación de la variedad como soporte a las actividades del ciclo de vida de un proceso de big data tradicional. En la Figura 2.3³⁸ podemos observar estos dos enfoques junto con las actividades que realiza cada uno y la forma en que la identificación de la variedad influye en el ciclo de vida. En las subsecciones siguientes describimos en mas detalle los pasos y actividades incluidos en los dos enfoques.




Figura 2.3: Enfoques Top-Down y Bottom-up para el desarrollo de SBD considerando variedad.

³⁸La Figura 2.3 se repite de la Figura 1.1 por razones de legibilidad.

2.6.1. El concepto de variedad

La variedad se define como la diversidad o heterogeneidad que puede existir en los datos y al mismo tiempo influir en las decisiones y procesos en el desarrollo de SBDs. En la Figura 2.3 podemos observar la variedad en azul en la parte izquierda definiendo 4 posibles tipos:

- *La variedad en las fuentes* de datos se refiere a tres tipos. El primero incluye datos generados automáticamente por sensores, cámaras de seguridad, vehículos autónomos, entre otros, especialmente impulsados por el IoT. Estas fuentes permiten a las organizaciones analizar patrones de comportamiento, identificar fallas y brechas de seguridad. El segundo tipo abarca datos generados por interacciones humanas con computadoras, como correos electrónicos, subidas de archivos, búsquedas en internet, entre otros. El tercer tipo engloba los datos recopilados por procesos empresariales, que tienen una estructura formal y se generan a través de transacciones, incluyendo metadatos sobre las tablas y relaciones consultadas. Trabajar con fuentes de datos heterogéneas añade complejidad, pero la idea es combinarlas para obtener una visión completa de lo que sucede en el dominio y llegar a conclusiones integrales.
- *La variedad de contenido* de los datos hace referencia a los distintos tipos y formatos que pueden tener y los clasifica en tres categorías: estructurados, semi-estructurados y no estructurados. Los datos estructurados son extraídos, en general, de bases de datos relacionales y tienen formatos bien definidos, lo que facilita su manipulación y análisis. Los datos semi-estructurados no siguen una estructura tabular restrictiva, pero tienen etiquetas para identificar atributos. Los datos no estructurados carecen de estructura y pueden ser archivos de texto plano, logs, datos de redes sociales, entre otros. Combinar estos tres tipos de datos, incluyendo comentarios de usuarios, opiniones, patrones de actividad, historiales de compras, entre otros, permite obtener conocimiento valioso.
- *La variedad de procesos* tiene varios enfoques. En primer lugar, se encuentra el procesamiento por lotes, que implica el procesamiento fuera de línea (offline) y paralelo de grandes volúmenes de datos. En segundo lugar, tenemos al procesamiento interactivo, que permite la interacción en tiempo real con los datos y usuarios. En tercer lugar, está el procesamiento en tiempo real, que implica el procesamiento continuo de los flujos de datos a medida que ingresan al sistema. Por último, destaca el procesamiento de grafos, que involucra la representación de objetos individuales y sus relaciones a través de nodos y arcos, respectivamente, lo que genera grafos densos que relacionan diferentes conjuntos de datos.
- *La variedad de contexto* es la diversidad de entornos en los cuales se llevan a cabo observaciones o análisis, lo que permite discernir entre distintos casos o agruparlos si comparten similitudes. Es decir, aunque se puedan desarrollar análisis previamente realizados en un dominio específico, su eficacia y validez pueden variar considerablemente según el contexto en el cual se aplican. Por lo tanto, la contextualización adecuada es esencial para garantizar la fiabilidad y la aplicabilidad de los resultados obtenidos. Es importante resaltar que la variedad de contexto no solo implica la diversidad de entornos físicos, sino también la inclusión de factores semánticos y situacionales que influyen en la interpretación de los datos.

2.6.2. El Proceso de Big Data

En el centro abajo de la Figura 2.3 podemos observar el proceso de big data (en azul). Como vemos las actividades no difieren en general de las descritas en la Sección 2.3, pero en este contexto, las mismas se ven influenciadas de acuerdo a la variedad que puede ser definida dentro de ellas. Es decir, con la inclusión del concepto de *variedad*, estas actividades se ven ahora influenciadas en las decisiones de diseño que se llevan a cabo durante su realización. Relacionando

las actividades con las variedades definidas en la subsección anterior, ahora las actividades se definen como:

- *Colección*: se encarga de la identificación y recopilación de datos que son relevantes para el análisis. Esta actividad se ve influenciada por la variedad de las fuentes ya que permite detectar diferencias en las estructuras que traen los datos a utilizar, las diferentes técnicas de adquisición, los dispositivos o software de donde provienen, etc.
- *Preparación*: se encarga del procesamiento y la organización de los datos recopilados durante la fase de colección. Esta actividad se ve influenciada por la variedad de contenido ya que las transformaciones se adaptan a las variables específicas del dominio, asegurando que los datos estén listos para el análisis. Puede, además, verse influenciada por la variedad de contexto ya que puede afectar las decisiones sobre cómo transformar y limpiar los datos, adaptándolos a condiciones específicas antes de la actividad analítica.
- *Analítica*: se encarga de la aplicación de técnicas analíticas para descubrir patrones o tendencias en los datos procesados. Esta actividad se ve influenciada por la variedad de procesos ya que se seleccionan y aplican métodos analíticos específicos del dominio según las particularidades del análisis. Además, se ve influida por la variedad de contexto al introducir requisitos específicos, modificar la interpretación de resultados y exigir adaptabilidad a cambios, asegurando así que las técnicas analíticas sean pertinentes y efectivas en situaciones particulares.
- *Visualización*: se encarga de presentar de manera gráfica y comprensible los resultados obtenidos del análisis. Esta actividad se ve influenciada por la variedad de contenido ya que afecta la forma en que se representan visualmente los datos para satisfacer las necesidades y preferencias específicas del dominio.
- *Acceso*: se encarga de facilitar la interacción de los usuarios finales con los resultados del análisis. Esta actividad se ve influenciada por la variedad de contexto ya que la personalización del acceso se adapta a las especificidades del dominio, considerando cómo los usuarios finales interactúan según sus roles y necesidades específicas.

2.6.3. Enfoques Top-Down y Bottom-up para identificar la variedad

Como mencionamos previamente, el proceso de identificación de variedades en el desarrollo de SBDs [12] se define mediante dos enfoques principales: el enfoque descendente o *Top-Bottom* (T-VIP) y el enfoque ascendente o *Bottom-up* (B-VIP). El primero, el cual podemos observar en el lado izquierdo de la Figura 2.3, (1) comienza con la formulación de hipótesis por parte de un experto en el dominio (¿qué hipótesis tengo?), basadas en su conocimiento previo, lo que guía el análisis posterior de datos para validar esas suposiciones. Luego, (2) los analistas comienzan a realizar las actividades del proceso de big data (3) para analizar los datos de acuerdo a las hipótesis definidas (¿los datos las corroboran?). Más tarde, estos resultados son devueltos para validar dichas hipótesis (4), posiblemente visualizando los resultados de diferentes maneras; y permitir su reformulación o la finalización de las actividades del proceso, alternativamente (5). Como resultado de este enfoque, se generan casos de dominio específicos que guardan las variaciones identificadas, los cuales pueden ser reutilizados en instancias futuras; promoviendo así la eficiencia y la consistencia en futuros análisis dentro del mismo dominio.

En contraste, el enfoque B-VIP, en el lado derecho de la Figura 2.3, se inicia (1) con la decisión de realizar un estudio exploratorio sobre el problema de dominio (¿qué dicen los datos?). Luego, (2) Los analistas se embarcan en el análisis de datos sin hipótesis predefinidas, permitiendo que los patrones y tendencias emerjan de manera natural a través de un proceso de big data (3). Los resultados obtenidos durante este estudio son devueltos (4) y se someten a un proceso de validación y discusión con expertos del dominio. Alternativamente, se puede

finalizar el proceso o reformular la búsqueda (5). La documentación en este enfoque se centra en la variedad emergente durante el estudio exploratorio. Los casos de dominio instanciados durante dicho proceso se almacenan para ser reutilizados en consultas y análisis futuros, contribuyendo así a la acumulación de conocimiento y la eficiencia en la toma de decisiones.

Ambos enfoques, a través de la definición de la variedad en cada etapa del proceso de big data, no solo permiten flexibilidad en cuanto las características distintivas de cada dominio, sino que también fomentan la reutilización de conocimientos y casos. De esta forma facilitan la gestión de la complejidad inherente de los datos y mejoran la eficiencia y la efectividad de los análisis en contextos específicos [12, 14].

2.6.4. Herramienta para la Gestión de la Variedad basada en Contexto (CoVaMaT)

CoVaMaT (Context-based Variety Management Tool) [12] es un sistema diseñado para definir, consultar y documentar las variedades de un dominio que se generan y reutilizan en todo proceso B-VIP y/o T-VIP. Está dirigido principalmente a ingenieros de software, desarrolladores, y científicos de datos. En la Figura 2.3 podemos observar a CoVaMaT en la parte derecha de la misma cercana justamente a las actividades del proceso de big data. Esto es así justamente porque durante ese proceso se crean o reutilizan activos del dominio junto con sus variedades.

En el contexto de CoVaMaT, se manejan conceptos clave como: *caso de dominio* que se refiere la implementación de un caso de aplicación en un dominio determinado, es decir es ejecutar todo el proceso de big data mediante alguno de los enfoques (T-VIP o B-VIP) propuestos; *activos de dominio* se refiere a toda la información generada en los casos de dominio y variedades definidas durante la ejecución de un caso de dominio particular, es decir, las variedades encontradas durante el desarrollo de un caso; *instanciación de caso* implica la recuperación de los activos de dominio generados para su instanciación en la creación de un caso de dominio particular, es decir la definición de las instancias específicas de las variedades almacenadas; y *caso reusable* que son casos de dominio ya instanciados que pueden ser utilizados nuevamente en futuros proyectos al construirse a partir de las variedades almacenadas.

Las tres funciones principales de CoVaMaT son:

- *F-1: Funcionalidad para documentar variedades*: Permite especificar la variedad de dominio de un caso como jerarquías de tipos de variedades. Estos tipos de variedades se van a identificar según se haga un T-VIP o B-VIP. Es en esta funcionalidad donde se crean los *activos de dominio* del caso siendo desarrollado y se comienza con la construcción de un *caso de dominio*. Esta función incluye un servicio (S-1: Servicio de documentación de variedad), un proceso (P-1: Documentar variedad de dominio) y un evento (E-1: Comienzo de búsqueda de variedad).
- *F-2: Funcionalidad para instanciar casos*: Facilita la creación de *casos de dominio* mediante la selección (instanciación) de las variedades específicas previamente definidas (como *activos de dominio*). Es en esta funcionalidad donde se crean las *instanciaciones de casos* y almacenan como nuevos *activos de dominio* instanciados. Puede completarse aquí el desarrollo de un *caso de dominio*. Esta función incluye un servicio (S-2: Servicio de instanciación de Caso), un proceso (P-2: Definir caso) y un evento (E-2: Solicitud de uso de CoVaMaT (instanciación de caso)).
- *F-3: Funcionalidad para reutilización de casos*: Permite la reutilización de los *activos de dominio* y *casos de dominio* previamente creados. Los usuarios pueden realizar consultas para recuperar casos similares en un contexto específico. Esta función incluye un servicio (S-3: Servicio de consulta de activos de dominio) y dos procesos (P-3: Definir caso de reuso; P-4: Consultar activos de dominio en casos similares) y se activa cuando los usuarios requieren la reutilización de casos (E-3: Solicitud de reuso).

A continuación describimos los tres servicios fundamentales enumerados previamente que respaldan el proceso de big data centrado en la variedad y la reutilización de activos del dominio:

- *S-1: Servicio de documentación de variedad:* Este servicio se centra en la identificación y documentación de las diversas variedades presentes en el dominio. Involucra catalogar y comprender las variabilidades en las fuentes de datos, contenido, procesos y contexto. Este proceso es esencial para la adaptabilidad del análisis de big data a las particularidades del dominio. Además, facilita la comprensión de la variabilidad inherente al dominio, proporcionando una base sólida para las etapas subsiguientes del proceso de big data.
- *S-2: Servicio de Instanciación de Caso:* Este servicio se enfoca en la creación de casos específicos a través de la selección de variaciones en las distintas categorías identificadas durante la documentación de variedades. Cada ejecución de las actividades del proceso de big data constituye un caso que se documenta como activos del dominio. Esto permite la creación de activos de dominio específicos para escenarios particulares, facilitando la posterior reutilización y adaptación del conocimiento.
- *S-3: Servicio de consulta de activos de dominio:* Este servicio facilita la composición de consultas que recuperan casos ya instanciados en el repositorio y que comparten similitudes con las características seleccionadas. Proporciona una forma eficiente de analizar el trabajo previo bajo condiciones específicas y promueve la reutilización de casos en el mismo o en dominios similares. También, agiliza el proceso de análisis al permitir a los usuarios aprender de experiencias anteriores y aplicar conocimientos existentes en nuevos contextos.

A su vez, también detallamos los procesos definidos en CoVaMaT:

- *P-1: Documentar variedad en dominio:* implica documentar los tipos de variedad dentro de un dominio. Los tipos de variedades pueden ser jerarquías de tipos de variedades identificadas mediante análisis de dominio (T-VIP) o estudios exploratorios (B-VIP).
- *P-2: Definir caso:* consiste en definir casos de dominio específicos basados en la variedad documentada. Recupera las variedades documentadas de P-1 y las instancia para un caso de dominio específico. Básicamente, selecciona las instancias de variedad relevantes para crear un caso específico que se implementará.
- *P-3: Definir caso reusable:* permite la reutilización de activos de dominio (creados en P-1) y/o casos de dominio (creados en P-2) para contextos similares. Las partes interesadas pueden consultar estos activos para encontrar y reutilizar casos que coincidan con un contexto o requisito particular.
- *P-4: Consultar activos de dominio en casos similares:* es parte del proceso de definición de casos reusables (P-3). Implica consultar los activos del dominio y/o casos de dominio para encontrar casos similares en función del contexto definido por las partes interesadas. Este proceso ayuda a identificar y seleccionar casos para su reutilización.

A su vez, para la documentación de la variedad utilizando los 4 procesos previos, se incluye un artefacto de software llamado *datasheet*. El mismo fue introducido en trabajos anteriores [38, 39], y contiene un modelo de variabilidad usando una combinación de la notación de UML y OVM (Modelo de Variabilidad Ortogonal) [40]. Este artefacto se utiliza para modelar funcionalidades de diseño en una línea de productos de software. Sin embargo, aquí se define una vista simplificada de las datasheets modelando solo puntos de variación y variantes (opcionales)³⁹. De esta forma,

³⁹Un punto de variación se usa para especificar que una variable puede cambiar, y las variantes son las variaciones concretas que pueden/deben seleccionarse para cada punto de variación

la variedad se almacena en datasheets y el resultado del proceso es un *activo de dominio* que contiene la definición de las variedades para el caso de dominio que se está implementando.

En resumen, CoVaMaT es un sistema que ayuda en la identificación, creación y documentación de variedades en un dominio. Su funcionamiento es esencial para facilitar la gestión y el análisis de datos en todo desarrollo de SBDs que consideren las variedades de los dominios analizados.

2.7. Resumen del capítulo

En este capítulo hemos proporcionado una visión integral de los Sistemas de Big Data y su aplicación en el contexto de la agrometeorología. Se exploraron los conceptos clave de Big Data, los estándares asociados y el ciclo de vida de estos datos. Además, se destacó el papel crucial de los SBDs en la toma de decisiones y se revisaron investigaciones previas relevantes en el ámbito de la agrometeorología. Este capítulo sienta las bases para comprender cómo los SBDs pueden mejorar la gestión de la agricultura en entornos agrometeorológicos.

En el próximo capítulo, describimos un proceso de Big Data con un enfoque Top-Down, que implica un abordaje metodológico, detallando cada uno de los pasos y componentes esenciales del proceso. Este proceso estará ilustrado a través del desarrollo de dos casos de dominio centrados en la predicción de heladas tempranas en el Alto Valle de Río Negro y Neuquén.

Capítulo 3

Aplicación del Enfoque Top-Down para la creación de Casos de Dominio

En este capítulo describimos la aplicación del enfoque top-down explicado en el capítulo anterior para la creación de dos casos de dominio dentro de la región del Alto Valle de Río Negro y Neuquén. Los casos se enmarcan dentro del dominio de la agrometeorología.

3.1. Enfoque Top-Down para el desarrollo de casos de dominio

En la Figura 3.1 mostramos el enfoque top-down que involucra los 5 pasos descritos en el capítulo anterior (Figura 2.3) ahora instanciada para contemplar dos casos de dominio diferentes. Estos casos describen una implementación de una situación de *variedad de contexto*, en la que los procesos y activos creados para el primer caso se documentan y se reutilizan en el segundo. Podemos observar en la figura que las tres primeras variedades se mantienen iguales, y luego la última (en naranja) es la que incluye la variación en cada caso de dominio. Por lo tanto, el *Caso de Dominio 1 - Villa Regina* crea *activos del dominio* y *casos del dominio* en el contexto del análisis del área abarcada por la Estación Meteorológica Villa Regina. Luego, el *Caso de Dominio 2 - Guerrico*, dentro del contexto de análisis de una nueva estación meteorológica que abarca otra zona denominada Guerrico, reutiliza los activos previos ya generados en el caso anterior y/o eventualmente crea otros nuevos. En la Figura 3.2 podemos observar las dos estaciones meteorológicas y el área que abarca cada una, enmarcada en azul.

A continuación describimos cada uno de los 5 pasos del enfoque top-down junto con las actividades que se realizan para ambos casos de dominio.

3.1.1. Caso de Dominio 1: Villa Regina

Este caso de dominio fue el primero que realizamos por lo que generó la construcción inicial de las hipótesis, su procesamiento y verificación. Como el dominio de cobertura es agrometeorología, creamos inicialmente el activo de dominio en CoVaMaT, al que llamamos *activo de dominio de agrometeorología*. A su vez, como definimos una situación de *variedad de contexto*, creamos dicha variedad en CoVaMaT para que pueda ser reusada en futuros casos, si es posible. Así, utilizamos la funcionalidad F-1 (*Funcionalidad para documentar variedades*) con su proceso P-1 (*Documentar variedad de dominio*) para documentar la variedad de contexto dentro del activo de dominio creado previamente. En la Figura 3.3 mostramos este proceso P-1 con sus 4 actividades donde se identifica la variedad, determina su tipo, ingresa un datasheet y se almacena. En la figura observamos el *activo de dominio de agrometeorología* en el cual se define una *variedad de contexto* mediante un datasheet que posee un nuevo artefacto denominado *Área Estación Meteorológica Villa Regina*.

A continuación describimos el trabajo realizado.




Figura 3.1: Enfoque Top-Down aplicado a dos casos de dominio



Figura 3.2: Estaciones meteorológicas junto con el área que abarcan

Paso 1: Definición de Hipótesis

Para la definición de las hipótesis en este caso de dominio nos hemos basado en el análisis realizado de los trabajos relacionados de la literatura y la información y conocimiento brindada por los usuarios expertos. En primer lugar los expertos nos plantearon el requerimiento de conocer si las variables relacionadas con el viento o la lluvia tienen influencia en la ocurrencia de heladas. Para ellos, es sabido que la temperatura influencia directamente sobre las heladas, pero se preguntaban si éstos eran los únicos factores. Particularmente querían conocer si había relación del viento y la lluvia con respecto a las mismas. Por ejemplo, ellos podrían afirmar, "si llueve y/o si hay viento fuerte no hay heladas", sin embargo, tenían dudas sobre esta relación y su comportamiento real. Algo similar está planteado en los trabajos de Kotikot et al. [8] y Ding et al. [5] donde analizaron estas variables con respecto a las heladas y llegaron a relaciones débiles o no concluyentes por sí solas.

De esta forma, planteamos la primera hipótesis como:

- **Hipótesis 1 (H1):** ¿Las variables climáticas relacionadas con el viento o lluvia




Figura 3.3: Proceso P-1 donde documentamos la variedad de contexto como un nuevo *activo de dominio de agrometeorología* en CoVaMaT

tienen influencia en la ocurrencia de heladas?

Luego, también era importante conocer el comportamiento de las variables climáticas en momentos previos (minutos, horas o incluso semanas antes) a eventos de heladas, de forma tal de conocer el grado de influencia de las mismas. Así, planteamos la segunda hipótesis:

- **Hipótesis 2 (H2): ¿Hay factores climáticos con mayor influencia en la presencia de heladas en momentos previos a su ocurrencia?**

Al mismo tiempo, como requerimiento de los usuarios expertos, se quería conocer si era posible predecir la presencia o no de heladas en horas posteriores. Para explorar este requerimiento, formulamos dos nuevas hipótesis. La primera contiene el conjunto de variables original como predictoras del modelo a construir y se define como:

- **Hipótesis 3 (H3): ¿Se puede lograr un modelo predictivo eficiente utilizando las variables climáticas originales?**

Luego, la última hipótesis se basó en la importancia de evaluar el modelo predictivo anterior simplificando la complejidad del mismo al descartar variables que posean menos relevancia. Así la hipótesis postula:

- **Hipótesis 4 (H4): ¿Se puede ahora lograr un modelo predictivo eficiente utilizando sólo un subconjunto de variables?**

En esta hipótesis se debería verificar si esta simplificación tiene el potencial de mejorar la eficiencia computacional del modelo y seguir brindando buenas predicciones.

De esta forma en la Figura 3.1 podemos observar las cuatro hipótesis generadas, las cuales debe ser luego procesadas en los pasos 2 y 3.

Pasos 2 y 3: Procesamiento de las Hipótesis

En los pasos 2 y 3 tomamos las hipótesis definidas (como analistas de datos) y llevamos a cabo todas las actividades involucradas. Para describir el trabajo realizado, nos centramos en las actividades del proceso de big data (en azul en la Figura 3.1) junto con la definición de las variedades que involucra cada una y el almacenamiento en la base de conocimiento CoVaMaT (en verde).

Proceso de Big Data: Actividad Colección




Figura 3.4: Proceso P-1 donde documentamos la variedad de las fuentes dentro del *activo de dominio de agrometeorología* en CoVaMaT

El conjunto de datos utilizado se obtuvo de la estación meteorológica Villa Regina, ubicada justamente en la misma ciudad. La estación registra datos en intervalos de diez (10) minutos y en este caso tomamos el conjunto desde el 5 de julio de 2009 a las 16:20 hs hasta el 17 de septiembre de 2019 a las 7:20 hs, lo que equivale a un total de 511.263 registros de datos semi estructurados con formato de texto. Este conjunto de datos posee 33 variables, con información de fecha, hora, temperatura promedio, temperatura máxima, temperatura mínima, humedad exterior, velocidad del viento, dirección del viento, entre otras. Sin embargo, veremos en la actividad siguiente, que no utilizamos las 33 variables ya que se eliminaron aquellas que no se correspondían con el procesamiento de las hipótesis.

Al mismo tiempo, en cuanto a la variedad, en la base de conocimiento CoVaMaT volvimos a utilizar el proceso P-1 (*Documentar variedad de dominio*) para documentar la variedad de las fuentes dentro del *activo de dominio de agrometeorología* creado previamente. En este caso, como podemos observar en la Figura 3.4, el proceso P-1 crea una nueva fuente de datos semi-estructurada proveniente de la estación meteorológica de Villa Regina.

Proceso de Big Data: Actividad Preparación

En esta actividad, y considerando las hipótesis definidas, se tomó la decisión de eliminar varias variables del conjunto de datos original. En muchos casos, estas variables eran valores derivados o internos que no aportaban información relevante y que los expertos y trabajos relacionados de la literatura no incluían como factores determinantes de las heladas. Así, eliminamos variables como: dirección del viento, temperatura interna, humedad interna, velocidad máxima del viento, dirección de la máxima velocidad del viento, entre otras. No obstante, algunas de las variables relacionadas con el viento y la lluvia se mantuvieron con el propósito de descartar cualquier posible influencia y validar la primera hipótesis ($H1$). Otras variables climáticas como las relacionadas con la radiación solar o la presión atmosférica fueron conservadas para validar la tercera hipótesis ($H3$).

Por otro lado, la variable temperatura promedio (*temp out*, que representa la temperatura promedio del registro) también se excluyó del conjunto de datos ya que el fenómeno de la helada comienza a manifestarse cuando las temperaturas descienden por debajo de los 0°C , por lo que la variable de interés principal en este estudio es la temperatura mínima. La Tabla 3.1 presenta el conjunto de 14 variables finales del conjunto de datos. En la misma podemos observar el nombre abreviado en inglés (como proviene de la fuente), su nombre traducido al español y el tipo.

Posteriormente, llevamos a cabo una tarea de estructuración y transformación de datos debido a que el conjunto original se encontraba en formato de texto¹. Después de las transformaciones, identificamos datos faltantes; que en este caso nos dio un total de 7.758 registros con valores va-

¹Para esto utilizamos la librería Pandas - <https://pandas.pydata.org/>

Variable	Nombre en español	Tipo
HiTemp	Temperatura Máxima	Numérico
LowTemp	Temperatura Mínima	Numérico
OutHum	Humedad Promedio	Numérico
DewPt	Punto de Rocío	Numérico
WindSpeed	Velocidad del viento	Numérico
WindRun	Aire desplazado por el viento	Numérico
WindChill	Sensación térmica	Numérico
Bar	Presión atmosférica	Numérico
Rain	Presencia de Lluvia	Categorico
RainRate	Promedio de lluvia	Numérico
SolarRad	Radiación solar	Numérico
SolarEnergy	Energía Solar	Numérico
Hi SolarRad	Máxima Radiación Solar	Numérico
ET	Evapotranspiración	Numérico

Tabla 3.1: Tabla descriptiva de las variables seleccionadas.

cíos para las variables *Temperatura Máxima*, *Temperatura Mínima*, *Humedad Promedio*, *Punto de Rocío* y *Sensación Térmica*. En lugar de optar por la eliminación de estos registros nulos, se decidió emplear la técnica KNNImputer² (ver Sección 2.3.3). Como el uso de esta técnica requiere la selección adecuada del número de vecinos (k), aplicamos la validación cruzada (cross-validation) utilizando el error cuadrático medio (MSE). Como resultado de este proceso, se determinó que el número óptimo de vecinos era igual a 1. Por ejemplo, en la Tabla 3.2(a)³ podemos observar que el valor nulo de las variables *Temperatura Máxima* (*HiTemp*), *Temperatura Mínima* (*LowTemp*), *Humedad Promedio* (*OutHum*), *Punto de Rocío* (*DewPt*) y *Sensación Térmica* (*WindChill*) fue reemplazado por el valor predicho por el KNNImputer, en la Tabla 3.2(b). Para cada valor *NaN*, el algoritmo seleccionó los datos con valores faltantes en el conjunto de datos, calculó la distancia entre cada dato y todos los demás en el conjunto de datos utilizando la distancia euclidiana, identificó el dato más cercano con el valor faltante en función de la distancia calculada, y utilizó el valor del vecino más cercano para imputar el valor faltante en el conjunto de datos original. Así por ejemplo podemos observar que el valor 10,6 de la fila 1 de la variable *Temperatura Máxima* (*HiTemp*) completado en la Tabla 3.2(b) proviene del valor correspondiente a la fila 10.539 (no mostrado) que, según el método, tenía la distancia más cercana al registro que se deseaba imputar. Este proceso se repitió para cada valor faltante en el conjunto de datos, reemplazándolo con el valor del vecino más cercano correspondiente. Al finalizar, el conjunto de datos poseía todos sus valores faltantes imputados. De esta forma, los 7.758 registros fueron adecuadamente completados, no existiendo luego valores nulos en el conjunto de datos. A este conjunto de datos lo llamamos *Conjunto de Datos Original Regina*.

Por otro lado, según los trabajos en la literatura, los modelos de clasificación tradicionales basados en datos estáticos no son adecuados para predecir eventos climáticos futuros, como las heladas. Para abordar este desafío y poder validar la segunda hipótesis (*H2*) fue necesario crear un nuevo conjunto de datos que posea una nueva variable continua representando la ocurrencia de heladas de un número específico de registros más adelante en el tiempo. Esta nueva variable, que llamamos *HeladaCont*, se calculó tomando el valor de la temperatura mínima de n registros futuros, donde n representa el número de registros a desplazarse hacia adelante. Por ejemplo, si queremos completar el valor con 1 hora en el futuro, el valor de n debería ser 6 ya que el

²Implementada por la librería scikit-learn <https://scikit-learn.org/>

³En todas las tablas y gráficos que se muestran en este capítulo utilizamos la notación numérica del sistema imperial, es decir los decimales se colocan con punto. Esto es así ya que desde las herramientas de software utilizadas, este es el sistema que está definido. En el texto utilizamos la notación decimal con coma.

	HiTemp	LowTemp	OutHum	DewPt.	WindChill
1	NaN	NaN	NaN	NaN	NaN
2	NaN	NaN	NaN	NaN	NaN
3	8.8	7.8	46.0	-2.6	8.0
4	9.3	8.9	48.0	-1.4	9.1
5	10.0	9.3	49.0	-0.5	9.7

(a) Antes de la imputación

	HiTemp	LowTemp	OutHum	DewPt.	WindChill
1	10.6	10.3	41.0	-2.3	7.6
2	10.1	9.7	44.0	-1.7	10.0
3	8.8	7.8	46.0	-2.6	8.0
4	9.3	8.9	48.0	-1.4	9.1
5	10.0	9.3	49.0	-0.5	9.7

(b) Después de la imputación

Tabla 3.2: Representación del conjunto de datos antes (a) y después (b) de la imputación de valores nulos.

	HiTemp	LowTemp	...	HeladaCont
1	13.1	12.9	...	9.7
2	13.1	12.9	...	12.9
3	13.2	12.9	...	13.1
4	13.2	12.9	...	12.9
5	13.4	13.1	...	12.9
6	13.4	13.1	...	10.3
7	10.1	9.7	...	9.7
8	13.4	12.9	...	7.8
9	13.4	13.1	...	8.9
10	13.2	12.9	...	9.3

Tabla 3.3: Ejemplo del nuevo *Conjunto de Datos Dinámico* (con la variable *HeladaCont*) con un $n = 6$

conjunto de datos tiene registros cada 10 minutos, por lo que 6 registros representarían una hora (60 minutos). Si quisiéramos hacerlo con un día, tomaríamos un $n = 138$. La Tabla 3.3 muestra como ejemplo un $n = 6$ donde el valor para *HeladaCont* en el registro 1 toma el valor de la *Temperatura Mínima (LowTemp)* del registro 7 (en violeta), el cual está 6 registros más adelante. Lo mismo para los registros 2 y 8 (en naranja), 3 y 9 (en rosa), etc.

El valor de n puede ser cambiado dinámicamente creando nuevos conjuntos de datos que se adapten a los requerimientos de los diferentes tipos de análisis que realizamos en las siguientes actividades del proceso de big data. Para nuestros análisis creamos 24 conjuntos de datos diferentes, donde cada uno reemplazó el valor de n en múltiplos de 6 hasta llegar a 138 (23 hs), es decir analizar desde la hora 0 a las 23 hs siguientes. Entonces, con un $n = 6$ tenemos una hora, con $n = 12$, 2 horas, y así sucesivamente, hasta un $n = 138$ para obtener 23 hs. La Tabla 3.4 muestra un ejemplo de cómo se va creando la variable para los diferentes valores de n . Se puede observar como en (a) el valor de *HeladaCont* del registro 1 se toma del valor de *Temperatura Mínima (LowTemp)* del registro 7, en color celeste; en (b), en color naranja, se puede ver como el valor de *HeladaCont* del registro 1 se toma del valor de *Temperatura Mínima (LowTemp)* del registro 13; y así sucesivamente hasta el $n = 138$. Cada uno de estos conjuntos de datos recibe el nombre de *Conjunto de Datos Dinámico Regina(n)*.

	LowTemp	HeladaCont		LowTemp	HeladaCont		LowTemp	HeladaCont
1	0.5	1.0	1	0.5	-0.6	1	0.5	5.3
2	0.7	1.6	2	0.7	-0.7	2	0.7	5.1
3	0.6	1.6	3	0.6	-0.7	3	0.6	4.7
4	0.5	1.3	4	0.5	-0.8	4	0.5	3.8
5	0.4	0.8	5	0.4	-0.9	5	0.4	3.1
6	0.4	0.2	6	0.4	-1.1	6	0.4	2.1
7	1.0	-0.6	7	1.0	-1.5	7	1.0	1.9
8	1.6	-0.7	8	1.6	-1.5	8	1.6	1.8
9	1.6	-0.7	9	1.6	-0.3	9	1.6	1.7
10	1.3	-0.8	10	1.3	-0.3	10	1.3	1.7
11	0.8	-0.9	11	0.8	-0.4	11	0.8	1.3
12	0.2	-1.1	12	0.2	-0.8	12	0.2	1.0
13	-0.6	-1.5	13	-0.6	-1.0	13	-0.6	0.8
14	-0.7	-1.5	14	-0.7	-1.3	14	-0.7	0.7
15	-0.7	-0.3	15	-0.7	-1.3	15	-0.7	0.3
16	-0.8	-0.3	16	-0.8	-0.9	16	-0.8	0.3
17	-0.9	-0.4	17	-0.9	-1.0	...	...	...
18	-1.1	-0.8	18	-1.1	-1.1	139	5.3	14.8

(a) Con $n = 6$ (b) Con $n = 12$ (c) Con $n = 138$

Tabla 3.4: Ejemplos de los conjuntos de datos dinámicos con (a) $n = 6$, (b) $n = 12$, y (c) $n = 138$

Por ultimo, y también como requerimiento de los tipos de análisis a realizar, transformamos los conjuntos de datos creados dinámicamente para la nueva variable *HeladaCont* cambiando el valor continuo por un valor categórico y renombrando la variable a *HeladaCat*. Esto, entre otras cosas, ayuda a disminuir la complejidad de, por ejemplo la Red Neuronal Artificial (que se usará más adelante), y convertirla en un problema de clasificación binario. Por lo tanto, el valor de *HeladaCont* se cambió a 0, cuando la *Temperatura Mínima* para ese registro era mayor o igual a 0 (representando que no hay ocurrencia de heladas para esa temperatura); y 1, si la *Temperatura Mínima* era menor a 0 (representando la ocurrencia de heladas). La Tabla 3.5 muestra como ejemplo un $n = 6$ donde el valor para *HeladaCat* en el registro 1 toma el valor de 0 ya que el valor de la *Temperatura Mínima* (*LowTemp*) del registro 7 (en violeta), el cual está 6 registros más adelante es mayor a 0 indicando la ausencia de helada; lo mismo para los registros 2 y 8 (en naranja), etc. Estos conjuntos de datos los llamamos *Conjunto de Datos de Clase Regina(n)*.

El paso siguiente consistió en la eliminación de los registros innecesarios de cada conjunto de datos⁴. Como el objetivo principal se centra en las heladas tardías, es importante considerar que estas heladas, en la zona del Alto Valle, ocurren entre los meses de julio a septiembre. Así, los registros correspondientes a los otros meses se eliminaron debido al riesgo de sobreajuste por el gran número de eventos de “no helada” en comparación con los eventos de “helada” [4]. A su vez, esta eliminación se hizo al final para asegurarnos que la variable creada, *HeladaCat*, siempre tenga un valor para imputar. Luego de este procesamiento, los conjuntos de datos quedaron con un total de 176.720 registros.

Por ultimo y para continuar registrando el caso de dominio, volvimos a aplicar el proceso P-1 de CoVaMat pero ahora para almacenar dentro de los *activos de dominio* a la *variedad de contenido*. Como podemos observar en la Figura 3.5, el proceso P-1 identifica dicha variedad y la almacena en CoVaMaT (en el artefacto de *activos del dominio*), mediante un datasheet que posee el conjunto de las 17 variables seleccionados (según Tabla 3.1) para ese caso de dominio. Todo como parte del *activo de dominio de agrometeorología*.

Proceso de Big Data: Actividad Analítica

⁴Conjunto de Datos Original Regina, Conjunto de Datos Dinámico Regina(n) y Conjunto de Datos de Clase Regina(n)

	LowTemp	HeladaCat
1	0.5	0
2	0.7	0
3	0.6	0
4	0.5	0
5	0.4	0
6	0.4	0
7	1.0	1
8	1.6	1
9	1.6	1
10	1.3	1
11	0.8	1
12	0.2	1
13	-0.6	1
14	-0.7	1
15	-0.7	1
16	-0.8	1
17	-0.9	1
18	-1.1	1

(a) Con $n = 6$

	LowTemp	HeladaCat
1	0.5	1
2	0.7	1
3	0.6	1
4	0.5	1
5	0.4	1
6	0.4	1
7	1.0	1
8	1.6	1
9	1.6	1
10	1.3	1
11	0.8	1
12	0.2	1
13	-0.6	1
14	-0.7	1
15	-0.7	1
16	-0.8	1
17	-0.9	1
18	-1.1	1

(a) Con $n = 12$

	LowTemp	HeladaCat
1	0.5	0
2	0.7	0
3	0.6	0
4	0.5	0
5	0.4	0
6	0.4	0
7	1.0	0
8	1.6	0
9	1.6	0
10	1.3	0
11	0.8	0
12	0.2	0
13	-0.6	0
14	-0.7	0
15	-0.7	0
16	-0.8	0
17	-0.9	0
...	...	...
139	5.3	0

(a) Con $n = 138$

Tabla 3.5: Ejemplo de registros con la variable *HeladaCat* imputados con valores categóricos.




Figura 3.5: Proceso P-1 donde documentamos la variedad de contenido como *activo de dominio de agrometeorología* en CoVaMaT

En esta actividad y a través de una serie de análisis, exploramos los conjuntos de datos con el objetivo de validar las hipótesis. Considerando la primera hipótesis ($H1$), la cual postulaba:

¿Las variables climáticas relacionadas con el viento o lluvia tienen influencia en la ocurrencia de heladas?

realizamos análisis de correlación para evaluar la asociación entre las variables climáticas. En particular analizamos los 3 coeficientes de correlación: Pearson, Sperman y Kendall (ver Sección 2.3.4). En un primer análisis comparamos las variables *Temperatura Máxima*, *Temperatura Mínima*, *Humedad Promedio*, *Punto de Rocío*, *Velocidad del viento*, *Aire desplazado por el viento*, *Sensación térmica*, *Presión atmosférica*, *Presencia de Lluvia*, *Promedio de lluvia*, *Radiación solar*, *Energía Solar*, *Máxima Radiación Solar* y *Evapotranspiración* con respecto a la variable de *Temperatura Mínima* como objetivo del estudio utilizando el *Conjunto de Datos Original Regina*.

Los resultados de este análisis se pueden observar en la Figura 3.6 donde los coeficientes de correlación son similares para los tres métodos utilizados. Allí vemos que se destaca una in-




Figura 3.6: Resultados del análisis de correlación para el *Conjunto de Datos Original Regina* con los métodos de Pearson, Spearman y Kendall

fluencia directa con las variables *Temperatura Máxima (HiTemp)* ($\approx 99\%$), *Sensación Térmica (WindChill)* ($\approx 98\%$), *Velocidad del Viento (WindSpeed)* ($\approx 47\%$), *Aire Desplazado por el Viento (WindRun)* ($\approx 47\%$), *Máxima Radiación Solar (Hi SolarRad)* ($\approx 44\%$), *Energía Solar (SolarEnergy)* ($\approx 43\%$), *Radiación Solar (SolarRad)* ($\approx 43\%$) y *Punto de Rocío (DewPt)* ($\approx 40\%$). Por otro lado, variables como *Presión Atmosférica (Bar)* ($\approx -38\%$) y *Humedad Promedio (OutHum)* ($\approx -61\%$) mostraron una influencia inversa significativa. Por último, las variables *Presencia de Lluvia (Rain)*, *Promedio de Lluvia (RainRate)* y *Evotranspiración (ET)* tuvieron coeficientes muy cercanos a cero lo que indica una correlación nula con la variable de interés. También se puede observar en los gráficos una diferencia entre los resultados obtenidos por Pearson y Spearman con respecto a Kendall dando algunas variaciones de un 10 % aproximadamente. Esto puede deberse al volumen de los datos, ya que Kendall suele usarse para conjuntos de datos pequeños y el utilizado es grande. Por ejemplo, para la variable *Máxima Radiación Solar (Hi SolarRad)* podemos ver que las dos primeras rondan un 46 % contra 36 % de Kendall. También hay diferencias con la variable *Presencia de Lluvia (Rain)* y esto se debe a que la misma es categórica, es decir, es la única variable con un rango definido; todas las demás son continuas. Recordemos que, según la literatura [27], cuando los datos se presentan en rangos, los mejores coeficientes se obtienen con Spearman.

En resumen y considerando la hipótesis sobre el análisis de las variables de viento y lluvia con respecto a la temperatura mínima, vemos que *WindChill (Sensación térmica)* posee un 99 % denotando una fuerte correlación positiva. Luego, *WindSpeed (Velocidad del viento)* y *WindRun (Aire desplazado por el viento)* están cercanos al 50 % con una asociación media positiva, y *Rain (Lluvia)* y *RainRate (Promedio de lluvia)* cercano a 0, denotando que no existe relación entre las variables correlacionadas.

En estos resultados de correlación se puede observar entonces cuales son las variables con más influencia en la temperatura mínima. Sin embargo no nos brindan un claro panorama de las heladas en sí mismas (temperaturas con menos de 0°C). De esta forma y para profundizar el análisis de la hipótesis, realizamos gráficos de dispersión y densidad sobre el mismo conjunto de datos pero relacionando la *Temperatura Mínima* menor a 0°C con solo aquellas variables definidas en la hipótesis. En la Figura 3.7 mostramos la relación con respecto a la *Velocidad del Viento*. El primer gráfico muestra un diagrama de dispersión donde vemos que la temperatura no desciende por debajo de los 0°C cuando la velocidad del viento supera los 13 km/h. En concordancia, en el diagrama de densidad (segundo gráfico) observamos que la mayoría de las lecturas se concentran en una velocidad del viento de 0 km/h y es allí donde también se observa la presencia de temperaturas más bajas (inferiores a 0°C). Luego vemos que en cuanto aumenta la velocidad del viento, suben también las temperaturas. En la Figura 3.8 mostramos la relación de las heladas y el *Aire Desplazado por el Viento*, donde se observa que, a partir de un desplazamiento de aire superior a 2 km, ya no se registran heladas. De esta forma, podemos ver que en ambas figuras




Figura 3.7: Diagramas de dispersión y densidad entre *Velocidad del Viento (WindSpeed)* y *Temperatura Mínima (LowTemp)*

se muestran relaciones directas entre la velocidad del viento y el aire desplazado en la incidencia de heladas; concluyendo que a medida que aumentan ambas variables se reduce la posibilidad de temperaturas inferiores a 0°C . Así, los datos corroboran la hipótesis en donde el viento tiene un efecto protector contra las heladas. Incluso podemos determinar una aproximación del viento requerido para que las mismas no se produzcan.

Luego, relacionamos las heladas con las variables vinculadas a la lluvia. Recordemos que la lluvia en los coeficientes de correlación nos dio valores cercanos a 0, es decir, sin relación. En la Figura 3.9 se muestra un gráfico de dispersión y uno de densidad para analizar la temperatura mínima con la *Presencia de Lluvia (Rain)*. Este dato es categórico, es decir 0 denota la ausencia de lluvia y 1 su presencia, y son los únicos dos valores permitidos. Así, lo primero que podemos observar en ambos diagramas es que en los periodos analizados la presencia de lluvias es muy escasa (la mayoría de los valores están ubicados en el 0). Esto sucede debido al clima de la zona el cual se caracteriza por ser semi-árido. También podemos observar que cuando no hay lluvia (eje $X=0$), pueden haber o no eventos de heladas. Sin embargo, cuando llueve (eje $Y=1$) no se registran temperaturas por debajo de los 5°C , lo que indica la ausencia de heladas durante estos eventos.

Luego, en la Figura 3.10, se muestran los diagramas de dispersión y densidad de la temperatura mínima, pero ahora relacionada con el *Promedio de Lluvia (RainRate)*. Podemos observar en ambos que a medida que aumenta dicho promedio, la temperatura no desciende de los 3°C . Por ejemplo, en el gráfico de dispersión vemos que cuando el promedio es mayor o igual a 2,5 mm, las temperaturas se mantienen por arriba de los 0°C . De esta forma, para el caso de la lluvia, por mas que los coeficientes de correlación nos habían dado una asociación casi nula entre ambas variables, con estos gráficos podemos observar una relación existente entre ellas cuando nos enfocamos en sus valores específicos.

En conclusión, los gráficos proporcionados sugieren que tanto el viento como la lluvia tienen efecto en la ocurrencia de heladas. El viento, al aumentar la velocidad, reduce la probabilidad de heladas al dispersar el aire frío; mientras que la lluvia tiende a elevar las temperaturas, evitando así la formación de heladas durante los eventos de precipitación.

Luego, se abordó la segunda hipótesis ($H2$), la cual se había definido como:




Figura 3.8: Diagramas de dispersión y densidad entre *Aire Desplazado por el Viento (WindRun)* y *Temperatura Mínima (LowTemp)*




Figura 3.9: Diagramas de dispersión y densidad entre *Presencia de Lluvia (Rain)* y *Temperatura Mínima (LowTemp)*




Figura 3.10: Diagramas de dispersión y densidad entre *Promedio de Lluvia (RainRate)* y *Temperatura Mínima (LowTemp)*

¿Hay factores climáticos con mayor influencia en la presencia de heladas en momentos previos a su ocurrencia?

Para analizar esta hipótesis, realizamos un nuevo análisis de correlación para explorar el impacto de las variables climáticas relacionadas con la temperatura mínima a lo largo del tiempo. En este análisis se consideró la variable agregada como objetivo, denominada *HeladaCont*, lo que facilitó el análisis de cómo estas variaciones relacionadas con la temperatura en momentos anteriores afectan a la temperatura en el futuro. Así, utilizamos los 24 *Conjuntos de Datos Dinámicos Regina(n)* creados desde $n = 0$ hasta $n = 138$ para analizar desde la hora 0 hasta las 23 hs futuras.

En un primer análisis general, en la Figura 3.11 mostramos, en cada uno de los 14 gráficos, el comportamiento de cada variable con respecto a *HeladaCont* en este período. Los valores del eje x de la figura coinciden con las horas del día, donde el 0 representa las 00:00hs, el 1 representa las 01:00hs y así sucesivamente hasta el 23 que representa las 23:00hs. Entonces, por ejemplo, en el primer gráfico se modela la temperatura máxima y el resultado de las correlaciones (eje y) con la variable *HeladaCont* para cada coeficiente empleado (Pearson en azul, Spearman en naranja y Kendall en verde). En el Apéndice A.1⁵ se muestran las tablas fuente de donde se derivaron estos gráficos.

Como podemos observar de todos los gráficos de la Figura 3.11, las variables que se destacaron fueron *Temperatura Máxima*, *Temperatura Mínima*, *Punto de Rocío*, *Velocidad del Viento*, *Aire Desplazado por el Viento* y *Sensación Térmica*. Los gráficos 1, 2, 4, 5, 6 y 7 (respectivamente) muestran cómo a medida que avanzan las horas, la correlación disminuye para luego volver a aumentar, teniendo sus picos máximos alrededor de las 00:00 hs y sus picos mínimos alrededor de las 12:00 hs. Por otro lado, en el gráfico 3, donde se compara a la *Humedad promedio (OutHum)*, se observa un comportamiento diferente; en este caso la correlación tiende a aumentar a medida que pasan las horas y luego a disminuir alcanzando sus picos máximos alrededor de las 12:00 hs y sus mínimos alrededor de las 00:00 hs. El comportamiento de estos gráficos (1, 2, 3, 4, 5, 6 y 7) coincide con las horas diurnas y nocturnas del día, en las que se puede ver cómo algunas variables tienden a disminuir o aumentar su influencia en la temperatura mínima dependiendo si es de

⁵Tablas A.1, A.2 y A.3




Figura 3.11: Resultados del análisis de correlación para los *Conjuntos de Datos Dinámico Regina* (n) desde $n = 0$ hasta $n = 138$ con los métodos de Pearson, Spearman y Kendall

día o de noche. En el gráfico 8 se puede ver un comportamiento similar entre los tres métodos pero Kendall muestra magnitudes superiores. Este comportamiento puede deberse al tamaño de la muestra ya que Kendall es sensible al volumen de datos. A continuación, en el gráfico 9, donde se compara a la *Presencia de Lluvia* (*Rain*), se observa que los coeficientes de correlación de Pearson son notablemente mayores que los demás, aunque muestran un comportamiento similar para los valores relacionados con la variable. Esto podría deberse a que el coeficiente de Pearson está diseñado para medir la relación entre variables continuas, mientras que esta variable es categórica. Luego, en el gráfico 10, donde se compara al *Promedio de Lluvia* (*RainRate*), se observa cómo los resultados de Pearson presentan no sólo magnitudes superiores a los demás, sino que además, tiene un comportamiento diferente. Esto puede suceder porque Pearson es sensible a las magnitudes, al tener pocos eventos de lluvia y, por consecuencia, pocas precipitaciones, nos muestra ese comportamiento tan diferente a Spearman y Kendall. Luego, los gráficos 11, 12, 13 y 14, para las variables *Radiación Solar* (*SolarRad*), *Energía Solar* (*SolarEnergy*), *Máxima Energía Solar* (*Hi SolarRad*) y *Evotranspiración* (*ET*) respectivamente, podrían indicar un retraso en la influencia de estos factores en los ciclos de día y noche con respecto a la temperatura mínima. Vemos que comienzan subiendo un poco su influencia para luego bajar y encontrar su pico mínimo alrededor de las 15:00 hs, como si existiera un retraso de 3 hs respecto a variables como la *Temperatura Máxima*, por ejemplo.




Figura 3.12: Resultados del análisis de correlación considerando el valor promedio de cada variable para los métodos de Pearson, Spearman y Kendall.

Una perspectiva distinta se puede observar en la Figura 3.12 la cual muestra el valor promedio de los coeficientes de Pearson (en color violeta), Spearman (en azul), Kendall (en verde) y el total promedio entre los tres métodos (en amarillo). Allí se puede observar cómo las variables *Temperatura Máxima (HiTemp)*, *Temperatura Mínima (LowTemp)*, *Punto de rocío (DewPt)*, y *Sensación Térmica (WindChill)* (gráficos 1, 2, 4 y 7 respectivamente) muestran una correlación directa promedio mayor a las del resto. Por otro lado, las variables *Humedad Promedio (OutHum)* y *Presión Atmosférica (Bar)* (gráficos 3 y 8 respectivamente) son las que mostraron la mayor correlación inversa promedio. Mientras que las variables *Velocidad del Viento (WindSpeed)*, *Presencia de Lluvia (Rain)*, *Promedio de Lluvia (RainRate)*, *Radiación Solar (SolarRad)*, *Energía Solar (SolarEnergy)*, *Máxima Energía Solar (Hi SolarRad)* y *Evotranspiración (ET)* (gráficos 5, 6, 9, 10, 11, 12, 13 y 14 respectivamente) son las que presentaron los valores promedios menos significativos por su cercanía al valor 0. Además, en el gráfico 10, podemos ver que Pearson presentó promedios positivos en contraste al resto de métodos que presentaron valores negativos. En el Apéndice A.1⁶ se muestran las tablas fuente donde se derivaron estos gráficos.

Analizando ahora los resultados obtenidos en la hipótesis *H1* con respecto a la hipótesis *H2* en donde se analizaron los momentos previos a la ocurrencia de la temperatura mínima, podemos ver que en *H1* los factores con mas influencia fueron la *Sensación térmica (WindChill)*, con un 99 % y la *Velocidad del viento (WindSpeed)* y el *Aire desplazado por el viento (WindRun)*. En cambio ahora, con la ocurrencia en momentos previos en un lapso de 24 hs, el valor de algunas variables cambió considerablemente. Por ejemplo, en el análisis de *H1* (con el *Conjunto de Datos Original Regina*), pudimos ver cómo la *Sensación térmica (WindChill)* tuvo una correlación del 99 %; mientras que para el análisis de *H2* (con el *Conjunto de Datos Dinámico Regina (n)*) pasó a tener un promedio menor al 35 %. Esta tendencia se mantiene, también, para las variables que dieron resultados negativos, como *Humedad Promedio*, que tuvo un valor de -61 % mientras que en el análisis de los datos dinámicos (*H2*) obtuvo -13 %. Esto nos indica que los momentos anteriores a un evento de helada son cruciales para poder predecirlas debido a la variabilidad que presentan las diferentes variables climáticas a lo largo del tiempo.

Nuevamente, como el análisis anterior solo brinda información de la relación de la temperatura mínima con respecto a otras variables, realizamos un estudio similar al realizado para *H1* en donde analizamos las variables de viento y lluvia en sus momentos previos para conocer su influencia en la ocurrencia de heladas.

Para este análisis, hemos evaluado la relación entre la *Velocidad del Viento*, *Aire Desplazado por el Viento* y *Promedio de Lluvia* con respecto a la variable *HeladaCont* durante un período de 24 hs, utilizando gráficos de líneas que nos muestran los valores mínimos necesarios de cada variable para que no ocurran heladas. Estos gráficos muestran en su eje *x* la hora, en el eje *y* la variable independiente y, por último, cada punto del gráfico muestra la medida mínima de esa variable para que no ocurran heladas. Todo esto sobre los *Conjuntos de Datos Dinámicos Regina (n)* desde $n = 0$ a $n = 138$.

En la Figura 3.13 observamos que a lo largo del día, la *Velocidad del Viento* necesaria para que no ocurran heladas tiende a aumentar. Por ejemplo, si una hora antes hubo una *Velocidad del Viento* superior a 14,5 km/h, no ocurrirán heladas; mientras que si 5 horas antes hubo una *Velocidad del Viento* superior a 20,9 km/h, tampoco ocurrirán heladas. Esta tendencia se mantiene a lo largo del día, en la cual podemos notar que a partir de las 14 hs la *Velocidad del Viento* se estabiliza en 32,2 km/h para evitar la ocurrencia de heladas. Aunque la variación en esta relación es leve, sigue siendo significativa en términos de su influencia en las condiciones climáticas. En el Apéndice A.1⁷ se muestran las tablas fuente de donde se derivaron estos valores.

Continuando, la Figura 3.14 refleja el comportamiento de la variable *Aire Desplazado por el Viento* con respecto a la temperatura mínima reflejada por la variable *HeladaCont* en el mismo periodo. La observación revela una tendencia similar a la de la *Velocidad el Viento* ya que a

⁶Tabla A.4

⁷Tabla A.5




Figura 3.13: Gráfico de líneas entre *Velocidad el Viento (WindSpeed)* y *HeladaCont*




Figura 3.14: Gráfico de líneas entre *Aire Desplazado por el Viento (WindRun)* y *HeladaCont*

medida que avanza el día, se requiere más *Aire Desplazado por el Viento* para evitar la ocurrencia de heladas. Por ejemplo, si 4 hs antes se registró 2,68 km de aire desplazado, no ocurrirán heladas; mientras que si 8 hs antes hubo 4,02 km de aire desplazado, no ocurrirán heladas tampoco. Este aumento en la cantidad de aire desplazado por el viento tiende a aumentar en las primeras 14 hs del día para luego estabilizarse en 5,25 km de aire desplazado por el viento para evitar la ocurrencia de heladas. En el Apéndice A.1⁸ se muestran las tablas con los datos fuente de donde se derivaron estos valores.

Por último, en la Figura 3.15 se observa una tendencia donde se requiere un *Promedio de Lluvia* cada vez mayor para evitar la ocurrencia de heladas a medida que avanza el tiempo. Por ejemplo, si 4 hs antes se registran precipitaciones superiores a 0,8 mm, no ocurrirán heladas; mientras que si 8 hs antes se registran precipitaciones superiores a 1 mm, no ocurrirán heladas tampoco. Al igual que en los casos anteriores se observa una tendencia a aumentar la cantidad requerida de lluvia para evitar las heladas a medida que pasa el tiempo. En el Apéndice A.1⁹ se muestran las tablas fuente de donde se derivaron estos valores.

En resumen, tras examinar todos los análisis efectuados para la segunda hipótesis (*H2*) con las correlaciones, destacamos una influencia constante de las variables relacionadas con la temperatura en la incidencia de heladas a lo largo del tiempo. Durante el día, la correlación tiende a ser menor, mientras que durante la noche es mayor. A pesar de esta variabilidad en la relación, las temperaturas siguen mostrando la mayor correlación promedio con la presencia de heladas, incluso al considerar las temperaturas proyectadas en períodos de hasta 24 hs. Esto sugiere que las fluctuaciones presentes y futuras en la temperatura son factores cruciales para predecir la probabilidad de heladas. En contraste, aunque las variables vinculadas al viento y la lluvia exhi-

⁸Tabla A.18

⁹Tabla A.7




Figura 3.15: Gráfico de líneas entre *Promedio de Lluvia (RainRate)* y *HeladaCont*

bieron coeficientes de correlación cercanos a cero y mostraron variaciones en sus valores a lo largo de 24 hs, resulta evidente que la presencia de estos fenómenos impacta en las temperaturas mínimas y, por ende, en la probabilidad de heladas. Cuando estos eventos climáticos se manifiestan, las condiciones para que ocurran heladas suelen estar influenciadas por la magnitud de dichos eventos. Por último, hay otras variables que se destacaron en este análisis, las cuales son *Humedad Promedio*, *Punto de Rocío* y *Presión Atmosférica* por tener valores promedios más alejados de 0. Esto señala que estas variables tienen una influencia en la ocurrencia de heladas.

Una vez finalizados los análisis para las hipótesis *H1* y *H2*, continuamos con las dos hipótesis siguientes con respecto a la predicción de heladas. De esta forma analizamos la tercera hipótesis que postulaba:

¿Se puede lograr un modelo predictivo eficiente utilizando las variables climáticas originales?

Para esta hipótesis, construimos varios modelos con diferentes configuraciones y les realizamos evaluaciones exhaustivas de sus comportamientos en distintos escenarios utilizando una Red Neuronal Artificial (ANN). La misma fue utilizada para pronosticar la presencia o no de heladas en los conjuntos de datos que teníamos preparados. Las configuraciones completas de la ANN puede encontrarse en el Apéndice A.3¹⁰

Las variables seleccionadas o predictoras para validar esta hipótesis fueron las del *Conjunto de Datos Original Regina* sacando la temperatura mínima que no tenía sentido, es decir se partió un conjunto de 13 variables: *Temperatura Máxima (HiTemp)*, *Humedad Promedio (OutHum)*, *Punto de Rocío (DewPt)*, *Velocidad del Viento (WindSpeed)*, *Aire Desplazado por el Viento (WindRun)*, *Sensación Térmica (WindChill)*, *Presión Atmosférica (Bar)*, *Presencia de Lluvia (Rain)*, *Promedio de Lluvia (RainRate)*, *Radiación Solar (SolarRad)*, *Energía Solar (SolarEnergy)*, *Máxima Radiación Solar (Hi SolarRad)* y *Evotranspiración (ET)*.

Como la cantidad de variables es extensa, es común que algunas de ellas estén altamente correlacionadas entre sí, lo que puede resultar en problemas de multicolinealidad. La multicolinealidad puede comprometer la precisión de las estimaciones de los coeficientes y dificultar la interpretación de los efectos individuales de las variables en un modelo predictivo. Un análisis de multicolinealidad permite identificar cualquier correlación alta entre las variables predictoras y facilitar la adopción de medidas para abordar este problema, como la eliminación y/o regularización de variables redundantes para reducirla, y así mejorar la robustez del modelo predictivo [41]. El análisis de multicolinealidad se puede realizar mediante el cálculo del Factor de Inflación de la Varianza (VIF, por sus siglas en inglés) el cual calcula, para cada variable predictora en

¹⁰Sección A.2

Variable	VIF antes	Variable	VIF después
HiTemp	990.06	HiTemp	367.82
OutHum	140.91	OutHum	16.91
DewPt.	13.19	DewPt.	13.18
WindSpeed	108230.33	WindSpeed	73065.97
WindRun	108378.35	WindRun	73063.51
WindChill	777.1	WindChill	304.54
Bar	467.39	Bar	1.41
Rain	1.37	Rain	1.43
RainRate	1.34	RainRate	1.4
SolarRad.	2088874.9	SolarRad.	1599239.47
SolarEnergy	2088730.85	SolarEnergy	1599117.88
Hi SolarRad.	48.35	Hi SolarRad.	36.76
ET	1.19	ET	1.11

Tabla 3.6: a) Resultados de VIF antes y b) después de la regularización L2 Ridge.

el modelo, una medida de cuánto aumenta la varianza de un coeficiente de regresión debido a la multicolinealidad con otras variables predictoras [41].

En la Tabla 3.6a) podemos observar que el cálculo de este factor dio como resultado muchos valores elevados para algunas de las variables, ya que un valor de mas de 10 se considera una multicolinealidad problemática. En dicha tabla se destacan las variables *Velocidad del Viento* (*WindSpeed*), *Aire Desplazado por el Viento* (*WindRun*), *Radiación Solar* (*SolarRad*) y *Energía Solar* (*Solar Energy*) con el VIF más elevado, indicando que son variables candidatas a ser eliminadas y/o regularizadas. Para esto aplicamos un método de regularización L2, conocido como regresión Ridge[28]¹¹ donde observamos una disminución de los valores de VIF para varias de las variables antes problemáticas, como se muestra en la Tabla 3.6b). Aunque algunas todavía permanecen en niveles considerables, la técnica ha tenido un impacto positivo en la reducción de la multicolinealidad. Sin embargo, para poder validar la hipótesis *H3* debemos evaluar los modelos predictivos con todas las variables, por eso no eliminamos ninguna, sino que únicamente aplicamos la regularización.

Posteriormente, tomamos el *Conjunto de Datos de Clase Regina* (n) desde $n = 0$ hasta $n = 138$ para poder crear y evaluar la ANN. Tomamos este conjunto de datos y no el original ya que nuestro objetivo era clasificar los registros según su probabilidad de que ocurran heladas y, como hemos dicho en la actividad de preparación, este conjunto de datos cuenta con una variable categórica la cual convierte el caso en un problema de clasificación binario; lo que a su vez ayuda a reducir la complejidad de los modelos creados. De esta forma, creamos cuatro modelos predictivos configurando la ANN con 8, 16, 32 y 64¹² unidades ocultas respectivamente. Variar la cantidad de unidades ocultas tiene un efecto significativo en la capacidad de la red para modelar relaciones complejas y sirve para ajustar el balance entre sesgo y varianza. Aumentar el número genera que se aumente significativamente el poder de cómputo requerido para el entrenamiento del modelo¹³, pero puede ayudar a la red a aprender patrones complejos. A su vez, elegir demasiadas unidades ocultas puede causar un sobreajuste. Sin embargo, reducir la cantidad, aunque simplifica el modelo, puede limitar su capacidad de aprendizaje.

Luego, para medir la eficiencia de los modelos en sus cuatro configuraciones construimos

¹¹Regresión Ridge es un método que incorpora una penalización a los coeficientes de las variables para minimizar la multicolinealidad

¹²Estos números fueron pensados en potencias de 2 para hacer un mejor uso de la memoria.

¹³Estos experimentos fueron realizados con algunas limitaciones de hardware.




Figura 3.16: Métricas derivadas de las matrices de confusión para cada modelo creado

primero cada matriz de confusión¹⁴. En el Apéndice A.3¹⁵, proporcionamos las tablas donde se presentan dichas matrices y sus métricas asociadas. Más tarde, a partir de las mismas, calculamos diferentes métricas como la *exactitud* (*accuracy*) para medir la proporción de predicciones correctas sobre el total de predicciones, la *sensibilidad* (*recall*) para conocer la proporción de predicciones positivas que son correctamente identificadas por el modelo, la *especificidad* (*specificity*) para medir la proporción de predicciones negativas que son correctamente identificadas por el modelo, *precisión* (*precision inglés*) para medir la proporción de predicciones positivas predichas correctamente respecto al total de predicciones clasificadas como positivas por el modelo y *puntaje F1* (*F1 Score*) para conocer la relación entre precisión y sensibilidad, es decir, para evaluar el rendimiento del modelo en cada iteración.

Así, en la Figura 3.16, se observan los resultados de estas métricas derivadas de las matrices de confusión de los modelos con cada una de las 4 cantidades de unidades ocultas. En dichos gráficos se observa la variación de las medidas (eje *y*) a lo largo de las horas del día (eje *x*). En términos generales podemos ver que todas las métricas tienden a disminuir durante las primeras 7 horas del día, donde luego parece no haber mucha variación. Se destaca la precisión, en el gráfico 2, con un comportamiento un poco diferente ya que la métrica disminuye durante las primeras 3 horas, luego aumenta hasta, aproximadamente, la hora 8, y por último oscila un poco por el resto de horas. De las configuraciones podemos concluir:

- Configuración con 8 unidades ocultas (color rojo en la figura). Se exhibió un rendimiento sólido con altos valores de precisión ($\approx 98,07\%$ a las 0 horas, gráfico 2) y especificidad ($\approx 66,29\%$ a las 0 horas, gráfico 5). Sin embargo, mostró una tendencia a reducir la sensibilidad (gráfico 3) y, por ende, el puntaje F1 (gráfico 4), indicando una posible limitación en la capacidad del modelo para identificar casos positivos.
- Configuración con 16 unidades ocultas (color azul en la figura). Mejoró la capacidad de sensibilidad ($\approx 92,02\%$ a las 0 horas, gráfico 3) y puntaje F1 ($\approx 94,86\%$ a las 0 horas, gráfico 4) en comparación con la configuración de 8 unidades, sugiriendo una mejora en la capacidad del modelo para identificar casos positivos. La precisión ($\approx 97,94\%$ a las 0 horas, gráfico 2) y la especificidad ($\approx 66,81\%$ a las 0 horas, gráfico 5) se mantuvieron altas, señalando una generalización eficaz a casos negativos.
- Configuración con 32 unidades ocultas (color verde en la figura). Se observó un ligero aumento en la sensibilidad ($\approx 92,15\%$ a las 0 horas, gráfico 3) y puntaje F1 ($\approx 94,91\%$ a las 0 horas, gráfico 4), indicando una mejora continua en la identificación de casos positivos.

¹⁴La matriz de confusión es una tabla que muestra el rendimiento de un modelo de clasificación al comparar las predicciones con los valores reales. Ayuda a visualizar los aciertos y errores de clasificación del modelo.

¹⁵Tablas A.8, A.9 A.10 y A.11 para 8, 16, 32 y 64 unidades ocultas respectivamente.

La precisión ($\approx 97,89\%$ a las 0 horas, gráfico 2) y especificidad ($\approx 67,31\%$ a las 0 horas, gráfico 5), siguieron siendo aceptables, destacando la capacidad del modelo para mantener un equilibrio entre casos positivos y negativos.

- Configuración con 64 unidades ocultas (color gris en la figura). Continuó con la tendencia de mejora en la sensibilidad ($\approx 92,43\%$ a las 0 horas, gráfico 3) y puntaje F1 ($\approx 94,96\%$ a las 0 horas, gráfico 4), sugiriendo una capacidad mejorada para identificar casos positivos. Aunque la precisión ($\approx 97,68\%$ a las 0 horas, gráfico 2) se mantuvo alta, la especificidad ($\approx 67,24\%$ a las 0 horas, gráfico 5) mostró una disminución modesta, indicando una posible propensión a clasificar erróneamente algunas casos negativos. Esto sugiere que, aunque pueda capturar patrones complejos en los datos de entrenamiento, podría tener dificultades para generalizar.

Como conclusión de los gráficos podemos decir que el análisis de las distintas configuraciones de unidades ocultas reveló tendencias claras en el desempeño de los modelos de predicción de heladas tardías en un periodo de 24 horas. A medida que se aumentó el número de unidades ocultas, se observaron mejorías generales en la precisión de las predicciones. Sin embargo, este beneficio se acompaña de un riesgo potencial de sobreajuste, especialmente evidente en el modelo con 64 unidades ocultas. Este riesgo llevó a que sea crucial encontrar un equilibrio óptimo entre la complejidad del modelo y su capacidad para generalizar patrones, evitando así un sobreajuste excesivo. Además, es importante destacar que todas las métricas se vieron gravemente afectadas por el paso del tiempo, ya que cuanto más cercano es el evento de helada más efectivo es el desempeño del modelo. En términos globales, la elección de la mejor configuración depende de un compromiso entre rendimiento y generalización. Considerando este equilibrio, la configuración con 32 unidades ocultas pareció ser la elección mas prudente ya que ofrece un desempeño sólido sin caer en los riesgos potenciales de las demás configuraciones.

Por último se planteó una hipótesis final del caso en donde se pretendía evaluar el modelo utilizando sólo un subconjunto de variables y minimizar así la complejidad de la red. Esta cuarta hipótesis postulaba:

¿Se puede ahora lograr un modelo predictivo eficiente utilizando sólo un subconjunto de variables?

Para seleccionar qué variables eliminar del conjunto de datos, nos guiamos de los resultados de las dos primeras hipótesis (con respecto a sus influencias en la ocurrencia de heladas), los resultados del VIF (en la hipótesis anterior) y la recomendación de los expertos de dominio. Principalmente excluimos las variables: *Velocidad del Viento*, *Aire Desplazado por el Viento*, *Sensación Térmica*, *Lluvia*, *Promedio de Lluvia*, *Radiación Solar*, *Evotranspiración* y *Energía Solar*. Si bien se probó que la lluvia y el viento influyen en la ocurrencia de heladas, sólo sucede bajo ciertas condiciones y con ciertas velocidades y cantidad de lluvia; pero su influencia general dio valores promedios. Por otro lado, *Sensación Térmica* tuvo valores muy elevados en comparación a otras variables pero los expertos de dominio recomendaron su eliminación. También se recomendó mantener una de las variables relacionadas a la radicación solar, la cual fue *Máxima Energía Solar (Hi SolarRad.)*. El resto de variables fueron eliminadas por su media/baja influencia demostrada en *H1* y *H2*. En la Tabla 3.7 podemos observar las 6 variables resultantes usadas para esta hipótesis.

Luego creamos un nuevo modelo predictivo en ANN utilizando una configuración de 32 unidades ocultas. Este ajuste se fundamentó en resultados previos de *H3* que definieron a esta configuración como la más óptima. En el Apéndice A.3¹⁶ se puede ver en detalle los valores resultantes. En la Figura 3.17 observamos estos valores gráficamente en donde podemos destacar una serie de patrones y tendencias que ofrecen una visión integral del desempeño del modelo en

¹⁶Tabla A.12

Variable	Nombre en español	Tipo
HiTemp	Temperatura Máxima	Numérica
LowTemp	Temperatura Mínima	Numérica
OutHum	Humedad Promedio	Numérica
DewPt.	Punto de Rocío	Numérica
Bar	Presión Atmosférica	Numérica
Hi SolarRad.	Máxima Energía Solar	Numérica


Tabla 3.7: Variables seleccionadas para la hipótesis $H4$ 

Figura 3.17: Comportamiento de las métricas derivadas de la matriz de confusión para la nueva configuración de 32 unidades ocultas y 6 variables.

diferentes momentos del día. En términos de rendimiento general, el modelo creado demostró una destacada exactitud (línea azul), con valores que oscilaron entre el 99,89 % (en la hora 0) y el 89,13 % (en la hora 23) a lo largo del día. Esto sugiere una habilidad constante para realizar predicciones precisas en la clasificación de eventos. Sin embargo, se observó una variación en otras métricas cruciales, como la sensibilidad (línea verde, con un valor promedio del $\approx 91,79\%$) y la especificidad (línea violeta, con un valor promedio del $\approx 66,69\%$). La sensibilidad mostró una disminución gradual a medida que avanzaban las horas, desde 99,92 % (en la hora 0) a 90,33 % (en la hora 23), indicando posiblemente una mayor dificultad en la detección de eventos positivos en momentos específicos. Por otro lado, la especificidad también exhibió variaciones a lo largo del día, desde 99,42 % (en la hora 0) hasta 61,95 % (en la hora 23), lo que indica que el modelo podría ser ajustado para mejorar su eficiencia en la identificación de eventos negativos en ciertos periodos. El análisis del puntaje F1 (línea roja) proporcionó una medida consolidada del rendimiento general del modelo, yendo de 99,94 % (en la hora 0) a 94,09 % (en la hora 23) durante las 24 horas del día. Esto sugiere que el rendimiento general del modelo fue alto y relativamente estable. De esta forma, a pesar de las fluctuaciones, el modelo mantuvo una eficacia considerable en la detección y clasificación de heladas a lo largo del día.

Para analizar si la elección de las variables para $H4$ fue eficiente, sobre todo contra las 13 variables definidas en $H3$, realizamos la comparación que se puede observar en la Figura 3.18. Para esto utilizamos los valores de las tablas en el Apéndice A.3¹⁷. La misma muestra en color rojo los resultados obtenidos en $H3$ en cada métrica con las 13 variables y 32 unidades ocultas, que llamaremos *Configuración13*. En el color azul observamos los resultados del modelo para las 6 variables de $H4$ y las 32 unidades ocultas, que llamaremos *Configuración6*. En términos generales, observamos comportamientos casi idénticos entre ambas configuraciones.

¹⁷Tablas A.10 y A.12

En el gráfico 1, se muestra la exactitud de ambos modelos donde se observa una variabilidad mínima, siendo más notoria la diferencia a partir de las 12 horas, donde la *Configuración6* tiene valores ligeramente inferiores a la *Configuración13*. Por ejemplo, podemos ver que a la hora 3 la *Configuración13* muestra una exactitud mayor, de 93,02 % contra los 92,94 % de la *Configuración6*; sin embargo, a la hora 1 la *Configuración6* tiene una exactitud mayor, del 97,32 % contra el 97,24 %. A pesar de estas variaciones, podemos ver un promedio del 90,49 % para la *Configuración6* contra los 90,71 % de la *Configuración13*. Respecto a la precisión, en el gráfico 2, notamos un ligero aumento en los promedios, con la *Configuración6* en 98,09 % y la *Configuración13* en 97,89 %. No obstante, en esta métrica podemos ver una variación más acentuada. Por ejemplo, para la *Configuración6* vemos que a las 5 horas se obtuvo un 96,95 % contra un 97,01 % de la *Configuración13*, pero, a las 10 horas la *Configuración6* aumenta a 98,82 % frente a los 98,53 % de la *Configuración13*. A pesar de esta mayor variación, los promedios se mantuvieron muy iguales. Por otro lado, en el gráfico 3, observamos la sensibilidad de ambos modelos, con la *Configuración6* mostrando una ligera disminución en comparación con la *Configuración13*, del 91,79 % y 92,15 % respectivamente en sus valores promedios. Como en el caso de la exactitud, vemos un comportamiento muy similar. Algunos ejemplos de esta variación la encontramos a las 13 horas, donde la *Configuración13* tiene una mejor sensibilidad, de 90,55 %, superando los 90,27 % de la *Configuración6*. Por otro lado, la *Configuración6* supera a la *Configuración13* a las 3 horas, con valores de 97,05 % y 97,0 % respectivamente. En cuanto al puntaje F1, en el gráfico 4, también se aprecia una disminución promedio con respecto a la *Configuración13* que presentó 94,91 %, contra los 94,81 % de la *Configuración6*. A pesar de notar una variación entre los valores de esta métrica, fue la que presentó menor variabilidad entre las configuraciones. Finalmente, en el gráfico 5, vemos que la especificidad es ligeramente menor en la *Configuración6*, con un 66,7 % frente a los 67,31 % de la *Configuración13*. De acuerdo a los valores promedios de cada métrica, y cada configuración, la especificidad fue la que mayor variabilidad mostró.

En resumen, la configuración de 32 unidades ocultas y 6 variables (*Configuración6*) mostró un rendimiento muy bueno y eficiente. A pesar de las disminuciones observadas en muchas de estas métricas, las diferencias son mínimas. Así, este último modelo es preferible en términos de simplicidad y eficiencia sin sacrificar la precisión general del mismo. Es decir, la nueva configuración ofrece beneficios en términos de mantenimiento y eficiencia computacional del modelo.




Figura 3.18: Comparación de las métricas derivada de las matrices de confusión para la configuración de 13 variables y 32 unidades ocultas (*Configuración13*), y la configuración de 6 variables y 32 unidades ocultas (*Configuración6*).

Al igual que en la actividad de preparación, llamamos al proceso P-1 de CoVaMaT para almacenar dentro de los activos de domino la *variedad de procesos*. Como podemos observar en la Figura 3.19, el activo creado contiene los métodos analíticos utilizados previamente.

Proceso de Big Data: Actividades de Visualización y Acceso




Figura 3.19: Proceso P-1 donde documentamos la variedad de procesos como *activo de dominio de agrometeorología* en CoVaMaT

Hemos realizado solo algunas de las actividades de visualización para este caso de dominio. En particular para la hipótesis $H4$ y para proporcionar a los expertos una forma de usar y entender cómo funciona el modelo predictivo, hemos realizado un formulario simple que permite ingresar los datos necesarios para la clasificación. Es decir, predice o clasifica datos actuales para determinar la presencia o ausencia de heladas en un período de n horas. Esta predicción se realiza con el modelo entrenado *Configuración6*. Así, en la Figura 3.20 podemos observar un conjunto de datos ingresado para cada una de las 6 variables, y la solicitud de que prediga la ocurrencia o no de heladas en las siguientes 2 hs. Como resultado, el formulario responde 1, indicando que va a haber heladas junto con el porcentaje de exactitud de la predicción.

Temperatura Máxima:	3.2
Temperatura Mínima:	1.7
Punto de Rocío:	1.9
Presión Atmosférica:	759.4
Humedad Promedio:	31
Radiación Solar:	251
Horas:	2

Predcir

Resultado: 1

Exactitud: 97.32 %

Figura 3.20: Formulario para predecir la ocurrencia o no de heladas en n horas posteriores

Al mismo tiempo, para mostrar una predicción mas completa, se pueden enviar datos por lotes. En la Tabla 3.8 se muestra un ejemplo donde usamos como entrada 20 registros del *Conjunto*

de Datos Original Regina, conservando solo las seis variables de *H4*. Ninguno de estos registros está etiquetado, es decir, no sabemos de antemano si ocurrirán o no heladas. Con este conjunto de datos, elegimos nuevamente 2 horas en el futuro para la predicción. Como podemos ver, el modelo fue capaz de clasificar correctamente los 20 registros del ejemplo. Es decir, cada valor de la variable *Predicción* coincide con el valor de la variable *HeladaCat*. Cabe destacar que en este ejemplo agregamos manualmente la variable *HeladaCat* sólo para poder corroborar los resultados.

HiTemp	LowTemp	OutHum	DewPt.	Bar	Hi SolarRad.	HeladaCat	Predicción
19.6	19.3	31.0	1.9	759.4	251.0	0	0
19.5	19.4	30.0	1.4	759.4	234.0	0	0
19.4	19.4	30.0	1.4	759.4	211.0	0	0
19.4	19.0	31.0	1.6	759.7	181.0	0	0
19.1	19.0	31.0	1.5	759.8	144.0	0	0
19.2	18.7	31.0	1.4	760.0	139.0	0	0
18.7	18.2	31.0	1.0	760.2	33.0	0	0
18.2	18.2	30.0	0.3	760.2	56.0	0	0
18.2	17.8	31.0	0.6	760.3	19.0	0	0
17.8	17.7	29.0	-0.5	760.3	28.0	0	0
17.8	17.5	28.0	-1.1	760.2	16.0	0	0
17.5	17.4	26.0	-2.3	760.5	11.0	0	0
17.6	17.4	24.0	-3.3	760.4	7.0	0	0
17.5	17.0	25.0	-3.0	760.3	0.0	0	0
17.1	16.7	26.0	-2.8	760.6	0.0	0	0
16.7	16.4	27.0	-2.5	760.8	0.0	0	0
16.4	16.1	28.0	-2.3	760.9	0.0	0	0
16.1	15.9	28.0	-2.5	760.9	0.0	0	0
15.9	15.4	30.0	-1.8	761.2	0.0	0	0
15.4	15.0	30.0	-2.3	761.3	0.0	0	0

Tabla 3.8: Predicciones de heladas para 20 filas del *Conjunto de Datos Original Regina* en 2 horas posteriores utilizando el modelo predictivo de *H4*

El resto de las actividades de visualización y acceso quedan pendientes de su terminación ya que sólo se realizaron en forma informal mostrando a los usuarios expertos los resultados obtenidos en gráficos. Resta también la realización de alguna plataforma integral que permita la visualización y acceso a los resultados de forma tal que estén disponibles en todo momento.

Paso 4: Verificación de las Hipótesis

Como hemos observado en los análisis realizados en la actividad de analítica, los resultados validaron la primera hipótesis (*H1*) la cual postulaba: *¿Las variables climáticas relacionadas con el viento o lluvia tienen influencia en la ocurrencia de heladas?*. Hemos podido observar como la presencia de estos eventos climáticos tienen una influencia directa en la ocurrencia de heladas. Pudimos ver que cuando ocurren eventos de lluvias (aún con precipitaciones bajas) o de viento (con velocidades bajas y/o poco aire desplazado) las temperaturas no tienden a ser menores a 0°C, evitando así la ocurrencia de las mismas.

Para la segunda hipótesis (*H2*) que postulaba: *¿Hay factores climáticos con mayor influencia en la presencia de heladas en momentos previos a su ocurrencia?*, los resultados indicaron que las variables *Temperatura Máxima*, *Temperatura Mínima*, *Humedad Promedio*, *Punto de Rocío*, *Sensación Térmica* y *Presión Atmosférica* son las que tienen la mayor influencia. El resto de variables mostraron una influencia muy cercana a 0. Además, hemos observado que a medida que avanza el tiempo, las magnitudes de las variables relacionadas con el viento y la lluvia tienden a aumentar para mantener las temperaturas mínimas por encima de 0°C, lo que sugiere que un aumento en la velocidad del viento, una mayor cantidad de aire desplazado por el viento y/o un

aumento en el promedio de lluvia pueden contribuir a prevenir la ocurrencia de heladas. Esto valida la hipótesis ya que, como hemos podido observar, hay variables que son mas influyentes que otras en la ocurrencia de heladas en momentos previos.

Tras analizar la tercera hipótesis (*H3*), que postulaba: *¿Se puede lograr un modelo predictivo eficiente utilizando las variables climáticas originales?*, empleamos las 13 variables originales del conjunto de datos para construir modelos efectivos y, entre todos ellos, encontramos que el modelo con 32 unidades ocultas logró un balance óptimo, sin incurrir en los riesgos de sobreajuste. Este modelo presentó valores destacados en varias métricas clave de evaluación, incluyendo exactitud, precisión, sensibilidad, especificidad y puntaje F1. Estos resultados demuestran la validez de la hipótesis, indicando que es posible construir un modelo predictivo eficiente utilizando las variables climáticas originales.

Con respecto a la cuarta hipótesis (*H4*) que postulaba: *¿Se puede ahora lograr un modelo predictivo eficiente utilizando sólo un subconjunto de variables?*, hemos demostrado que dejar sólo un subconjunto de variables seleccionadas en base a diferentes suposiciones, resultó ser también altamente eficiente en la predicción de heladas y comparable con el modelo realizado en la hipótesis anterior. Los resultados sugieren que las variables seleccionadas poseen un poder predictivo significativo en la detección de heladas, lo que respalda la idea de que no es necesario utilizar el conjunto completo de variables climáticas para desarrollar un modelo efectivo de predicción.

Paso 5: Reformulación o Terminación

Se decidió finalizar este caso de dominio debido a que se arribó a la verificación de las hipótesis formuladas. Como resultado del mismo se generaron todos los activos pertenecientes al dominio de agrometeorología que mostramos en las Figuras 3.3, 3.4, 3.5 y 3.19. Un resumen completo de todos los activos creados puede verse en la Figura 3.21.

Luego, para la documentación del *caso de dominio*, utilizamos la funcionalidad F-2 (*Funcionalidad para instanciar casos*) para instanciar los activos de dominio creados previamente. De esta forma llamamos al proceso P-2 (*Definir caso*) el cual recupera los activos de dominio, en este caso el único creado de agrometeorología, selecciona e instancia las variedades, y desarrolla y almacena el caso. En la Figura 3.22 podemos observar que desde el *activo de dominio de agrometeorología* instanciamos todos los datasheets creados para los activos de este dominio resultando en las aplicadas al caso. Por último, el caso se documentó como *Caso de dominio VR*.

3.1.2. Caso de Dominio 2: Guerrico

A continuación realizamos un segundo caso de dominio el cual requirió realizar las mismas 5 actividades del enfoque Top-Down (Figura 3.1) pero ahora sobre un área diferente. Como podemos observar en la Figura 3.23, nos abocamos al área abarcada por la Estación Meteorológica Guerrico.

La realización de este segundo caso tiene la particularidad de que existen en el repositorio de CoVaMaT activos en el dominio de agrometeorología, creados en el caso anterior que se reusaron para la creación de este segundo caso. Para esto, utilizamos la funcionalidad F-3 (*Funcionalidad para reutilización de casos*) y los procesos P-3 (*Definir caso de reuso*) y P-4 (*Consultar activos de dominio en casos similares*) para consultar y recuperar los activos del dominio y/o casos de dominio existentes y similares.

En la Figura 3.24 podemos observar los pasos para la búsqueda y recuperación de los activos creados para el caso de dominio de Villa Regina y que fueron reusados para Guerrico. Lo primero que realizamos (número 1 de la figura) fue la búsqueda de los activos en donde se encontró y recuperó el *activo de dominio de agrometeorología* (Proceso P-3). Luego de que lo analizamos y seleccionamos, determinamos que era necesario crear una nueva variedad que ahora incluya el área de Guerrico (número 2, en naranja en la figura). La variedad de contexto posee entonces




Figura 3.21: Resumen de las variedades para cada clase, almacenadas como un activo de dominio de agrometeorología




Figura 3.22: Caso de dominio VR creado a partir de las instancias del activo de dominio de agrometeorología



Figura 3.23: Caso de Dominio 2 para el área que incluye la Estación Meteorológica Guerrico




Figura 3.24: Creación de una nueva variedad de contexto para el área de Guerrico y de un nuevo caso reusable *Caso reusable Guerrico*

ahora las dos áreas, Villa Regina y Guerrico. Luego, se utilizó el proceso P-4 para buscar casos del dominio similares, donde se recuperó el *Caso de dominio VR* (número 3 en la figura) con todos sus activos asociados (Figura 3.22). Con el caso ya recuperado, instanciamos la variedad de contexto al área de Guerrico (número 4 en la figura) y creamos un nuevo activo denominado *Caso reusable Guerrico* el cual posee el área instanciada (número 5 en la figura). Luego continuamos con las siguientes actividades del proceso de big data, analizando si hay similitudes en las siguientes variedades.

Paso 1: Definición de Hipótesis

Las hipótesis planteadas en este caso se correspondieron con las dos primeras hipótesis definidas en el caso de dominio anterior (*H1* y *H2*). A su vez, agregamos una nueva hipótesis aquí que involucra la comparación de los resultados de este caso con el caso previo en la zona de Villa Regina. La nueva hipótesis postulaba:

- **Hipótesis 5 (*H5*):** *¿Los factores analizados en el área de Villa Regina, poseen la misma influencia en el área de Guerrico para la ocurrencia de heladas?*

Esta hipótesis fue planteada por los expertos ya que deseaban observar el comportamiento en una nueva área con características diferentes. El área de Guerrico tiene la particularidad de ser más fría y con mayor ocurrencia de heladas tardías.




Figura 3.25: Creación de una nueva variedad de fuentes instanciada al *Caso reusable Guerrico*

Pasos 2 y 3: Procesamiento de las Hipótesis

En los pasos 2 y 3 tomamos las 2 primeras hipótesis definidas (como analistas de datos) y llevamos a cabo todas las actividades involucradas (Figura 3.1).

Proceso de Big Data: Actividad Colección

La actividad de colección de datos es similar al *Caso de Dominio VR* ya que poseen los mismos formatos, pero son obtenidos desde otra estación meteorológica, en este caso Guerrico.

Para registrar esta actividad en la base de conocimiento CoVaMaT (Figura 3.25), y como tenemos variedades similares de datos semi-estructurados definidas en el *activo de dominio de agrometeorología*, creamos primero una nueva variedad de fuente, denominada *estación meteorológica Guerrico*, desde el activo recuperado (numero 1 y naranja en la figura). Podemos observar que ya se encuentra en el repositorio la estación de Villa Regina. Luego, instanciamos esa variedad y se la asociamos al *Caso reusable Guerrico* (numero 2 en la figura).

Proceso de Big Data: Actividad Preparación

Dentro de esta actividad se llevaron a cabo las mismas técnicas de preparación de los datos aplicadas en el *Caso de Dominio VR*, pero ahora sobre el conjunto de datos de Guerrico. Esto se debe a que ambos conjuntos de datos poseían las mismas variables, la misma frecuencia de medición y el mismo formato. Al igual que con el caso de Villa Regina, se prepararon 3 conjuntos de datos: *Conjunto de Datos Original Guerrico*, que posee el conjunto de datos original con 14 variables; *Conjunto de Datos Dinámico Guerrico(n)*, que posee la variable *HeladaCont* y permite crear dinámicamente n conjuntos; y, por último, el *Conjunto de Datos de Clase Guerrico(n)*, el cual es similar al conjunto anterior con una nueva variable (*HeladaCat*) que posee un valor categórico de presencia o ausencia de heladas..

Para la creación y documentación en CoVaMaT, no tuvimos en este caso que crear nuevas variedades ya que son las mismas que poseíamos en el *activo de dominio de agrometeorología* para la variedad de contenido. Por lo tanto lo único que realizamos fue asociarlas al *Caso reusable Guerrico* (Figura 3.26).

Proceso de Big Data: Actividad Analítica

En esta actividad, examinamos los diferentes conjuntos de datos para evaluar nuestras hipótesis. De acuerdo a la primera hipótesis ($H1$), que planteaba:




Figura 3.26: Instanciación de las variables climáticas asociadas con el *activo de dominio de agrometeorología* al *Caso reusable Guerrico*




Figura 3.27: Resultados del análisis de correlación para el *Conjunto de Datos Original Guerrico* con los métodos de Pearson, Spearman y Kendall

¿Las variables climáticas relacionadas con el viento o lluvia tienen influencia en la ocurrencia de heladas?

Se comenzó realizando un análisis sobre el *Conjunto de Datos Original Guerrico* para evaluar la correlación de las diferentes variables climáticas sobre la variable objetivo *Temperatura Mínima (LowTemp)*. En la Figura 3.27 se pueden observar estos resultados donde se destaca una influencia directa de las variables *Temperatura Máxima (HiTemp)* ($\approx 99\%$), *Sensación Térmica (WindChill)* ($\approx 96\%$), *Máxima Radiación Solar (Hi SolarRad.)* ($\approx 48\%$), *Energía Solar (SolarEnergy)* ($\approx 47\%$) y *Energía Solar (SolarEnergy)* ($\approx 47\%$). Las variables *Humedad Promedio (OutHum)* ($\approx -68\%$) y *Presión Atmosférica (Bar)* ($\approx -28\%$) fueron las que presentaron la mayor correlación inversa. Por último, *Velocidad del Viento (WindSpeed)* ($\approx 30\%$), *Aire Desplazado por el Viento (WindRun)* ($\approx 33\%$), *Punto de Rocío (DewPt.)* ($\approx 32\%$), *Evotranspiración (ET)* ($\approx 14\%$), *Promedio de Lluvia (RainRate)* ($\approx -0,24\%$) y *Lluvia (Rain)* ($\approx -0,91\%$) tuvieron los valores más cercanos a 0.

Los resultados mostrados por Pearson y Spearman son casi idénticos; la mayor diferencia la podemos encontrar en la variable *Lluvia (Rain)*. Esto se debe a que esa variable es categórica y Spearman suele dar resultados mejores para este tipo de variables. Más allá de esto, las diferencias son de alrededor de 1%. Por otro lado, vemos resultados considerablemente más bajos para Kendall; por ejemplo Pearson y Spearman tuvieron resultados de 52% para *Máxima Radiación Solar (Hi SolarRad.)*, mientras que Kendall obtuvo un 39%. Esto ocurre porque Kendall se utiliza para conjuntos de datos mas pequeños.

Al mismo tiempo, y para comprender mejor el comportamiento de las variables, no solo con




Figura 3.28: Diagramas de dispersión y densidad entre *Velocidad del Viento (WindSpeed)* y *Temperatura Mínima (LowTemp)* en Guerrico

la temperatura mínima, sino también con la ocurrencia de heladas (temperaturas menores a 0°C), realizamos diagramas de dispersión y densidad sobre las variables relacionadas con el viento y la lluvia. En la Figura 3.28, que evalúa la *Velocidad del Viento (WindSpeed)*, observamos en el diagrama de dispersión que a partir de una velocidad del viento superior a los 16 km/h las temperaturas son superiores a los 0°C . Por otro lado, el diagrama de densidad muestra que la mayoría de los registros son de velocidades de 0 km/h. Si bien el diagrama de dispersión muestra un gran número de velocidades distintas, el diagrama de densidad nos muestra que la mayoría de los registros se agrupan en velocidades de 0 km/h, y es allí donde también se observa la presencia de temperaturas más bajas (inferiores a 0°C).

Por otro lado, en cuanto al *Aire Desplazado por el Viento (WindRun)* (Figura 3.29), el diagrama de dispersión muestra que se requiere de un volumen de aire desplazado superior a 2,68 km para que la temperatura se mantenga por encima de los 0°C . Además, podemos notar la relación que existe entre la *Velocidad del Viento (WindSpeed)* y el *Aire Desplazado por el Viento (WindRun)* donde vemos que a mayor velocidad del viento existe más aire desplazado y esto influye directamente en la ocurrencia de heladas. Es decir, a medida que aumentan, las temperaturas se mantienen por encima de los 0°C .

Con respecto a la *Lluvia (Rain)*, en el diagrama de dispersión de la Figura 3.30, se evidencia que cuando hay lluvia, no ocurren heladas ya que las temperaturas se mantienen encima de los 0°C . Recordemos que esta variable es categórica, donde 0 representa la ausencia de lluvia mientras que 1 representa la presencia de lluvia. Con respecto al diagrama de densidad vemos que las lluvias son muy escasas y esto es debido a las características climáticas de la zona.

Por último, con respecto al *Promedio de Lluvia (RainRate)*, en el diagrama de dispersión de la Figura 3.31, se observa que a partir de promedios de lluvia bajos, superiores recién a los 0,8 mm, no ocurren heladas. A su vez, el diagrama de densidad confirma lo visto con respecto a la *Presencia de Lluvia (Rain)*, donde tenemos promedios muy bajos debido a las características de la zona.

Tras evaluar estos resultados podemos afirmar que las variables relacionadas con la lluvia y el viento influyen en las temperaturas mínimas y, por consecuencia, en la ocurrencia de heladas. Aunque tuvimos valores de correlación muy bajos, es evidente que estos eventos tienen influencia en las heladas ya que cuando ocurren, bajo ciertos parámetros y cantidades, las temperaturas no descienden de los 0°C .




Figura 3.29: Diagramas de dispersión y densidad entre *Aire Desplazado por el Viento (WindRun)* y *Temperatura Mínima (LowTemp)* en Guerrico




Figura 3.30: Diagramas de dispersión y densidad entre *Presencia de Lluvia (Rain)* y *Temperatura Mínima (LowTemp)* en Guerrico




Figura 3.31: Diagramas de dispersión y densidad entre *Promedio de Lluvia (RainRate)* y *Temperatura Mínima (LowTemp)* en Guerrico

A continuación abordamos la segunda hipótesis, la cual postulaba:

¿Hay factores climáticos con mayor influencia en la presencia de heladas en momentos previos a su ocurrencia?

Para responder a esta hipótesis se realizó el análisis de correlación en un periodo de 24 hs con el *Conjunto de Datos Dinámico Guerrico (n)* teniendo como objetivo la variable agregada *HeladaCont*, con $n = 0$ hasta $n = 138$. La Figura 3.32 muestra los resultados de este análisis. Las variables *Temperatura Máxima (HiTemp)*, *Temperatura Mínima (LowTemp)*, *Velocidad del Viento (WindSpeed)*, *Aire Desplazado por el Viento (WindRun)* y *Sensación Térmica (WindChill)* (gráficos 1, 2, 5, 6 y 7, respectivamente) muestran un comportamiento similar donde la correlación tiene sus picos mínimos entre las 12:00 hs y las 14:00 hs aproximadamente, para luego volver a subir. La variable *Humedad Promedio (OutHum)* (gráfico 3), tiene un comportamiento inverso, es decir, tiende a subir hasta cerca de las 12:00 hs para luego disminuir. Las variables *Presión Atmosférica (Bar)*, *Presencia de Lluvia (Rain)* y *Promedio de Lluvia (RainRate)* (gráficos 8, 9 y 10 respectivamente) nos muestran comportamientos muy similares entre los diferentes coeficientes de correlación. Sin embargo, para la *Presión Atmosférica (Bar)* (gráfico 8), Kendall tiene magnitudes superiores a las del resto. Con respecto al *Promedio de Lluvia (RainRate)* (gráfico 10) vemos cómo Pearson comienza con magnitudes superiores a las del resto que, a medida que pasa el tiempo, se va igualando a las otros coeficientes. Por último, las variables *Punto de Rocío (DewPt.)*, *Radiación Solar (SolarRad.)*, *Energía Solar (SolarEnergy)*, *Máxima Radiación Solar (Hi SolarRad.)* y *Evotranspiración* (gráficos 4, 11, 13 y 14, respectivamente) están indicando un retraso de unas 3 hs en su influencia en comparación con variables como la *Temperatura Máxima (HiTemp)* (gráfico 1).

Luego, en la Figura 3.33 evaluamos el valor promedio de los coeficientes de Pearson (en color violeta), Spearman (en azul) y Kendall (en verde). Observamos que en la mayoría de los casos, los resultados son muy similares, con la excepción de *Promedio de Lluvia (RainRate)* (gráfico 10), en el cual Pearson y Kendall tuvieron valores positivos, mientras que Spearman tuvo resultados negativos. Esto puede deberse a que Spearman, al evaluar únicamente la relación de rango, puede identificar una tendencia negativa que puede ser dominante en ciertos segmentos de los datos, lo que resulta en un coeficiente negativo. También, las variables *Radiación Solar (SolarRad.)*,




Figura 3.32: Resultados del análisis de correlación para los *Conjuntos de Datos Dinámico Guerrero* (n) desde $n = 0$ hasta $n = 138$ con los métodos de Pearson, Spearman y Kendall

Energía Solar (*SolarEnergy*) y *Máxima Radiación Solar* (*Hi SolarRad.*) (gráficos 11, 12 y 13), muestran promedios más bajos por parte de Spearman. Debemos recordar que Spearman es sensible a las magnitudes por lo que esto podría estar afectando sus resultados. En el Apéndice A¹⁸ se muestran las tablas fuente donde se derivaron estos gráficos.

Analizando ahora los resultados obtenidos en la hipótesis $H1$ con respecto a la hipótesis $H2$ en donde se analizaron los momentos previos a la ocurrencia de la temperatura mínima, podemos afirmar que en el análisis de $H2$ obtuvimos una disminución de los valores de correlación para todas las variables, es decir, que sus valores se acercaron mucho más a 0. Por ejemplo, la *Temperatura Máxima*, en el análisis de $H1$ obtuvo un valor promedio de 99 %, mientras que para el análisis de $H2$ tuvo valores de, aproximadamente, 30 %. Estamos hablando de una disminución de casi 70 puntos. Esto también ocurrió con las variables que tuvieron valores de correlación negativa, por ejemplo *Humedad Promedio* obtuvo un resultado de -68 % en el primer análisis y -14 % en el análisis dinámico. Sin embargo proporcionalmente las influencias quedaron igual.

En conclusión, los resultados de los análisis de correlación muestran una influencia significativa de las temperaturas, tanto máxima como mínima, siendo las de mayor influencia en la ocurrencia de heladas. Se observaron también comportamientos donde los ciclos de día y noche

¹⁸Tablas A.13, A.14, A.15, A.16






Figura 3.33: Resultados del análisis de correlación considerando el valor promedio de cada variable para los métodos de Pearson, Spearman y Kendall.

Figura 3.34: Gráfico de líneas entre *Velocidad del Viento (WindSpeed)* y *HeladaCont*Figura 3.35: Gráfico de líneas entre *Aire Desplazado por el Viento (WindRun)* y *HeladaCont*

alteran la influencia de las diferentes variables en la temperatura mínima. Esto indica que los momentos anteriores a un evento de helada son cruciales.

Por otro lado, en el análisis de correlación, las variables vinculadas al viento y la lluvia, arrojaron resultados cercanos a cero. Sin embargo, estas variables requirieron de un análisis mas específico ya que se debían analizar con respecto a la ocurrencia de heladas y no solo a la temperatura mínima general. Así, realizamos un estudio similar al realizado para *H1* pero ahora para conocer su influencia en momentos previos a la ocurrencia de heladas. En la Figura 3.34¹⁹ vemos como las velocidades del viento (*WindSpeed*) requeridas para que no ocurran heladas tiende a aumentar durante las primeras 12 horas del día, momento en el cual las velocidades tienden a disminuir. Vemos, por ejemplo, que a las 4 hs es necesario una velocidad del viento superior a los 24,10 km/s para que no ocurran heladas, mientras que en 8 horas antes son necesarias velocidades superiores a los 41,8 km/h. En el Apéndice A²⁰ se muestran las tablas fuente donde se derivaron estos gráficos.

Luego, en la Figura 3.35 mostramos el comportamiento de la variable *Aire Desplazado por el Viento (WindRun)* a lo largo del día, de acuerdo a los mismos parámetros anteriores. Se observa un aumento progresivo en la cantidad de aire desplazado durante las primeras 12 hs del día (9,66 km), seguido de una posterior disminución abrupta a las 13 hs (7,11 km) y luego una ligera disminución durante las 10 hs siguientes. Este incremento gradual sugiere que, para evitar heladas, se requiere un mayor volumen de aire desplazado por el viento durante el día. En el Apéndice A²¹ se muestran las tablas fuente donde se derivaron estos gráficos.

Por último, la Figura 3.36 muestra el promedio de lluvia (*RainRate*) requerido para que no

¹⁹Este gráfico muestra en su eje *x* la hora, en el eje *y* la variable independiente y cada punto del gráfico muestra la medida mínima de esa variable para que no ocurran heladas

²⁰Tablas A.17

²¹Tabla A.18




Figura 3.36: Gráfico de líneas entre *Promedio de Lluvia (RainRate)* y *HeladaCont*




Figura 3.37: Instanciación de las variedades de procesos asociadas con el *activo de dominio de agrometeorología* al *Caso reusable Guerrico*

ocurran heladas. En este caso podemos observar que en todo momento los promedios aumentan, sin mostrar ninguna disminución. Por ejemplo, a las 4 hs son requeridas precipitaciones de 1 mm para que no ocurran heladas, mientras que a las 8 hs se requiere de 1,6 mm. En el Apéndice A²² se muestran las tablas fuente donde se derivaron estos gráficos.

En resumen, los resultados de estos análisis muestran que las variables relacionadas a la temperatura (*Temperatura Máxima* y *Temperatura Mínima*) fueron las de mayor influencia en la temperatura minina para ambas hipótesis. A pesar de que existe una variación en los ciclos de noche y día a lo largo de un periodo de 24 hs, mostraron la mayor correlación. Por otro lado, las variables relacionadas al viento y la lluvia (*Velocidad del Viento*, *Aire Desplazado por el Viento*, *Presencia de Lluvia* y *Promedio de Lluvia*), a pesar de poseer correlaciones casi nulas, mostraron influencia en la ocurrencia de heladas. También se destaca una influencia relevante y positiva de las variables *Punto de Rocío* y *Sensación Térmica*. Por otro lado, las variables que mostraron la mayor influencia negativa fueron *Humedad Promedio* y *Presión Atmosférica*. El resto de variables (*Radiación Solar*, *Energía Solar*, *Máxima Energía Solar* y *Evotranspiración*) tuvieron los resultados más cercanos a 0.

Para registrar lo realizado en este caso reusable en CoVaMaT, y como en la variedad de contenido, no hemos creado nuevas variedades de procesos. Por lo tanto, lo que realizamos fue, en base a la variedad de procesos recuperada del *activo de dominio de agrometeorología* asociamos al *Caso reusable Guerrico* las mismas variedades (Figura 3.37) eliminando las utilizadas para la clasificación ya que sólo hemos realizado análisis de correlaciones y procesamiento por lotes.

Al finalizar estas actividades tenemos información suficiente como para responder la quinta hipótesis, la cual postulaba:

²²Tabla A.19

¿Los factores analizados en el área de Villa Regina poseen la misma influencia en el área de Guerrico para la ocurrencia de heladas?

En primer lugar analizamos el resultado de los análisis de correlación realizados con los conjuntos de datos originales del área de Villa Regina²³ y Guerrico²⁴. Para este análisis utilizamos una función conocida como *porcentaje de cambio* [42, 43] la cual representa el cambio en el valor de una cantidad con respecto a otra previa, en forma porcentual. La misma se define como:

$$\frac{B-A}{A} * 100 \%$$

Donde A representa los valores de Villa Regina y B los valores de Guerrico. De esta forma, la función proporciona el porcentaje de cambio de B con respecto a A .




Figura 3.38: Porcentaje de cambio entre los diferentes métodos de correlación para Villa Regina y Guerrico en el análisis de correlación con los conjuntos de datos originales.

En la Figura 3.38, se presenta un gráfico comparando los tres coeficientes de correlación, para ambas áreas, donde el color verde representa el porcentaje de cambio de Pearson, el color naranja el de Spearman y el color celeste el de Kendall. Un resultado positivo significa que el área de Guerrico obtuvo un resultado del coeficiente para la variable más alto que Villa Regina, dejando entonces una diferencia positiva; cuando es negativo, indica lo contrario, el coeficiente mas alto se había obtenido para el área de Villa Regina. Cuando se aproximan a 0 significa que para ese coeficiente no hubo diferencias en los valores resultantes en las dos áreas. Dicha figura fue basada en base a las Figuras 3.6 y 3.27. En el Apéndice A.5²⁵ se muestra la tabla fuente de donde se derivaron estos gráficos.

En la figura podemos observar que para la *Temperatura Mínima (LowTemp)*, no se observan variaciones significativas, ya que se obtuvo una correlación de 1 en ambos casos. En cuanto a la

²³ Conjunto de Datos Original Regina

²⁴ Conjunto de Datos Original Guerrico

²⁵ Tabla A.20




Figura 3.39: Porcentaje de cambio entre los diferentes métodos de correlación para Villa Regina y Guerrico en el análisis de correlación con los conjuntos de datos dinámicos.

Temperatura Máxima (HiTemp), se registran porcentajes de cambio positivos en los coeficientes de Pearson (0,17%) y Spearman (0,005%), indicando una leve correlación positiva, mientras que el coeficiente de Kendall muestra un ligero cambio negativo (-0,01%). La *Presión Atmosférica (Bar)* presenta porcentajes de cambio positivos en todos los coeficientes, siendo más notable en Pearson (35,2%) y menos en Spearman 22,43% y 22,58% en Kendall, lo que sugiere un cambio moderado con respecto a Villa Regina en este aspecto. El *Punto de Rocío (DewPt)*, la *Evotranspiración (ET)* y la *Humedad Promedio (OutHum)* muestran porcentajes de cambio negativos en todos los coeficientes, siendo más pronunciado en Pearson para el punto de rocío y la evotranspiración. La *Máxima Radiación Solar (Hi SolarRad.)* registra porcentajes de cambio positivos en todos los coeficientes, siendo más significativo en Pearson (13,32%), seguido por Spearman (7,58%) y Kendall (7,53%) con valores más bajos. La *Presencia de Lluvia (Rain)* y el *Promedio de Lluvia (RainRate)* muestran porcentajes de cambio negativos en Pearson (-327,13%), en comparación con las correlaciones de Spearman (23,88%) y Kendall (23,65%). En cuanto a la *Energía Solar (SolarEnergy)* y la *Radiación Solar (SolarRad)*, se observan porcentajes de cambio positivos en los tres coeficientes, indicando que la influencia de la variable fue mas alta para Guerrico. La *Sensación Térmica (WindChill)*, el *Aire Desplazado por el Viento (WindRun)* y la *Velocidad del Viento (WindSpeed)* muestran porcentajes de cambio cercanos a cero o negativos en los coeficientes, mostrando que no hay variaciones significativas de esas variables en ambas zonas.

Podemos observar que en general los coeficientes de correlación de Pearson y Spearman tienden a ser más similares entre sí, y diferentes a Kendall en la mayoría de las variables. Esto se puede deber al volumen de los datos, como hemos enunciado anteriormente.

Considerando ahora los conjuntos de datos dinámicos para las dos áreas, *Conjunto de Datos Dinámico Regina(n)* y *Conjunto de Datos Dinámico Guerrico(n)* con $n = 0$ hasta $n = 138$, en la Figura 3.39 podemos observar nuevamente el porcentaje de cambio de los coeficientes de Pearson, Spearman y Kendall. Dicha figura fue realizada en base a las Figuras 3.11 y 3.32. En

el Apéndice A.5²⁶ se muestra la tabla fuente de donde se derivaron estos gráficos.

Como podemos observar en la figura, la correlación entre las variables de *Temperatura Mínima (LowTemp)* y *Temperatura Máxima (HiTemp)* mostró ligeras disminuciones en Guerrico en comparación con Villa Regina según los coeficientes de correlación. En cuanto a la *Presión Atmosférica (Bar)*, la correlación de Pearson y Spearman indicó un aumento en Guerrico en comparación con Villa Regina (Pearson: 33,29 %, Spearman: 19,12 %), mientras que la correlación de Kendall sugirió una ligera disminución en Guerrico (-1,11 %). Para el *Punto de Rocío (DewPt)*, se observaron disminuciones en Guerrico según Pearson y Spearman (-1,89 % y -10,18 % respectivamente), mientras que Kendall mostró un aumento en Guerrico en relación con Villa Regina del 43,82 %. La *Evotranspiración (ET)* mostró variaciones significativas donde Pearson indicó una fuerte disminución en Guerrico con un coeficiente de -22,62 %, mientras que Spearman y Kendall sugirieron un aumentos en comparación a Villa Regina (Spearman: 8,41 %, Kendall: 58,31 %). En términos de *Máxima Radiación Solar (Hi SolarRad)*, todos los métodos mostraron un aumento, un 3,18 % para Pearson, 12,14 % para Spearman y de 129,19 % para Kendall. La *Humedad Promedio* mostró una disminución en todos los coeficientes de correlación, de un -13,95 % para Pearson, de -11,22 % para Spearman y de -58,84 % para Kendall. La *Presencia de Lluvia (Rain)* mostró una fuerte disminución según Pearson, de un -69,62 %, mientras que Spearman y Kendall sugirieron un aumento del 53,33 % y del 55,15 % respectivamente. El *Promedio de Lluvia (RainRate)* también mostró cambios significativos entre los diferentes coeficientes de correlación, con Pearson indicando una fuerte disminución del -36,78 %, mientras que Spearman y Kendall sugirieron un aumento del 82,01 % y del 119,02 % respectivamente. En cuanto a la *Energía Solar (SolarEnergy)* y la *Radiación Solar (SolarRad)*, todos los coeficientes de correlación mostraron un aumento. La *Sensación Térmica (WindChill)* mostró pocas variaciones excepto por el 36,2 % de Kendall. Finalmente en cuanto a la *Cantidad de aire Desplazado por el Viento* y la *Velocidad del Viento* se obtuvieron aumentos en todos coeficientes de correlación, siendo mas altos para Kendall, luego Spearman y por ultimo Pearson.

En resumen, los resultados revelan una variabilidad en la dirección y magnitud de la relación entre Guerrico y Villa Regina para diferentes variables climáticas, con algunos mostrando una tendencia consistente entre los métodos de correlación y otros mostrando discrepancias significativas. La interpretación precisa puede depender de las características específicas de cada variable y del contexto climático de las dos zonas. En términos generales, los métodos de correlación que mostraron mayores similitudes en sus resultados fueron Pearson y Spearman. Estos dos métodos suelen estar más alineados en la dirección y magnitud de la relación entre las variables. Por otro lado, el método que mostró resultados más diferentes fue Kendall.

Si comparamos ahora los porcentajes de cambio observados para los datos originales (Figura 3.38) y los datos dinámicos (Figura 3.39) vemos que con los datos originales los coeficientes se comportaron con menos variaciones que en el segundo caso, donde en general casi todas las variables poseen diferencias, y como vimos, algunas muy significativas. Sin embargo, se evidencia una notable coherencia en las características térmicas entre las dos áreas investigadas. Tanto las temperaturas máximas como las mínimas exhiben una influencia que se mantiene consistente en ambos lugares. Este hallazgo sugiere una homogeneidad en los patrones térmicos generales entre Villa Regina y Guerrico. Las variables asociadas al viento muestran un comportamiento similar en ambas ubicaciones, lo que sugiere una estabilidad también de estos fenómenos. En lo que respecta a las variables solares, se observa una variabilidad más marcada. Aunque la radiación solar y la energía solar muestran cierta consistencia entre las dos áreas, los cambios en estos parámetros sugieren que influencia del sol puede variar significativamente entre Villa Regina y Guerrico. Las diferencias en las variables relacionadas con la humedad y la lluvia son evidentes entre las dos ubicaciones. Los patrones de humedad y precipitación parecen ser bastante diferentes, lo que sugiere que los factores locales pueden desempeñar un papel crucial en la distribución y la cantidad de precipitación en cada área. La presión atmosférica es otro factor

²⁶Tabla A.21




Figura 3.40: Porcentaje de cambio de las variables relacionadas con el viento y la lluvia en el periodo de 24 horas para que no ocurran heladas.

que muestra diferencias significativas entre las dos áreas. La influencia de la presión atmosférica es notablemente mayor en Guerrico en comparación con Villa Regina. Aunque pudimos observar cierta uniformidad en algunas variables climáticas entre Villa Regina y Guerrico, otras muestran variaciones sustanciales. Estas diferencias resaltan la importancia de considerar las características geográficas y climáticas específicas de cada área al analizar el clima y sus efectos.

Como en la hipótesis $H1$ se hizo hincapié en las variables relacionadas con el viento y la lluvia, también analizamos el comportamiento de estas características climáticas en ambas áreas. La Figura 3.40 muestra los porcentajes de cambio de las variables asociadas al viento y la lluvia para que no ocurran heladas. Los datos utilizados para esta parte del análisis se encuentran en el Apéndice A.5²⁷

Los datos de *Velocidad del Viento (WindSpeed)*, en el gráfico 1, indican la diferencia porcentual necesaria en Guerrico en comparación con Villa Regina para evitar heladas. A lo largo del día, se observan variaciones significativas en esta diferencia, lo que sugiere la influencia dinámica del viento en la prevención de heladas. Por ejemplo, a las 0 hs, se requiere un aumento del 11,03% en la velocidad del viento en Guerrico con respecto a Villa Regina para evitar la formación de heladas; mientras que a las 12:00 hs (su pico máximo) se requieren velocidades un 111,31% mayores en Guerrico.

Los datos del *Aire Desplazado por el Viento (WindRun)*, en el gráfico 2, muestran una correlación directa con la velocidad del viento, donde un aumento en ésta refleja un mayor volumen de aire desplazado entre Guerrico y Villa Regina. Esto sugiere que en Guerrico se necesita un volumen de aire desplazado por el viento mayor que en Villa Regina para prevenir las heladas. Si lo observamos con mayor detalle, podemos ver que a lo largo del día los valores los valores tienden a ser mayores, a pesar de sus fluctuaciones. Por ejemplo, 1 hora antes requiere un 37,21% más de aire desplazado por el viento, mientras que 11 horas antes son requeridos 88,16% más de aire desplazado por el viento para evitar la ocurrencia de heladas.

En el gráfico 3 mostramos la variable *Promedio de Lluvia (RainRate)* donde vemos una tendencia similar a las otras dos variables. Los promedios de lluvias necesarios para que no ocurran heladas en Guerrico necesitan ser mayores. Por ejemplo, entre 6 y 12 hs antes son requeridos promedios de lluvia hasta 60% mayores en Guerrico para evitar las heladas. Si bien es cierto que los promedios fluctúan entre 0% a las 0 horas antes o 11,11% unas 18 horas antes, estos valores tienden a ser superiores en esta área.

²⁷Tabla A.22

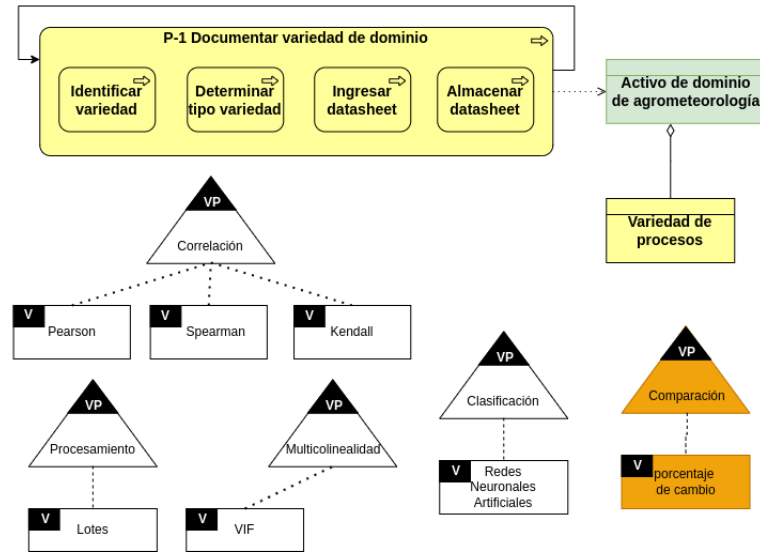


Figura 3.41: Proceso P-1 donde documentamos la nueva variedad de procesos para la comparación como *activo de dominio de agrometeorología* en CoVaMaT

Para dejar registrado lo realizado para la hipótesis $H5$ debemos crear dos nuevos activos en CoVaMat. Por un lado, como no existía en la variedad de procesos un método que compare resultados de dos análisis en dos contextos diferentes, agregamos dicho método como parte del *activo de dominio de agrometeorología*, en la *variedad de procesos*. Como podemos observar en la Figura 3.19, llamamos al proceso P-1 para agregar este nuevo punto variante al que llamamos *comparación* con la variante de la función elegida llamada *porcentaje de cambio* (en naranja).

Proceso de Big Data: Actividades de Visualización y Acceso

Nuevamente, como en el Caso de Dominio 1, estas actividades quedan pendientes de realización para trabajos futuros.

Paso 4: Verificación de las Hipótesis

Los resultados obtenidos en los análisis previos han podido validar la primera hipótesis ($H1$) la cual postulaba: *¿Las variables climáticas relacionadas con el viento o lluvia tienen influencia en la ocurrencia de heladas?*. Se constata que la presencia de dichos fenómenos climáticos incide directamente en la ocurrencia de heladas.

Para la segunda hipótesis ($H2$) que postulaba: *¿Hay factores climáticos con mayor influencia en la presencia de heladas en momentos previos a su ocurrencia?*. Las variables que se destacaron fueron *Temperatura Máxima*, *Temperatura Mínima*, *Humedad Promedio*, *Punto de Rocío*, *Sensación Térmica* y *Presión Atmosférica*. Fueron descartadas todas las variables cuyos valores promedio de correlación fueron cercanos a 0. Por otro lado, los resultados también revelaron que el avance del tiempo influye en las magnitudes de las variables relacionadas con el viento y la lluvia, dado que deben aumentar para que no ocurran heladas. Así se verificó que una mayor velocidad del viento, mayor volumen de aire desplazado por el viento y/o mayores precipitaciones a lo largo del tiempo afectan la ocurrencia de heladas, validando así la hipótesis.

Para evaluar la quinta hipótesis ($H5$) que postulaba *¿Los factores analizados en el área de Villa Regina, poseen la misma influencia en el área de Guerrico para la ocurrencia de heladas?* realizamos varias comparaciones con resultados variados. En ellas notamos la importancia de las mismas variables en la prevención de heladas en ambas áreas. Sin embargo vimos que hay factores que varían en cuanto a su influencia marcando diferencias significativas. Pudimos observar

algunas diferencias como:

- Guerrico tiene una *temperatura mínima más baja* que Villa Regina.
- Guerrico tiene una *menor influencia* de la *temperatura máxima, punto de rocío, evotranspiración y humedad* en la ocurrencia de heladas que Villa Regina.
- Guerrico tiene una *mayor influencia* de la *presión atmosférica, energía solar, radiación solar, velocidad del viento, cantidad de aire desplazado por el viento, y lluvia* en la ocurrencia de heladas que Villa Regina.
- Guerrico requiere *velocidades de viento entre 11,03 % y 111,31 % superiores* a Villa Regina para que no ocurran heladas.
- Guerrico requiere de *volúmenes de aire desplazado por el viento entre 11,2 % y 89,41 % superiores* a Villa Regina para que no ocurran heladas.
- Guerrico requiere de *lluvias hasta 63,64 % mas intensas* que Villa Regina para que no ocurran heladas.

Todas las diferencias antes mencionadas implican que el área de Guerrico posee condiciones climáticas distintas y, en algunos aspectos, más extremas en comparación con Villa Regina. Estas diferencias sugieren que Guerrico puede experimentar temperaturas más bajas, una influencia climática más fuerte de ciertos factores como la presión atmosférica, la radiación solar, la velocidad del viento y la lluvia, y requerir condiciones específicas de estos elementos para evitar la ocurrencia de heladas.

Paso 5: Reformulación o Terminación

Luego, para finalizar documentación del *caso reusable Guerrico*, instanciamos las variedades que faltan, por ejemplo la definida en *H5*. En la Figura 3.42 podemos observar que desde el *activo de dominio de agrometeorología* instanciamos todos los datasheets creados para los activos de este dominio resultando en las aplicadas al caso.




Figura 3.42: *Caso reusable Guerrico* creado a partir de las instanciaciones del *activo de dominio de agrometeorología*

3.2. Resumen del capítulo

En este capítulo hemos descripto los pasos realizados del enfoque top-down para el desarrollo de dos casos dentro del dominio de agrometeorología. Ambos casos responden a una variación contextual por zona, en donde se analizaron hipótesis aplicables a la zona de Villa Regina y

Guerrico. Además, en cada actividad se describió la forma en que se creó el activo de dominio en agrometeorología, su instanciación en el caso de dominio de Villa Regina y por último una nueva instanciación en el caso reusable de Guerrico. Todo esto fue almacenado en la base de conocimiento CoVaMaT.

Capítulo 4

Conclusiones y Trabajo Futuro

En este capítulo se describen las conclusiones y contribuciones más importantes de este trabajo de tesis. En primer lugar, se resumen los puntos principales de estudio a través de los objetivos presentados en el primer capítulo y de las tareas que se llevaron a cabo para alcanzar los mismos. Luego, se describen las conclusiones especificando las contribuciones teóricas y prácticas desarrolladas en este trabajo. Por último, se discuten las limitaciones y los trabajos futuros.

4.1. Resumen del Trabajo

En este trabajo hemos realizado el desarrollo de casos de dominio como aplicaciones de sistemas de big data en el campo de la agrometeorología, centrándonos en la detección y predicción de heladas tardías en el Alto Valle de Río Negro y Neuquén. Para el desarrollo de los casos hemos aplicado un enfoque top-down que se basa en la detección de variedades para la creación de aplicaciones flexibles y adaptables.

En el Capítulo 2 analizamos los conceptos fundamentales de los Sistemas de Big Data y los estándares internacionales existentes. También exploramos el ciclo de vida típico dentro de estos sistemas, desde la evaluación del caso de negocio hasta la visualización y utilización de los datos resultantes. Luego describimos el dominio específico de la agrometeorología, destacando su importancia en la gestión agrícola y la toma de decisiones. A continuación nos centramos específicamente en el análisis de la influencia de variables climáticas con un enfoque particular en el problema de las heladas tardías y su impacto en las cosechas de la región. Realizamos un análisis de varios trabajos relacionados en la literatura sobre el mismo dominio de aplicación en donde se emplearon diferentes métodos de aprendizaje automático destacándose el uso de redes neuronales artificiales. Por último, describimos los trabajos previos del grupo de investigación en la cual esta enmarcada esta tesis, que utiliza cuatro variedades para guiar los desarrollos. Presentamos los enfoques top-down y bottom-up para la construcción de casos dentro de dominios específicos y la herramienta de soporte CoVaMaT que permite la documentación de activos para fomentar el reuso.

En el Capítulo 3 describimos el desarrollo de dos casos dentro del dominio de la agrometeorología, mediante la aplicación de un enfoque top-down. El contexto estuvo definido específicamente por la zona de aplicación, ya que nos abocamos a las zonas de Villa Regina y de Guerrico. Así, en el primer caso de dominio de Villa Regina definimos cuatro hipótesis que buscaban hallar la relación de diferentes variables climáticas con la ocurrencia de heladas para la realización de un modelo que permita predecirlas antes de que ocurran. Durante este primer caso, se crearon varios activos de dominio en CoVaMaT que luego fueron utilizados por el caso de dominio de Guerrico. En este último, los activos documentados fueron reusados para la ejecución de las dos mismas primeras hipótesis, reusando los activos de Villa Regina. Se agregó una tercera hipótesis para comparar los resultados de acuerdo a la variedad de contexto planteada.

A continuación, describimos, para cada objetivo específico definido en el Capítulo 1, el trabajo

realizado para lograrlo:

- Para la realización del primer objetivo, el cual planteaba *modelar el contexto para el análisis y definir hipótesis*, en el Capítulo 2 (secciones 2.1, 2.2 y 2.5) profundizamos en las nociones básicas y específicas en la construcción de sistemas de big data en general, los estándares y los trabajos relacionados en el dominio de la agrometeorología respectivamente. Esto incluyó el análisis y clasificación de modelos de análisis empleados, junto con las variables utilizadas, las zonas investigadas y los resultados que obtuvieron. Esta información nos proporcionó un panorama de las técnicas más usadas para comprender las variables climáticas y los diferentes métodos utilizados para la predicción de heladas. Al mismo tiempo, nos guió en la creación del activo de dominio de agrometeorología para el cual definimos dos variedades de contexto, uno para la zona Villa Regina (sección 3.1.1 del Capítulo 3) y el otro para la zona de Guerrico (sección 3.1.2 del Capítulo 3). A partir de allí, planteamos cuatro hipótesis para el caso de dominio de Villa Regina y tres para el caso de Guerrico. Estas hipótesis fueron definidas acorde a los trabajos en la literatura y los requerimientos de los usuarios expertos del INTA. También documentamos las variedades de contexto definidas que se almacenaron empleando la herramienta CoVaMaT.
- Para la realización del segundo objetivo, el cual planteaba *instanciar el modelo de contexto*, en el Capítulo 3 describimos detalladamente la aplicación el enfoque top-down desarrollado en trabajos previos del grupo de investigación. Para ello, realizamos algunas de las actividades incluidas en el proceso de big data donde primero recolectamos datos de dos estaciones meteorológicas, una en Villa Regina y otra de Guerrico, la cuales sumaban, entre ambas, más de 1 millón de registros. Luego, mediante la actividad de preparación se transformaron dichas fuentes para que estén aptas para el análisis que llevaríamos a cabo. Esto incluyó tareas como la eliminación de registros, eliminación de variables, imputar datos faltantes, agregar variables nuevas, entre otras (secciones 3.1.1 y 3.1.2 del Capítulo 3). Además, identificamos y almacenamos la variedad hallada que, en este caso, fue la variedad de las fuentes y contenido, haciendo uso de la herramienta CoVaMaT.
- Con respecto al tercer objetivo, el cual planteaba *verificar las hipótesis*, continuamos la aplicación del resto de las actividades del proceso de big data. Empleamos varias técnicas de análisis de datos (secciones 3.1.1 y 3.1.2 del Capítulo 3), estudiamos las estadísticas básicas de las diferentes variables de las estaciones meteorológicas de Villa Regina y Guerrico, analizamos la relación entre las variables a través de diferentes coeficientes de correlación en varios análisis con series temporales, entre otras tareas. Además, para el caso de Villa Regina, exploramos la multicolinealidad entre las variables predictoras y la variable objetivo para luego entrenar una red neuronal artificial que sea capaz de predecir heladas en periodos de hasta 24 horas. Por último, comparamos los resultados que obtuvimos en ambas áreas estudiadas. Hicimos varios hallazgos, como que la temperatura en momentos previos es el factor climático más determinante para predecir heladas, que no es necesario un gran número de variables para entrenar un modelo eficiente, que existe variabilidad en las variables climáticas de ambas áreas estudiadas, entre otras. El resultado de estos análisis nos permitió validar las hipótesis planteadas. Además, identificamos y almacenamos la variedad hallada que, en este caso, fue la variedad de proceso, haciendo uso de la herramienta CoVaMaT.

En conclusión, en este trabajo hemos mostrado la importancia del enfoque top-down en el desarrollo de aplicaciones de big data para la agrometeorología, específicamente en la detección de heladas tardías en el Alto Valle de Río Negro y Neuquén. Hemos identificado patrones climáticos relevantes y validado hipótesis clave mediante un análisis detallado de datos. La herramienta CoVaMaT ha facilitado la gestión de variedades, sentando las bases para futuras investigaciones.

Este trabajo ofrece nuevas perspectivas para la gestión agrícola y la toma de decisiones en la región, y marca el camino para futuras investigaciones en el campo de la agrometeorología.

4.2. Limitaciones y Trabajos Futuros

Podemos identificar ciertas limitaciones que han impactado en la extensión del trabajo desarrollado. Así, podemos identificar áreas prometedoras para futuras tareas que permitan ampliar y enriquecer los resultados presentados. A continuación, detallamos las limitaciones encontradas durante este trabajo y proponemos direcciones para investigaciones futuras.

1. *Hipótesis 3 y 4 para la estación meteorológica de Guerrico:* Debido a la extensión de esta tesis, se optó por no llevar a cabo el proceso de analítica que involucraba el análisis de multicolinealidad y el entrenamiento de una red neuronal artificial para el conjunto de datos de Guerrico. Estas hipótesis específicas quedaron pendientes para trabajos futuros. El análisis de multicolinealidad es crucial para garantizar la precisión de los modelos predictivos, especialmente en conjuntos de datos complejos como los meteorológicos. Asimismo, el entrenamiento de una red neuronal artificial para el conjunto de datos de Guerrico, puede ayudar a comprender las variables meteorológicas en ese área y a predecir los eventos de heladas con mayor precisión.
2. *Contextualizar una nueva zona de estudio:* El conjunto de datos proporcionado por el INTA incluye tres estaciones meteorológicas: Villa Regina, Guerrico y Cinco Saltos. En esta tesis, solo se analizaron las dos primeras, quedando pendiente Cinco Saltos. Explorar este conjunto de datos adicional permitiría una comparación más completa y robusta entre las diferentes zonas, ofreciendo una visión más completa de los patrones climáticos regionales.
3. *Visualización y Acceso:* Esta actividad fue limitada en esta tesis para los casos de estudio analizados y para una representación básica de los resultados. La visualización adecuada de los datos es fundamental para interpretar patrones y tendencias, así como para comunicar resultados de manera efectiva. Incluir esta fase en futuros trabajos aportará a la comprensión general de los datos y facilitaría la toma de decisiones.
4. *Recursos computacionales:* El entrenamiento de redes neuronales artificiales puede ser intensivo en recursos computacionales, especialmente con conjuntos de datos grandes o configuraciones complejas como el uso de muchas unidades ocultas o la validación cruzada con múltiples pliegues. La falta de recursos adecuados puede limitar significativamente la capacidad para realizar análisis profundos y exhaustivos. En futuros trabajos, sería beneficioso contar con la infraestructura necesaria para explorar completamente estas técnicas avanzadas de modelado o buscar una forma más optimizada para realizar los entrenamientos.

Apéndice A

Apéndice

A.1. Resultados del análisis de correlación Villa Regina.

La Tabla A.1 muestra los coeficientes de la correlación de Pearson para el **Conjunto de Datos Dinámico Villa Regina** desde $n = 0$ hasta $n = 138$, la Tabla A.2 muestra los coeficientes de la correlación de Spearman para el **Conjunto de Datos Dinámico Villa Regina** desde $n = 0$ hasta $n = 138$ y, por último, la Tabla A.3 muestra los coeficientes de la correlación de Kendall para el **Conjunto de Datos Dinámico Villa Regina** desde $n = 0$ hasta $n = 138$. Por otra parte, la Tabla A.4 muestra el promedio de los valores para cada variable por cada uno de los métodos de correlación y, el último registro, muestra el promedio que tuvo cada variable al combinar los resultados de cada método.

Hora	HiTemp	LowTemp	OutHum	DewPt.	WindSpeed	WindRun	WindChill	Bar	Rain	RainRate	SolarRad.	SolarEnergy	Hi SolarRad.	ET
0	0.997482	1.0	-0.662058	0.454388	0.474907	0.475288	0.992683	-0.437299	-0.002051	0.004668	0.443547	0.443548	0.456533	0.219513
1	0.955848	0.952969	-0.61606	0.453315	0.48905	0.489489	0.947201	-0.421531	-0.002442	0.00497	0.553129	0.553129	0.566392	0.234115
2	0.867395	0.863359	-0.535584	0.435408	0.469794	0.470225	0.856777	-0.400548	-0.001798	0.005272	0.610542	0.610542	0.622746	0.231917
3	0.748597	0.743691	-0.433901	0.403912	0.424293	0.424687	0.737196	-0.377913	-0.00101	0.0058	0.617062	0.617062	0.626525	0.214794
4	0.612523	0.607325	-0.321846	0.362078	0.36016	0.360496	0.601654	-0.356784	-0.001414	0.00483	0.575933	0.575932	0.581674	0.18537
5	0.471228	0.466277	-0.208934	0.313806	0.286113	0.286378	0.461929	-0.339361	-0.002143	0.004138	0.493992	0.493991	0.49655	0.147288
6	0.33475	0.330545	-0.102549	0.263758	0.209016	0.209202	0.327932	-0.326243	-0.003042	0.003553	0.383107	0.383106	0.383876	0.10514
7	0.211125	0.208085	-0.008778	0.216296	0.133934	0.134045	0.207522	-0.316734	-0.004087	0.002725	0.258271	0.25827	0.258626	0.063667
8	0.106139	0.104568	0.068101	0.174831	0.064689	0.064728	0.106266	-0.309654	-0.004963	0.00225	0.136277	0.136276	0.136241	0.027064
9	0.024464	0.024434	0.125102	0.142667	0.005284	0.005262	0.028332	-0.303623	-0.005701	0.001552	0.02867	0.028668	0.027883	-0.002821
10	-0.033376	-0.032172	0.163644	0.12207	-0.04356	-0.043626	-0.002181	-0.29753	-0.006214	0.000984	-0.060734	-0.060736	-0.062393	-0.026148
11	-0.069521	-0.067493	0.184946	0.111214	-0.082395	-0.082494	-0.0596	-0.290856	-0.006183	0.00061	-0.13196	-0.131961	-0.13479	-0.043621
12	-0.085992	-0.083681	0.190667	0.108668	-0.114046	-0.114171	-0.073806	-0.283816	-0.005233	0.000424	-0.190227	-0.190227	-0.194291	-0.057193
13	-0.084334	-0.082233	0.181857	0.112275	-0.140415	-0.140563	-0.070236	-0.277435	-0.003813	0.000464	-0.239268	-0.239268	-0.244498	-0.068119
14	-0.06388	-0.062405	0.158102	0.120193	-0.161013	-0.16118	-0.048102	-0.273186	-0.002656	0.000314	-0.2824	-0.2824	-0.288578	-0.076431
15	-0.022922	-0.022302	0.118257	0.131622	-0.172865	-0.17305	-0.005728	-0.272699	-0.002128	0.000277	-0.318234	-0.318233	-0.325018	-0.081595
16	0.039655	0.039365	0.061743	0.146122	-0.172962	-0.173157	0.058068	-0.276825	-0.001684	0.000204	-0.342911	-0.34291	-0.349751	-0.081579
17	0.123001	0.122096	-0.010566	0.16349	-0.155134	-0.155324	0.14229	-0.285461	-0.001066	0.000174	-0.349333	-0.349333	-0.355383	-0.073587
18	0.222999	0.221808	-0.095356	0.182845	-0.118461	-0.118632	0.242646	-0.297324	-0.001141	-0.000149	-0.32824	-0.32824	-0.332134	-0.055462
19	0.333637	0.332404	-0.187404	0.204732	-0.064434	-0.064573	0.352975	-0.309922	-0.000516	0.000115	-0.271868	-0.271867	-0.271468	-0.02629
20	0.447191	0.446113	-0.280421	0.228409	0.004132	0.004048	0.46529	-0.320161	-0.001009	0.000541	-0.176332	-0.176331	-0.170795	0.013158
21	0.554032	0.553005	-0.366216	0.253511	0.081867	0.081847	0.569898	-0.324979	-0.0014	0.001188	-0.044311	-0.044311	-0.035275	0.059584
22	0.643268	0.642138	-0.435319	0.27793	0.160389	0.160447	0.655882	-0.321914	-0.00174	0.002062	0.110644	0.110645	0.121634	0.106851
23	0.703545	0.702072	-0.477749	0.299513	0.23157	0.231713	0.712016	-0.309847	-0.001583	0.002801	0.270775	0.270775	0.282443	0.149128

Tabla A.1: Resultados de la correlación de Pearson en un periodo de 24hs (Villa Regina).

La Tabla A.5 muestra las velocidades mínimas de viento necesarias para que no ocurran heladas a lo largo de un periodo de 24 horas.

La Tabla A.6 muestra la mínima cantidad de aire desplazado por el viento necesaria para que no ocurran heladas a lo largo de un periodo de 24 horas.

La Tabla A.6 muestra el promedio de lluvia mínimo necesaria para que no ocurran heladas a lo largo de un periodo de 24 horas.

Hora	HiTemp	LowTemp	OutHum	DewPt.	WindSpeed	WindRun	WindChill	Bar	Rain	RainRate	SolarRad.	SolarEnergy	Hi SolarRad.	ET
0	0.999014	1.0	-0.671773	0.445417	0.532402	0.532402	0.993032	-0.424631	-0.015289	-0.008507	0.483167	0.483167	0.486321	0.130689
1	0.953617	0.952258	-0.623462	0.450383	0.560337	0.560337	0.943544	-0.409645	-0.01501	-0.010039	0.61003	0.61003	0.612203	0.130662
2	0.857638	0.855095	-0.538786	0.436108	0.540677	0.540677	0.845505	-0.389679	-0.013011	-0.009974	0.673978	0.673978	0.675632	0.119364
3	0.731507	0.728149	-0.433479	0.406239	0.486849	0.486849	0.71882	-0.368132	-0.011751	-0.010664	0.673942	0.673942	0.675093	0.100625
4	0.590749	0.587078	-0.319773	0.366139	0.410668	0.410668	0.578911	-0.347909	-0.011415	-0.011352	0.621319	0.621319	0.621636	0.077442
5	0.447406	0.443856	-0.207061	0.320383	0.322815	0.322815	0.437383	-0.331122	-0.011179	-0.012446	0.528739	0.528739	0.528395	0.05244
6	0.310752	0.307746	-0.10206	0.273086	0.231757	0.231757	0.303413	-0.318318	-0.012746	-0.01344	0.409733	0.409733	0.409146	0.027662
7	0.187906	0.185827	-0.010215	0.227412	0.14294	0.14294	0.183922	-0.308752	-0.013435	-0.013838	0.275009	0.275009	0.274695	0.004439
8	0.084228	0.083356	0.064827	0.186451	0.061293	0.061293	0.084123	-0.301276	-0.014788	-0.014282	0.134428	0.134428	0.134442	-0.015296
9	0.003197	0.003571	0.12077	0.153654	-0.008356	-0.008356	0.007039	-0.294612	-0.015639	-0.014056	-0.002277	-0.002277	-0.002112	-0.02952
10	-0.054984	-0.053619	0.159151	0.131057	-0.064224	-0.064224	-0.047543	-0.287861	-0.01601	-0.01332	-0.12578	-0.12578	-0.125558	-0.037608
11	-0.092034	-0.089981	0.181003	0.117134	-0.107169	-0.107169	-0.081484	-0.280741	-0.015907	-0.012509	-0.229641	-0.229641	-0.229537	-0.040222
12	-0.1093	-0.106955	0.187739	0.111087	-0.141319	-0.141319	-0.095925	-0.273649	-0.015114	-0.010559	-0.316649	-0.316649	-0.316678	-0.03869
13	-0.107835	-0.105557	0.179541	0.110684	-0.169575	-0.169575	-0.091901	-0.267648	-0.013903	-0.007697	-0.38845	-0.38845	-0.38863	-0.033812
14	-0.087195	-0.085342	0.156097	0.114499	-0.191006	-0.191006	-0.069018	-0.264177	-0.012615	-0.00547	-0.444763	-0.444763	-0.445005	-0.026812
15	-0.046536	-0.045373	0.116523	0.12312	-0.202791	-0.202791	-0.026568	-0.264665	-0.012118	-0.004017	-0.481604	-0.481604	-0.481803	-0.018264
16	0.015124	0.01542	0.060461	0.135115	-0.201254	-0.201254	0.036444	-0.269763	-0.011738	-0.003708	-0.492795	-0.492795	-0.492795	-0.00909
17	0.09748	0.097098	-0.011566	0.151054	-0.180714	-0.180714	0.119521	-0.279318	-0.010502	-0.00255	-0.469871	-0.469871	-0.469758	0.001847
18	0.197159	0.196438	-0.096544	0.170306	-0.140665	-0.140665	0.219212	-0.292014	-0.009604	-0.001923	-0.409576	-0.409576	-0.409077	0.014189
19	0.30837	0.30767	-0.189173	0.192807	-0.081847	-0.081847	0.329649	-0.305333	-0.008606	-0.001614	-0.314295	-0.314295	-0.312849	0.028042
20	0.423745	0.423297	-0.283031	0.217545	-0.007467	-0.007467	0.443223	-0.316077	-0.009286	-0.002929	-0.188427	-0.188427	-0.185642	0.042698
21	0.534194	0.533944	-0.369756	0.244103	0.077556	0.077556	0.55079	-0.321277	-0.009954	-0.004528	-0.037546	-0.037546	-0.03375	0.057543
22	0.628638	0.628315	-0.439815	0.270651	0.165037	0.165037	0.641254	-0.318484	-0.010706	-0.006221	0.129676	0.129676	0.133857	0.071386
23	0.693959	0.693223	-0.483251	0.295092	0.247246	0.247246	0.701676	-0.306611	-0.010625	-0.007081	0.302189	0.302189	0.305906	0.084157

Tabla A.2: Resultados de la correlación de Spearman en un periodo de 24hs (Villa Regina).

Hora	HiTemp	LowTemp	OutHum	DewPt.	WindSpeed	WindRun	WindChill	Bar	Rain	RainRate	SolarRad.	SolarEnergy	Hi SolarRad.	ET
0	0.981189	1.0	-0.485804	0.314587	0.399874	0.399874	0.948424	-0.29094	-0.012447	-0.006904	0.356726	0.356726	0.359745	0.106721
1	0.831281	0.829587	-0.443223	0.316737	0.420735	0.420735	0.809138	-0.280116	-0.01222	-0.008157	0.462913	0.462913	0.465602	0.10728
2	0.687273	0.68544	-0.37484	0.304127	0.404944	0.404944	0.6712	-0.265906	-0.010594	-0.008109	0.522558	0.522558	0.524932	0.097888
3	0.554286	0.552278	-0.2963	0.281441	0.362969	0.362969	0.541491	-0.250802	-0.009568	-0.008673	0.523097	0.523097	0.52462	0.082112
4	0.431459	0.429436	-0.216	0.252346	0.304783	0.304783	0.421218	-0.236771	-0.009296	-0.009237	0.476096	0.476096	0.476454	0.062871
5	0.319422	0.317542	-0.138964	0.219944	0.238797	0.238797	0.311421	-0.225134	-0.009604	-0.010133	0.398788	0.398788	0.39843	0.042421
6	0.219499	0.217953	-0.068396	0.186976	0.171198	0.171198	0.213767	-0.216094	-0.010388	-0.010951	0.30518	0.30518	0.304635	0.022381
7	0.13316	0.132147	-0.00712	0.155519	0.105715	0.105715	0.129864	-0.209119	-0.010955	-0.01128	0.20331	0.20331	0.203006	0.003736
8	0.061815	0.061489	0.042789	0.127453	0.045714	0.045714	0.061171	-0.203536	-0.012061	-0.011641	0.099233	0.099233	0.099204	-0.012047
9	0.00661	0.006997	0.079929	0.104966	-0.005403	-0.005403	0.008605	-0.198569	-0.012754	-0.011452	-0.001194	-0.001194	-0.001083	-0.023398
10	-0.032901	-0.031961	0.105323	0.08931	-0.04637	-0.04637	-0.028508	-0.193636	-0.01306	-0.010853	-0.091797	-0.091797	-0.091617	-0.029833
11	-0.058085	-0.056773	0.119683	0.079514	-0.077807	-0.077807	-0.0516	-0.188574	-0.012978	-0.010191	-0.167985	-0.167985	-0.167871	-0.031898
12	-0.069896	-0.068446	0.123948	0.075105	-0.102732	-0.102732	-0.061484	-0.183633	-0.01233	-0.008599	-0.23198	-0.23198	-0.231935	-0.030646
13	-0.069026	-0.067662	0.118204	0.074604	-0.123283	-0.123283	-0.058852	-0.179511	-0.01134	-0.006264	-0.284984	-0.284984	-0.285037	-0.026713
14	-0.055328	-0.054256	0.102353	0.077332	-0.138932	-0.138932	-0.043567	-0.177161	-0.010292	-0.004451	-0.326924	-0.326924	-0.327017	-0.021081
15	-0.02842	-0.027784	0.075852	0.082701	-0.147632	-0.147632	-0.015339	-0.177547	-0.009889	-0.003268	-0.354818	-0.354818	-0.354873	-0.014221
16	0.012443	0.012543	0.038517	0.090774	-0.146688	-0.146688	0.026558	-0.181128	-0.009581	-0.003017	-0.364145	-0.364145	-0.364137	-0.006883
17	0.067253	0.066935	-0.009282	0.10155	-0.131877	-0.131877	0.082041	-0.187795	-0.008572	-0.002072	-0.348767	-0.348767	-0.348619	0.001811
18	0.134274	0.133728	-0.065646	0.114606	-0.102777	-0.102777	0.149322	-0.196643	-0.00784	-0.001561	-0.304572	-0.304572	-0.304095	0.011575
19	0.210492	0.209936	-0.127421	0.129946	-0.059842	-0.059842	0.225384	-0.205946	-0.007024	-0.001308	-0.233056	-0.233056	-0.231764	0.02253
20	0.29212	0.29173	-0.190929	0.146925	-0.00539	-0.00539	0.306305	-0.213481	-0.00758	-0.00238	-0.138679	-0.138679	-0.136373	0.034145
21	0.374383	0.374165	-0.251116	0.165318	0.05691	0.05691	0.387209	-0.21714	-0.008127	-0.003686	-0.027111	-0.027111	-0.024199	0.045957
22	0.450491	0.450292	-0.301524	0.183888	0.121062	0.121062	0.461096	-0.215197	-0.008742	-0.005069	0.094673	0.094673	0.097793	0.057073
23	0.509158	0.508606	-0.334138	0.201198	0.181481	0.181481	0.516266	-0.206936	-0.008673	-0.005767	0.220134	0.220134	0.223116	0.067526

Tabla A.3: Resultados de la correlación de Kendall en un periodo de 24hs (Villa Regina).

	HiTemp	LowTemp	OutHum	DewPt.	WindSpeed	WindRun	WindChill	Bar	Rain	RainRate	SolarRad.	SolarEnergy	Hi SolarRad.	ET
Pearson	0.334869	0.333749	-0.14543	0.236794	0.090413	0.090462	0.340954	-0.322152	-0.002709	0.002069	0.072755	0.072755	0.074865	0.048531
Spearman	0.315283	0.314813	-0.148068	0.235417	0.095133	0.095133	0.321876	-0.314237	-0.012565	-0.008447	0.039189	0.039189	0.040168	0.028911
Kendall	0.248456	0.248913	-0.104338	0.161536	0.071894	0.071894	0.250464	-0.212555	-0.010246	-0.006876	0.032779	0.032779	0.033705	0.023721
Promedio General	0.299536	0.299158	-0.132612	0.211249	0.085813	0.08583	0.304431	-0.282981	-0.008507	-0.004418	0.048241	0.048241	0.049579	0.033721

Tabla A.4: Promedios parciales y generales de las correlaciones de Pearson, Spearman y Kendall (Villa Regina).

Hora	WindSpeed	Hora	WindSpeed	Hora	WindSpeed	Hora	WindSpeed
1	17.7	7	24.1	13	30.6	19	32.2
2	17.7	8	24.1	14	32.2	20	32.2
3	17.7	9	27.4	15	32.2	21	32.2
4	17.7	10	29.0	16	32.2	22	32.2
5	20.9	11	29.0	17	32.2	23	29.0
6	24.1	12	27.4	18	32.2	24	29.0

Tabla A.5: Tabla de valores mínimos de *Velocidad del Viento (WindSpeed)* para que no ocurran heladas (Villa Regina).

Hora	WindRun	Hora	WindRun	Hora	WindRun	Hora	WindRun
1	2.95	7	4.02	13	5.10	19	5.36
2	2.95	8	4.02	14	5.36	20	5.36
3	2.95	9	4.56	15	5.36	21	5.36
4	2.95	10	4.83	16	5.36	22	5.36
5	3.49	11	4.83	17	5.36	23	4.83
6	4.02	12	4.56	18	5.36	24	4.83

Tabla A.6: Tabla de valores mínimos de *Aire Desplazado por el Viento (WindRun)* para que no ocurran heladas (Villa Regina).

Hora	RainRate	Hora	RainRate	Hora	RainRate	Hora	RainRate
1	1.20	7	1.62	13	2.60	19	2.60
2	1.20	8	1.62	14	2.60	20	2.60
3	1.20	9	1.76	15	2.60	21	2.60
4	1.20	10	1.90	16	2.60	22	2.60
5	1.20	11	2.04	17	2.60	23	2.60
6	1.20	12	2.60	18	2.60	24	4.60

Tabla A.7: Tabla de valores mínimos de *Promedio de Lluvia (RainRate)* para que no ocurran heladas (Villa Regina).

A.2. Configuración de la Red Neuronal Artificial

La ANN se implementó utilizando la clase “MLPClassifier”¹ de la biblioteca scikit-learn². El modelo de la red neuronal se configura con diferente número de capas ocultas que tienen 8, 16, 32 y 64 unidades. La función de activación utilizada en la capa oculta es la función ReLU (Rectified Linear Unit)[44].

El modelo utilizó el optimizador de descenso de gradiente estocástico (SGD)[28] para minimizar la función de pérdida durante el entrenamiento. El número máximo de iteraciones se estableció en 1000.

Se utilizó la técnica de validación cruzada estratificada (Stratified K-Fold)[22] con 5 pliegues para evaluar la capacidad de generalización del modelo. Esto asegura que la distribución de clases sea preservada en cada pliegue.

El preprocesamiento de datos incluye la estandarización de las características utilizando StandardScaler³ de scikit-learn. Esto garantiza que todas las características tengan una media de cero y una desviación estándar de uno, lo que facilita el entrenamiento de la red neuronal y mejora la convergencia del modelo.

A.3. Resultados de las ejecuciones de las redes neuronales artificiales Villa Regina.

La tabla A.8 muestra los valores de la matriz de confusión y sus métricas derivadas para la configuración de 8 unidades ocultas y el *Conjunto de Datos de Clase* con $n = 0$ hasta $b = 138$.

La tabla A.9 muestra los valores de la matriz de confusión y sus métricas derivadas para la configuración de 16 unidades ocultas y el *Conjunto de Datos de Clase* con $n = 0$ hasta $b = 138$.

La tabla A.10 muestra los valores de la matriz de confusión y sus métricas derivadas para la configuración de 32 unidades ocultas y el *Conjunto de Datos de Clase* con $n = 0$ hasta $b = 138$.

La tabla A.11 muestra los valores de la matriz de confusión y sus métricas derivadas para la configuración de 64 unidades ocultas y el *Conjunto de Datos de Clase* con $n = 0$ hasta $b = 138$.

La tabla A.12 muestra los valores de la matriz de confusión y sus métricas derivadas para la configuración de 32 unidades ocultas y el *Conjunto de Datos de Clase* con $n = 0$ hasta $b = 138$ al que se le eliminaron variables.

¹https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPClassifier.html

²<https://scikit-learn.org/stable/>

³<https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html>

A.3. RESULTADOS DE LAS EJECUCIONES DE LAS REDES NEURONALES ARTIFICIALES VILLA RE

Hora	TP	FP	FN	TN	Accuracy	Precision	Recall	F1 Score	Specificity
0	31127.4	31.2	44.4	4141.0	0.997861	0.998999	0.998576	0.998787	0.992586
1	30605.4	553.2	459.8	3725.6	0.971339	0.982246	0.985201	0.98372	0.870852
2	30346.0	812.6	894.4	3291.0	0.951703	0.97392	0.971375	0.972644	0.802189
3	29978.8	1179.8	1343.6	2841.8	0.928605	0.962136	0.957109	0.959612	0.706926
4	30199.8	958.8	2192.4	1993.0	0.910842	0.969229	0.932329	0.950412	0.676317
5	30298.0	860.6	2622.0	1563.4	0.901466	0.97238	0.920358	0.94565	0.645636
6	30496.0	662.6	3056.6	1128.8	0.894771	0.978734	0.908951	0.942527	0.633114
7	30621.0	537.6	3305.4	880.0	0.891269	0.982746	0.902581	0.940955	0.620796
8	30627.0	531.6	3345.0	840.4	0.890318	0.982939	0.90154	0.94048	0.612818
9	30695.0	463.6	3425.8	759.6	0.889956	0.985121	0.899606	0.940419	0.621762
10	30698.0	460.6	3462.4	723.0	0.889005	0.985218	0.898643	0.93994	0.611639
11	30704.4	454.2	3420.6	764.8	0.890369	0.985423	0.899764	0.940646	0.628817
12	30686.8	471.8	3361.4	824.0	0.891546	0.984858	0.901277	0.941215	0.636129
13	30576.4	582.2	3180.0	1005.4	0.893555	0.981315	0.905801	0.942043	0.635134
14	30551.8	606.8	3122.8	1062.6	0.894477	0.980525	0.907266	0.942474	0.636579
15	30513.4	645.2	3082.2	1103.2	0.894539	0.979293	0.908258	0.942437	0.631544
16	30468.8	689.8	3072.2	1113.2	0.89356	0.977862	0.908407	0.941854	0.617643
17	30540.4	618.2	3179.4	1006.0	0.892553	0.98016	0.905714	0.941466	0.619403
18	30577.0	581.6	3226.0	959.4	0.89227	0.981334	0.904573	0.941388	0.62243
19	30613.0	545.6	3309.6	875.8	0.890923	0.98249	0.90244	0.940763	0.617583
20	30613.8	544.8	3322.2	863.2	0.89059	0.982515	0.902108	0.940594	0.613245
21	30653.6	505.0	3329.2	856.2	0.891518	0.983793	0.902035	0.94114	0.629708
22	30545.2	613.4	3241.6	943.8	0.890929	0.980314	0.904063	0.940642	0.60691
23	30614.8	543.8	3301.2	884.2	0.891212	0.982547	0.902673	0.940914	0.620314

Tabla A.8: Resultados promediados de la Matriz de Confusión y métricas derivadas para 8 unidades ocultas.

Hora	TP	FP	FN	TN	Accuracy	Precision	Recall	F1 Score	Specificity
0	31134.4	24.2	22.0	4163.4	0.998693	0.999223	0.999294	0.999258	0.994229
1	30682.0	476.6	475.6	3709.8	0.973059	0.984704	0.984738	0.98472	0.886202
2	30311.8	846.8	843.8	3341.6	0.952167	0.972823	0.972933	0.972871	0.798205
3	29846.6	1312.0	1185.6	2999.8	0.929334	0.957893	0.961813	0.959838	0.696298
4	30094.4	1064.2	2055.4	2130.0	0.911736	0.965845	0.936247	0.950729	0.672695
5	30218.0	940.6	2512.2	1673.2	0.902309	0.969812	0.923254	0.945954	0.641286
6	30377.6	781.0	2875.4	1310.0	0.896548	0.974934	0.913571	0.943234	0.62851
7	30625.4	533.2	3244.4	941.0	0.893119	0.982887	0.904217	0.941909	0.63871
8	30664.8	493.8	3317.6	867.8	0.892163	0.984152	0.902379	0.94149	0.638511
9	30698.2	460.4	3380.0	805.4	0.891342	0.985224	0.90083	0.941131	0.639179
10	30673.8	484.8	3358.6	826.8	0.891257	0.984441	0.901322	0.941041	0.635657
11	30641.6	517.0	3292.2	893.2	0.892225	0.983407	0.902993	0.94148	0.635174
12	30585.2	573.4	3191.6	993.8	0.893476	0.981598	0.905525	0.942018	0.637984
13	30543.4	615.2	3126.4	1059.0	0.894138	0.980256	0.907151	0.942285	0.633096
14	30504.8	653.8	3051.4	1134.0	0.895167	0.979017	0.909071	0.942746	0.634817
15	30503.4	655.2	3063.4	1122.0	0.894788	0.978972	0.908747	0.942548	0.632265
16	30482.8	675.8	3061.4	1124.0	0.894262	0.978311	0.90875	0.942241	0.625366
17	30533.8	624.8	3129.6	1055.8	0.893775	0.979948	0.907039	0.942081	0.629308
18	30524.4	634.2	3105.0	1080.4	0.894206	0.979646	0.907676	0.942285	0.631167
19	30568.2	590.4	3191.4	994.0	0.893	0.981052	0.90547	0.941745	0.627539
20	30598.6	560.0	3239.6	945.8	0.892496	0.982027	0.904263	0.941541	0.628708
21	30499.2	659.4	3159.2	1026.2	0.891959	0.978837	0.906151	0.941084	0.611482
22	30574.2	584.4	3225.8	959.6	0.892197	0.981245	0.904565	0.941343	0.622642
23	30512.8	645.8	3165.6	1019.8	0.892163	0.979274	0.906012	0.941214	0.614429

Tabla A.9: Resultados promediados de la Matriz de Confusión y métricas derivadas para 16 unidades ocultas.

Hora	TP	FP	FN	TN	Accuracy	Precision	Recall	F1 Score	Specificity
0	31143.4	15.2	30.2	4155.2	0.998716	0.999512	0.999032	0.999272	0.996369
1	30675.8	482.8	490.2	3695.2	0.97247	0.984505	0.984276	0.984387	0.884839
2	30395.6	763.0	942.6	3242.8	0.951743	0.975512	0.96996	0.972707	0.811224
3	29981.4	1177.2	1289.8	2895.6	0.9302	0.962219	0.958777	0.960483	0.711527
4	30086.0	1072.6	1985.6	2199.8	0.913473	0.965576	0.938129	0.951631	0.674257
5	30226.8	931.8	2486.6	1698.8	0.903282	0.970095	0.924106	0.946474	0.653514
6	30389.8	768.8	2837.8	1347.6	0.897957	0.975326	0.914611	0.943985	0.638005
7	30272.2	886.4	2800.0	1385.4	0.895699	0.971552	0.915385	0.942606	0.612456
8	30571.0	587.6	3163.4	1022.0	0.893872	0.981141	0.906248	0.942195	0.639186
9	30565.2	593.4	3200.8	984.6	0.892649	0.980955	0.905232	0.941557	0.6288
10	30701.4	457.2	3341.0	844.4	0.892536	0.985327	0.901871	0.941747	0.650281
11	30634.0	524.6	3242.6	942.8	0.893413	0.983164	0.904288	0.942075	0.642951
12	30618.2	540.4	3180.2	1005.2	0.894732	0.982657	0.905912	0.942722	0.650582
13	30649.2	509.4	3197.0	988.4	0.895134	0.983651	0.905545	0.942983	0.659892
14	30520.4	638.2	3006.8	1178.6	0.896871	0.979517	0.910324	0.94365	0.649597
15	30345.2	813.4	2840.0	1345.4	0.896633	0.973895	0.914423	0.94322	0.623643
16	30464.4	694.2	2993.0	1192.4	0.895677	0.977721	0.910544	0.942937	0.632183
17	30481.2	677.4	3050.4	1135.0	0.894528	0.97826	0.909034	0.942374	0.626811
18	30532.4	626.2	3100.0	1085.4	0.894573	0.979903	0.907834	0.94249	0.634172
19	30485.8	672.8	3040.6	1144.8	0.894935	0.978407	0.909312	0.942592	0.630539
20	30563.2	595.4	3172.4	1013.0	0.893396	0.980891	0.905965	0.94194	0.629787
21	30533.2	625.4	3178.6	1006.8	0.892372	0.979928	0.905717	0.941359	0.617821
22	30575.4	583.2	3222.6	962.8	0.892321	0.981283	0.904664	0.94141	0.624024
23	30596.8	561.8	3235.4	950.0	0.892565	0.98197	0.904387	0.941572	0.631473

Tabla A.10: Resultados promediados de la Matriz de Confusión y métricas derivadas para 32 unidades ocultas.

Hora	TP	FP	FN	TN	Accuracy	Precision	Recall	F1 Score	Specificity
0	31123.4	35.2	17.6	4167.8	0.998506	0.99887	0.999436	0.999152	0.99169
1	30672.2	486.4	456.2	3729.2	0.973331	0.98439	0.985356	0.984867	0.885199
2	30304.2	854.4	793.6	3391.8	0.953372	0.972579	0.974492	0.973529	0.799052
3	29977.0	1181.6	1253.0	2932.4	0.931117	0.962078	0.959908	0.960977	0.713417
4	29986.0	1172.6	1848.8	2336.6	0.914514	0.962367	0.941961	0.952034	0.667371
5	29982.4	1176.2	2185.8	1999.6	0.904878	0.962251	0.93209	0.946912	0.630189
6	30298.4	860.2	2678.2	1507.2	0.899887	0.972393	0.918891	0.944831	0.640997
7	30518.4	640.2	3019.4	1166.0	0.896458	0.979454	0.909995	0.943434	0.648094
8	30506.8	651.8	3092.6	1092.8	0.894058	0.979081	0.908098	0.942168	0.643659
9	30632.8	525.8	3196.4	989.0	0.894687	0.983125	0.90552	0.942725	0.65331
10	30597.4	561.2	3152.4	1033.0	0.89493	0.981989	0.906599	0.942786	0.649467
11	30596.0	562.6	3136.4	1049.0	0.895343	0.981944	0.907034	0.942996	0.653243
12	30564.8	593.8	3104.8	1080.6	0.895354	0.980943	0.907806	0.942945	0.650547
13	30383.8	774.8	2890.8	1294.6	0.896288	0.975134	0.91314	0.943108	0.627499
14	30421.4	737.2	2877.6	1307.8	0.897725	0.976341	0.913586	0.94392	0.639692
15	30370.2	788.4	2815.8	1369.6	0.898025	0.974697	0.915169	0.943985	0.636152
16	30414.8	743.8	2923.8	1261.6	0.896231	0.976129	0.912339	0.943133	0.63339
17	30439.8	718.8	2937.2	1248.2	0.89656	0.976931	0.912024	0.943347	0.63765
18	30577.4	581.2	3099.8	1085.6	0.895852	0.981347	0.907959	0.943226	0.651466
19	30410.4	748.2	2938.2	1247.2	0.895699	0.975988	0.911897	0.942852	0.625712
20	30307.8	850.8	2912.6	1272.8	0.893521	0.972694	0.912365	0.941541	0.602317
21	30481.6	677.0	3067.0	1118.4	0.89407	0.978272	0.908605	0.942136	0.627533
22	30437.4	721.2	3065.4	1120.0	0.892865	0.976854	0.908516	0.941438	0.610392
23	30418.4	740.2	3002.4	1183.0	0.894109	0.976244	0.910204	0.942043	0.619709

Tabla A.11: Resultados promediados de la Matriz de Confusión y métricas derivadas para 64 unidades ocultas.

Hora	TP	FP	FN	TN	Accuracy	Precision	Recall	F1 Score	Specificity
0	31134.2	24.4	16.0	4169.4	0.998857	0.999217	0.999487	0.999351	0.994195
1	30689.2	469.4	477.8	3707.6	0.973201	0.984935	0.984673	0.984803	0.887677
2	30360.4	798.2	925.6	3259.8	0.951228	0.974383	0.970452	0.972394	0.80475
3	30001.2	1157.4	1337.0	2848.4	0.929425	0.962855	0.957366	0.960087	0.711862
4	30224.4	934.2	2249.8	1935.6	0.909914	0.970018	0.930912	0.949968	0.683731
5	30207.2	951.4	2598.2	1587.2	0.89957	0.969466	0.920922	0.944505	0.630301
6	30330.0	828.6	2885.4	1300.0	0.894918	0.973407	0.91318	0.942307	0.612937
7	30629.8	528.8	3317.6	867.8	0.891172	0.983029	0.90231	0.940923	0.623855
8	30651.0	507.6	3401.2	784.2	0.889407	0.983709	0.900129	0.940058	0.609814
9	30756.4	402.2	3489.4	696.0	0.889894	0.987092	0.898126	0.940499	0.639621
10	30791.6	367.0	3560.6	624.8	0.888875	0.988222	0.896358	0.940046	0.633717
11	30801.0	357.6	3529.8	655.6	0.890013	0.988523	0.897188	0.940641	0.646358
12	30731.2	427.4	3416.0	769.4	0.891257	0.986283	0.899964	0.941148	0.643171
13	30634.8	523.8	3300.2	885.2	0.891806	0.983189	0.902762	0.941254	0.63051
14	30534.4	624.2	3123.6	1061.8	0.893962	0.979967	0.907197	0.942178	0.630286
15	30473.6	685.0	3060.6	1124.8	0.894024	0.978016	0.908743	0.942102	0.622439
16	30517.0	641.6	3125.2	1060.2	0.893425	0.979409	0.907111	0.941871	0.623722
17	30594.6	564.0	3196.8	988.6	0.893595	0.981899	0.905398	0.942097	0.636983
18	30567.8	590.8	3156.8	1028.6	0.893968	0.981039	0.906402	0.94224	0.636781
19	30550.0	608.6	3175.4	1010.0	0.892938	0.980468	0.90585	0.94168	0.62448
20	30564.0	594.6	3244.0	941.4	0.891393	0.980917	0.904057	0.940913	0.615036
21	30546.4	612.2	3226.8	958.6	0.891382	0.980352	0.904477	0.940875	0.613847
22	30641.2	517.4	3302.4	883.0	0.891925	0.983395	0.902716	0.941326	0.632219
23	30594.0	564.6	3277.6	907.8	0.891291	0.98188	0.903253	0.940916	0.61948
Promedios	30563.558333	595.041667	2766.408333	1418.991667	0.904893	0.980903	0.917876	0.948091	0.666990

Tabla A.12: Resultados promedios de la Matriz de Confusión y métricas derivadas para 32 unidades ocultas y conjunto de datos reducido.

A.4. Resultados del análisis de correlación Guerrico.

La Tabla A.1 muestra los coeficientes de la correlación de Pearson para el *Conjunto de Datos Dinámico Guerrico* desde $n = 0$ hasta $n = 138$, la Tabla A.2 muestra los coeficientes de la correlación de Spearman para el *Conjunto de Datos Dinámico Guerrico* desde $n = 0$ hasta $n = 138$ y, por último, la Tabla A.3 muestra los coeficientes de la correlación de Kendall para el *Conjunto de Datos Dinámico Guerrico* desde $n = 0$ hasta $n = 138$. Por otra parte, la Tabla A.4 muestra el promedio de los valores para cada variable por cada uno de los métodos de correlación y, el último registro, muestra el promedio que tuvo cada variable al combinar los resultados de cada método.

Hora	HiTemp	LowTemp	OutHum	DewPt	WindSpeed	WindRun	WindChill	Bar	Rain	RainRate	SolarRad.	SolarEnergy	Hi SolarRad.	ET
0	0.999146	1.0	-0.735898	0.365199	0.485888	0.485876	0.986737	-0.283391	-0.00876	0.001312	0.511067	0.511066	0.517347	0.162335
1	0.962717	0.960904	-0.684416	0.38976	0.483753	0.483751	0.952563	-0.272948	-0.009047	0.000786	0.614328	0.614327	0.621115	0.163697
2	0.87685	0.873522	-0.594685	0.396747	0.452267	0.452268	0.868907	-0.259287	-0.00814	0.000629	0.659491	0.659489	0.665666	0.155487
3	0.758798	0.754341	-0.482281	0.389268	0.402171	0.402181	0.752802	-0.244929	-0.006921	0.000381	0.649095	0.649092	0.654258	0.138844
4	0.622333	0.617186	-0.358587	0.37022	0.338936	0.338955	0.618319	-0.232022	-0.005301	0.000448	0.590498	0.590495	0.594847	0.116327
5	0.478962	0.473585	-0.233128	0.342243	0.268469	0.268497	0.477184	-0.221911	-0.004079	0.000532	0.494823	0.494821	0.498969	0.090314
6	0.338184	0.333093	-0.113776	0.30807	0.195132	0.195162	0.338956	-0.214763	-0.002951	0.000668	0.375365	0.375362	0.37955	0.063174
7	0.208934	0.20464	-0.008056	0.270844	0.124837	0.124867	0.212287	-0.21007	-0.001598	0.000843	0.245753	0.245751	0.249949	0.037628
8	0.097962	0.094912	0.078909	0.234612	0.061222	0.061249	0.103849	-0.207017	-0.000817	0.001062	0.119627	0.119624	0.123261	0.014896
9	0.009984	0.008363	0.144611	0.203585	0.005717	0.005736	0.018264	-0.204613	-0.000704	0.001107	0.007066	0.007064	0.00982	-0.004044
10	-0.053778	-0.054117	0.189133	0.180175	-0.041329	-0.041323	-0.043153	-0.202062	-0.000936	0.000801	-0.087655	-0.087656	-0.086094	-0.019359
11	-0.094099	-0.093446	0.213218	0.164057	-0.080168	-0.080178	-0.081243	-0.198816	-0.001565	0.000528	-0.165664	-0.165664	-0.165458	-0.031513
12	-0.112453	-0.111207	0.217841	0.153674	-0.111101	-0.111119	-0.097536	-0.194879	-0.002169	0.000434	-0.230657	-0.230657	-0.231692	-0.04086
13	-0.109819	-0.108488	0.204086	0.14729	-0.135302	-0.135326	-0.093028	-0.19077	-0.002761	0.000375	-0.286001	-0.286	-0.288192	-0.048029
14	-0.085728	-0.084715	0.172056	0.143377	-0.151781	-0.151809	-0.067328	-0.187561	-0.003499	0.000386	-0.333538	-0.333538	-0.33661	-0.052534
15	-0.039183	-0.038641	0.121563	0.141236	-0.157036	-0.157069	-0.019637	-0.186519	-0.004398	0.000487	-0.371974	-0.371975	-0.375182	-0.053438
16	0.030066	0.03013	0.053227	0.140722	-0.147299	-0.147336	0.050107	-0.18859	-0.005226	0.000548	-0.394012	-0.394012	-0.396579	-0.048878
17	0.120237	0.120089	-0.030852	0.14244	-0.119968	-0.120009	0.140137	-0.193773	-0.006078	0.000655	-0.388762	-0.388761	-0.389849	-0.037567
18	0.226451	0.226457	-0.126409	0.146936	-0.075639	-0.075688	0.245686	-0.201108	-0.00666	0.001023	-0.346591	-0.34659	-0.345877	-0.018899
19	0.342432	0.342605	-0.227796	0.155054	-0.017496	-0.017549	0.360257	-0.208939	-0.006443	0.001974	-0.263259	-0.263258	-0.260944	0.005881
20	0.459747	0.460201	-0.328141	0.167412	0.049592	0.04954	0.475783	-0.215144	-0.006209	0.002868	-0.140694	-0.140692	-0.137185	0.035012
21	0.569205	0.569886	-0.419452	0.184458	0.120311	0.120264	0.583122	-0.217654	-0.005807	0.00374	0.012311	0.012313	0.016507	0.06497
22	0.660535	0.661246	-0.492496	0.206251	0.187509	0.187466	0.672292	-0.214944	-0.005255	0.004561	0.180723	0.180723	0.185228	0.092749
23	0.722159	0.722415	-0.536271	0.232007	0.243007	0.242969	0.731952	-0.206438	-0.00496	0.005233	0.346391	0.346391	0.351082	0.115052

Tabla A.13: Resultados de la correlación de Pearson en un periodo de 24hs (Guerrico).

Hora	HiTemp	LowTemp	OutHum	DewPt	WindSpeed	WindRun	WindChill	Bar	Rain	RainRate	SolarRad.	SolarEnergy	Hi SolarRad.	ET
0	0.999064	1.0	-0.745165	0.352794	0.504409	0.504409	0.985391	-0.32937	-0.011637	-0.003283	0.521452	0.521452	0.523179	0.139588
1	0.958577	0.956614	-0.690589	0.377346	0.509201	0.509201	0.947088	-0.317736	-0.012033	-0.004178	0.645812	0.645812	0.646836	0.136369
2	0.86456	0.861178	-0.595476	0.381863	0.475651	0.475651	0.85523	-0.302488	-0.010265	-0.003855	0.701781	0.701781	0.702465	0.12284
3	0.73864	0.734369	-0.478496	0.370076	0.420994	0.420994	0.73117	-0.286478	-0.008203	-0.004043	0.690648	0.690648	0.691214	0.102988
4	0.596909	0.592181	-0.352516	0.346645	0.352115	0.352115	0.591376	-0.2721	-0.006424	-0.004011	0.626995	0.626995	0.627607	0.079782
5	0.451013	0.446173	-0.226879	0.315443	0.276089	0.276089	0.447709	-0.260888	-0.005192	-0.003854	0.526885	0.526885	0.527704	0.055301
6	0.309756	0.305215	-0.108737	0.279414	0.197525	0.197525	0.309035	-0.253018	-0.00405	-0.003403	0.40289	0.40289	0.403988	0.030872
7	0.18121	0.177398	-0.004695	0.241241	0.121843	0.121843	0.183112	-0.247789	-0.002683	-0.002468	0.26538	0.26538	0.266809	0.007929
8	0.071349	0.06864	0.080634	0.204603	0.053209	0.053209	0.075913	-0.244224	-0.001926	-0.00185	0.123337	0.123337	0.125028	-0.011942
9	-0.015957	-0.017401	0.145118	0.173775	-0.006008	-0.006008	-0.008676	-0.241247	-0.002068	-0.001684	-0.014364	-0.014364	-0.012583	-0.026738
10	-0.080087	-0.080405	0.189269	0.151089	-0.055904	-0.055904	-0.070077	-0.238063	-0.002285	-0.002025	-0.138351	-0.138351	-0.13663	-0.036088
11	-0.121564	-0.120969	0.213749	0.135738	-0.096814	-0.096814	-0.108872	-0.234172	-0.002877	-0.002362	-0.244574	-0.244574	-0.242978	-0.040281
12	-0.140867	-0.139635	0.218901	0.125977	-0.128856	-0.128856	-0.125596	-0.229651	-0.003523	-0.002368	-0.334029	-0.334029	-0.332599	-0.040187
13	-0.138213	-0.13677	0.205143	0.120341	-0.153558	-0.153558	-0.120474	-0.225158	-0.004305	-0.002681	-0.408733	-0.408733	-0.407509	-0.036694
14	-0.113787	-0.112489	0.172815	0.117596	-0.169316	-0.169316	-0.093785	-0.221882	-0.005033	-0.002695	-0.467158	-0.467158	-0.466011	-0.030254
15	-0.067333	-0.066388	0.122194	0.116871	-0.172478	-0.172478	-0.045606	-0.221266	-0.006182	-0.002626	-0.504181	-0.504181	-0.502915	-0.021215
16	0.001419	0.00188	0.054175	0.118312	-0.160116	-0.160116	0.024021	-0.22439	-0.007074	-0.002413	-0.512095	-0.512095	-0.510497	-0.010583
17	0.091197	0.091308	-0.029322	0.122647	-0.130787	-0.130787	0.1137	-0.231246	-0.007983	-0.002228	-0.481829	-0.481829	-0.479698	0.001888
18	0.197683	0.197697	-0.124397	0.130053	-0.085553	-0.085553	0.219095	-0.24065	-0.008267	-0.001243	-0.410929	-0.410929	-0.408343	0.016153
19	0.314735	0.314938	-0.225588	0.140873	-0.0274	-0.0274	0.334229	-0.250565	-0.007702	0.000554	-0.302861	-0.302861	-0.299982	0.03186
20	0.434661	0.43511	-0.326007	0.155609	0.039279	0.039279	0.451537	-0.258378	-0.006901	0.002183	-0.163848	-0.163848	-0.16079	0.047999
21	0.548569	0.549212	-0.417769	0.17455	0.109666	0.109666	0.562378	-0.26167	-0.005998	0.003603	-0.002189	-0.002189	0.000908	0.063751
22	0.645974	0.64659	-0.4918	0.197657	0.17767	0.17767	0.656713	-0.258667	-0.004549	0.004977	0.17233	0.17233	0.175262	0.078226
23	0.713434	0.713435	-0.536798	0.224441	0.235341	0.235341	0.721664	-0.248754	-0.003565	0.005478	0.348189	0.348189	0.35056	0.090634

Tabla A.14: Resultados de la correlación de Spearman en un periodo de 24hs (Guerrico).

La Tabla A.17 muestra la velocidad mínima del viento necesaria para que no ocurran heladas a lo largo de un periodo de 24 horas.

La Tabla A.18 muestra la cantidad mínima de agua desplazado por el viento necesaria para que no ocurran heladas a lo largo de un periodo de 24 horas.

La Tabla A.17 muestra el promedio mínimo de lluvia necesaria para que no ocurran heladas a lo largo de un periodo de 24 horas.

Hora	HiTemp	LowTemp	OutHum	DewPt	WindSpeed	WindRun	WindChill	Bar	Rain	RainRate	SolarRad.	SolarEnergy	Hi SolarRad.	ET
0	0.981056	1.0	-0.543761	0.252453	0.370593	0.370593	0.910146	-0.225237	-0.009503	-0.00266	0.38999	0.38999	0.391702	0.114755
1	0.83587	0.833484	-0.493948	0.267877	0.373967	0.373967	0.808363	-0.216932	-0.009826	-0.003391	0.497234	0.497234	0.498683	0.11228
2	0.692827	0.690283	-0.415571	0.266987	0.348098	0.348098	0.677971	-0.20616	-0.008381	-0.003126	0.549479	0.549479	0.550691	0.100616
3	0.559557	0.556879	-0.327364	0.256009	0.306743	0.306743	0.550265	-0.194995	-0.006698	-0.003282	0.53755	0.53755	0.538438	0.083751
4	0.435612	0.432869	-0.237923	0.238013	0.255577	0.255577	0.429638	-0.185066	-0.005242	-0.003255	0.479888	0.479888	0.480559	0.064478
5	0.321644	0.318913	-0.151947	0.215304	0.199909	0.199909	0.318117	-0.177309	-0.004234	-0.003126	0.396718	0.396718	0.397412	0.044505
6	0.218618	0.216088	-0.07274	0.189814	0.142879	0.142879	0.217245	-0.171747	-0.003301	-0.002759	0.299842	0.299842	0.300686	0.024823
7	0.128534	0.126421	-0.003701	0.163316	0.088341	0.088341	0.129079	-0.167893	-0.002183	-0.001996	0.196263	0.196263	0.197358	0.006475
8	0.053199	0.051719	0.052678	0.138182	0.039054	0.039054	0.055537	-0.165154	-0.001565	-0.001494	0.091172	0.091172	0.092501	-0.009356
9	-0.006039	-0.006807	0.095166	0.117169	-0.003422	-0.003422	-0.00189	-0.162859	-0.001681	-0.001361	-0.010161	-0.010161	-0.008697	-0.021129
10	-0.049317	-0.049461	0.124204	0.101704	-0.039185	-0.039185	-0.043342	-0.160485	-0.00186	-0.001642	-0.101415	-0.101415	-0.09994	-0.028561
11	-0.077213	-0.076852	0.140236	0.091239	-0.068439	-0.068439	-0.069407	-0.157704	-0.002345	-0.001918	-0.17977	-0.17977	-0.178335	-0.031882
12	-0.090187	-0.089472	0.143422	0.084583	-0.09131	-0.09131	-0.080588	-0.154562	-0.002872	-0.001923	-0.246011	-0.246011	-0.244642	-0.031778
13	-0.088449	-0.087634	0.134	0.080784	-0.108946	-0.108946	-0.077122	-0.151493	-0.00351	-0.002179	-0.301458	-0.301458	-0.300183	-0.028969
14	-0.072291	-0.071578	0.112308	0.078961	-0.120311	-0.120311	-0.095932	-0.149275	-0.004106	-0.002191	-0.345192	-0.345192	-0.343913	-0.023819
15	-0.041631	-0.041125	0.078675	0.078517	-0.122746	-0.122746	-0.027345	-0.148889	-0.005045	-0.002134	-0.373365	-0.373365	-0.371922	-0.016603
16	0.003845	0.004056	0.033661	0.079552	-0.114099	-0.114099	0.018932	-0.151075	-0.005776	-0.001964	-0.379998	-0.379998	-0.37826	-0.008123
17	0.063569	0.063565	-0.021556	0.082561	-0.09325	-0.09325	0.07886	-0.155831	-0.006519	-0.001813	-0.358493	-0.358493	-0.356391	0.001779
18	0.135126	0.135066	-0.084572	0.087674	-0.06096	-0.06096	0.149999	-0.162336	-0.006754	-0.001009	-0.305848	-0.305848	-0.303486	0.013066
19	0.215337	0.215403	-0.152229	0.095129	-0.019397	-0.019397	0.229257	-0.169212	-0.006292	0.00046	-0.224534	-0.224534	-0.222078	0.02549
20	0.300227	0.300487	-0.220567	0.105308	0.028164	0.028164	0.312757	-0.174646	-0.005637	0.001792	-0.120567	-0.120567	-0.118132	0.038288
21	0.385157	0.385635	-0.284869	0.118483	0.078216	0.078216	0.395946	-0.17693	-0.0049	0.002955	-0.001371	-0.001371	0.000949	0.050863
22	0.463851	0.464436	-0.338898	0.134668	0.126553	0.126553	0.472611	-0.17486	-0.003716	0.004078	0.126017	0.126017	0.128153	0.062583
23	0.52474	0.524874	-0.373197	0.153461	0.167745	0.167745	0.531536	-0.168022	-0.002911	0.004488	0.255515	0.255515	0.257355	0.072866

Tabla A.15: Resultados de la correlación de Kendall en un periodo de 24hs (Guerrico).

	HiTemp	LowTemp	OutHum	DewPt	WindSpeed	WindRun	WindChill	Bar	Rain	RainRate	SolarRad.	SolarEnergy	Hi SolarRad.	ET
Pearson	0.332906	0.33179	-0.165733	0.232318	0.099237	0.099224	0.341137	-0.214923	-0.004595	0.001308	0.074905	0.074905	0.077247	0.037552
Spearman	0.310039	0.309078	-0.164676	0.211456	0.095258	0.095258	0.318178	-0.25416	-0.005864	-0.00152	0.043357	0.043357	0.045043	0.031342
Kendall	0.332906	0.33179	-0.165733	0.232318	0.099237	0.099224	0.341137	-0.214923	-0.004595	0.001308	0.074905	0.074905	0.077247	0.037552
Promedios generales	0.296171	0.295529	-0.149143	0.196227	0.088218	0.088213	0.302094	-0.213704	-0.005081	-0.000048	0.051525	0.051524	0.053382	0.031526

Tabla A.16: Promedios parciales y generales de los coeficientes de correlación de Pearson, Spearman y Kendall (Guerrico).

Hora	WindSpeed	Hora	WindSpeed	Hora	WindSpeed	Hora	WindSpeed
1	16.1	7	30.6	13	57.9	19	38.3
2	17.7	8	35.4	14	49.6	20	38.3
3	19.3	9	41.8	15	49.6	21	40.2
4	25.7	10	46.7	16	45.1	22	38.6
5	24.1	11	46.7	17	46.7	23	33.8
6	30.6	12	51.5	18	43.1	24	33.8

Tabla A.17: Tabla de valores mínimos de *Velocidad del Viento (WindSpeed)* para que no ocurran heladas (Guerrico).

Hora	WindRun	Hora	WindRun	Hora	WindRun	Hora	WindRun
1	2.68	7	5.10	13	9.66	19	7.27
2	2.95	8	5.90	14	7.11	20	7.27
3	3.22	9	6.97	15	7.30	21	6.71
4	4.29	10	7.78	16	7.51	22	6.44
5	4.02	11	7.78	17	7.27	23	5.63
6	5.10	12	8.58	18	7.27	24	5.63

Tabla A.18: Tabla de valores mínimos de *Aire Desplazado por el Viento (WindRun)* para que no ocurran heladas (Guerrico).

Hora	RainRate	Hora	RainRate	Hora	RainRate	Hora	RainRate
1	0.8	7	1.6	13	1.6	19	2.0
2	0.8	8	1.6	14	1.2	20	2.0
3	0.8	9	1.6	15	1.2	21	2.0
4	0.8	10	1.6	16	2.0	22	2.0
5	1.0	11	1.6	17	2.0	23	2.0
6	1.2	12	1.6	18	2.0	24	2.4

Tabla A.19: Tabla de valores mínimos de *Promedio de Lluvia (RainRate)* para que no ocurran heladas (Guerrico).

A.5. Resultados de comparación entre Villa Regina y Guerrico

La tabla A.20 muestra los valores del porcentaje de cambio de los coeficientes de correlación de Pearson, Spearman y Kendall, entre los resultados del *Conjunto de Datos Estático Villa Regina* y el *Conjunto de Datos Estático Guerrico*.

	Porcentajes de cambio (%)		
	Pearson	Spearman	Kendall
Bar	35.19516051453315	22.433740302895657	22.58317527468939
DewPt.	-19.628513847896436	-20.794814295067837	-19.751046434739802
ET	-26.047860290596848	6.809947420545687	7.528312171693713
Hi SolarRad.	13.320984626487864	7.579005789299666	8.883164780626615
HiTemp	0.16682724945378052	0.004951703134926918	-0.013563225738205493
LowTemp	0.0	0.0	0.0
OutHum	-11.153094151985366	-10.925161410044938	-11.930216558557694
Rain	-327.12734209269945	23.88274364337292	23.648873798023093
RainRate	-71.89915376656103	61.411404039774276	61.47259242406986
SolarEnergy	15.2223324540473	7.9237781175628115	9.324705899814944
SolarRad.	15.222545287369025	7.9237781175628115	9.324705899814944
WindChill	-0.5989658635334622	-0.7694951605694162	-4.035888141828717
WindRun	2.227755553029549	-5.25779283322989	-7.322537981737277
WindSpeed	2.3105851569886924	-5.25779283322989	-7.322537981737277

Tabla A.20: Resultados del porcentaje de cambio entre los diferentes métodos de correlación para Villa Regina (V. Regina) y Guerrico, para los conjuntos de datos originales.

La tabla A.21 muestra los valores del porcentaje de cambio de los coeficientes de correlación de Pearson, Spearman y Kendall, entre los resultados del *Conjunto de Datos Dinámico Villa Regina* y el *Conjunto de Datos Dinámico Guerrico*, en ambos casos desde $n = 0$ hasta $n = 138$. Además, se incluyó el promedio que obtuvo cada variable entre los tres coeficientes de correlación.

	Pearson			Spearman			Kendall			% de cambio Promedios
	V. Regina	Guerrico	% de cambio	V. Regina	Guerrico	% de cambio	V. Regina	Guerrico	% de cambio	
LowTemp	1.000000	1.000000	0.000000	1.000000	1.000000	0.000000	1.000000	1.000000	0.000000	
HiTemp	0.997482	0.999146	0.166827	0.999014	0.999064	0.004952	0.981189	0.981056	-0.013563	0.052739
WindChill	0.992683	0.986737	-0.598966	0.993032	0.985391	-0.769495	0.948424	0.910146	-4.035888	-1.801450
WindRun	0.475288	0.517347	2.227756	0.532402	0.523179	-5.257793	0.399874	0.391702	-7.322538	-3.450858
WindSpeed	0.474907	0.511067	2.310585	0.532402	0.521452	-5.257793	0.399874	0.389990	-7.322538	-3.423249
Hi SolarRad.	0.456533	0.511066	13.320985	0.486321	0.521452	7.579006	0.359745	0.389990	8.883165	9.927718
DewPt.	0.454388	0.485880	-19.628514	0.483167	0.504409	-20.794814	0.356726	0.370593	-19.751046	-20.058125
SolarEnergy	0.443548	0.485876	15.222332	0.483167	0.504409	7.923778	0.356726	0.370593	9.324706	10.823605
SolarRad.	0.443547	0.365199	15.222545	0.445417	0.352794	7.923778	0.314587	0.252453	9.324706	10.823676
ET	0.219513	0.162335	-26.047860	0.130689	0.139588	6.809947	0.106721	0.114755	7.528312	-3.903200
RainRate	0.004668	0.001312	-71.899154	-0.008507	-0.003283	61.411404	-0.006904	-0.002660	61.472592	16.994948
Rain	-0.002051	-0.008760	-327.127342	-0.015289	-0.011637	23.882744	-0.012447	-0.009503	23.648874	-93.198575
Bar	-0.437299	-0.283391	35.195161	-0.424631	-0.329370	22.433740	-0.290940	-0.225237	22.583175	26.737359
OutHum	-0.662058	-0.735898	-11.153094	-0.671773	-0.745165	-10.925161	-0.485804	-0.543761	-11.930217	-11.336157

Tabla A.21: Resultados del porcentaje de cambio entre los diferentes métodos de correlación para Villa Regina (V. Regina) y Guerrico, para los conjuntos de datos dinámicos.

La tabla A.22 muestra los valores del porcentaje de cambio de los valores mínimos de las variables relacionadas al viento y la lluvia para que no ocurran heladas, entre los resultados del *Conjunto de Datos Dinámico Villa Regina* y el *Conjunto de Datos Dinámico Guerrico*, en ambos casos desde $n = 0$ hasta $n = 138$.

Hora	WindSpeed	WindRun	RainRate	Hora	WindSpeed	WindRun	RainRate	Hora	WindSpeed	WindRun	RainRate	Hora	WindSpeed	WindRun	RainRate
0	11.03	11.2	0	6	36	35.64	60	12	111.31	89.41	60	18	18.94	35.63	11.11
1	37.21	37.21	0	7	57.33	46.77	60	13	62.09	32.65	63.64	19	18.94	35.63	11.11
2	33.1	33.61	0	8	73.44	52.85	60	14	54.04	36.19	50	20	24.84	25.19	11.11
3	77.24	78.01	0	9	70.44	61.08	60	15	40.06	40.11	11.11	21	19.88	20.15	5.26
4	49.69	50	25	10	61.03	61.08	60	16	45.03	35.63	11.11	22	4.97	5.04	0
5	46.41	46.13	50	11	77.59	88.16	60	17	33.85	35.63	11.11	23	16.55	16.56	9.09

Tabla A.22: Porcentaje de cambio de las variables relacionadas con el viento y la lluvia de Guerrico en comparación con Villa Regina en un periodo de 24 hs.

Bibliografía

- [1] A. Bahga and V. Madiseti, *Big data science & analytics : a hands-on approach*. Bahga, A. and Madiseti, V., 2016.
- [2] T. Erl, W. Khattak, and P. Buhler, *Big Data Fundamentals: Concepts, Drivers & Techniques*, 1st ed. Prentice Hall Press, 2016.
- [3] W. M. Organization, *Guide to Agricultural Meteorological Practices*. World Meteorological Organization, 2010. [Online]. Available: <https://library.wmo.int/records/item/35689-guide-to-agricultural-meteorological-practices>
- [4] P. F. Verdes, P. M. Granitto, H. D. Navone, and H. A. Ceccatto, “Frost prediction with machine learning techniques,” in *VI Congreso Argentino de Ciencias de la Computacion*, October 2000. [Online]. Available: <http://sedici.unlp.edu.ar/handle/10915/23444>
- [5] L. Ding, K. Noborio, and K. Shibuya, “Frost forecast using machine learning - from association to causality,” *Procedia Computer Science*, vol. 159, pp. 1001–1010, 2019. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1877050919314632>
- [6] —, “Modelling and learning cause effect application in frost forecast,” *Procedia Computer Science*, vol. 176, pp. 2264–2273, 2020. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1877050920321918>
- [7] I. Zhou, J. Lipman, M. Abolhasan, and N. Shariati, “Minute-wise frost prediction: An approach of recurrent neural networks,” *Array*, vol. 14, p. 100158, 2022. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S2590005622000248>
- [8] S. M. Kotikot, A. Flores, R. E. Griffin, J. Nyaga, J. L. Case, R. Mugo, A. Sedah, E. Adams, A. Limaye, and D. E. Irwin, “Statistical characterization of frost zones: Case of tea freeze damage in the kenyan highlands,” *International Journal of Applied Earth Observation and Geoinformation*, vol. 84, p. 101971, 2020. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0303243418309899>
- [9] D. L. Gobbett, U. Nidumolu, and S. Crimp, “Modelling frost generates insights for managing risk of minimum temperature extremes,” *Weather and Climate Extremes*, vol. 27, p. 100176, 2020, innovations in managing climate risks and building resilience in agriculture. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S2212094716300147>
- [10] A. L. Diedrichs, F. Bromberg, D. Dujovne, K. Brun-Laguna, and T. Watteyne, “Prediction of frost events using machine learning and iot sensing devices,” *IEEE Internet of Things Journal*, vol. 5, no. 6, pp. 4589–4597, 2018.
- [11] H. Salehinejad, J. Baarbe, S. Sankar, J. Barfett, E. Colak, and S. Valaee, “Recent advances in recurrent neural networks,” *CoRR*, vol. abs/1801.01078, 2018.
- [12] L. Osycka, A. Cechich, A. Buccella, A. Montenegro, and A. Muñoz, “Covamat: Functionality for variety reuse through a supporting tool,” in *XI Conference on Cloud Computing, Big Data & Emerging Topics (JCC-BD&ET)*, 2023.

- [13] L. Osycka, A. Buccella, and A. Cechich, "Data variety modeling: A case of contextual diversity identification from a bottom-up perspective," in *Computer Science - CACIC 2021*, P. Pesado and G. Gil, Eds. Cham: Springer International Publishing, 2022, pp. 124–138.
- [14] A. Cechich, A. Buccella, A. M. C. Villegas, and A. M. A. Rodriguez, "A model of reusable variation in big data system development," in *XI Conference on Cloud Computing, Big Data & Emerging Topics (JCC-BD&ET)*, 2023.
- [15] A. Buccella, J. Luzuriaga, A. Cechich, L. Osycka, F. Paterno, M. Pol'la, M. Cruz, R. Martinez, R. Mazalu, and M. Moyano, "Reusabilidad en el contexto de desarrollo de sistemas para big data," in *Actas del XXIII Workshop de Investigadores en Ciencias de la Computación (WICC21)*, Chilecito, La Rioja, 2021, pp. 525–529.
- [16] W. Chang, S. Mishra, and N.-P. NIST, "Nist big data interoperability framework: Volume 5, architectures white paper survey," 2015-10-22 2015.
- [17] A. Buccella, L. O. Alejandra Cechich, J. Luzuriaga, C. Villegas, M. Cruz, F. Corgatelli, R. Martínez, and R. Mazalu, "Covamat: Modelo conceptual de una herramienta para el soporte a la gestión de variedad en sistemas big data," in *Actas del XXV Workshop de Investigadores en Ciencias de la Computación (WICC23)*, Junin, Bs As, 2023.
- [18] W. Chang and N. Grady, "Nist big data interoperability framework: Volume 1, definitions," 2019-10-21 2019.
- [19] W. Chang, N. Grady, and N.-P. NIST, "Nist big data interoperability framework: Volume 2, big data taxonomies [version 2]," 2018-06-26 2018.
- [20] W. Chang, G. Fox, and N.-P. NIST, "Nist big data interoperability framework: Volume 3, big data use cases and general requirements [version 2]," 2018-06-26 2018.
- [21] W. Chang, A. Roy, M. Underwood, and N.-P. NIST, "Nist big data interoperability framework: Volume 4, big data security and privacy [version 2]," 2018-06-26 00:06:00 2018.
- [22] J. Han, M. Kamber, and J. Pei, *Data Mining: Concepts and Techniques*, 3rd ed., ser. The Morgan Kaufmann Series in Data Management Systems. Elsevier Science, 2012.
- [23] Y. Zhang and S. Zhang, "K-nearest neighbor imputation approach for missing data in water quality data sets," *Water*, vol. 11, no. 1, p. 42, 2019.
- [24] L. Shu and H. Zhang, "A novel approach for missing data imputation based on k-nearest neighbors," *Computational Intelligence and Neuroscience*, vol. 2019, pp. 1–11, 2019.
- [25] S. Schürer and A. Klingenhoff, "Frequent value imputation for high-dimensional missing data," *BMC bioinformatics*, vol. 6, no. 1, p. 37, 2005.
- [26] G. E. Batista and M. C. Monard, "An analysis of four missing data treatment methods for supervised learning," *Applied Artificial Intelligence*, vol. 17, no. 5-6, pp. 519–533, 2003.
- [27] E. F. El-Hashash and R. H. A. Shiekh, "A comparison of the pearson, spearman rank and kendall tau correlation coefficients using quantitative variables," *Asian Journal of Probability and Statistics*, vol. 20, no. 3, p. 36–48, Oct. 2022. [Online]. Available: <https://journalajpas.com/index.php/AJPAS/article/view/425>
- [28] C. M. Bishop, *Pattern Recognition and Machine Learning (Information Science and Statistics)*, 1st ed. Springer, 2007.
- [29] H. S. Mavi and G. J. Tupper, *Agrometeorology: Principles and Applications of Climate Studies in Agriculture*. Food Product Press, 2004.

- [30] S. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 3rd ed. Prentice Hall, 2010.
- [31] C. Chatfield, “The holt-winters forecasting procedure,” *Journal of the Royal Statistical Society. Series C (Applied Statistics)*, vol. 27, no. 3, pp. 264–279, 1978.
- [32] C. W. J. Granger, “Investigating causal relations by econometric models and cross-spectral methods,” *Econometrica*, vol. 37, no. 3, pp. 424–438, 1969.
- [33] J. Pearl, *Causality*, 2nd ed. Cambridge University Press, 2009.
- [34] R. McElreath, *Statistical rethinking: a Bayesian course with examples in R and Stan*, ser. Chapman & Hall/CRC texts in statistical science series. CRC Press/Taylor & Francis Group, 2016, no. 122, largely / videos.
- [35] J. H. Friedman, “Multivariate adaptive regression splines,” *The Annals of Statistics*, vol. 19, no. 1, pp. 1–67, 1991.
- [36] C. J. Talsma, K. C. Solander, M. K. Mudunuru, B. Crawford, and M. R. Powell, “Frost prediction using machine learning and deep neural network models,” *Frontiers in Artificial Intelligence*, vol. 5, 2023. [Online]. Available: <https://www.frontiersin.org/articles/10.3389/frai.2022.963781>
- [37] L. Osycka, “Modelado bottom-up de variedad de dominio en sistemas big data,” Master’s thesis, Facultad de Informática - Universidad Nacional del Comahue, 2022.
- [38] A. Buccella, A. Cechich, M. Pol’la, M. Arias, S. Doldan, and E. Morsan, “Marine ecology service reuse through taxonomy-oriented SPL development,” *Computers & Geosciences*, vol. 73, no. 0, pp. 108 – 121, 2014. [Online]. Available: <http://www.sciencedirect.com/science/article/pii/S0098300414002155>
- [39] A. Buccella, A. Cechich, J. Porfiri, and D. Diniz Dos Santos, “Taxonomy-oriented domain analysis of gis: A case study for paleontological software systems,” *ISPRS International Journal of Geo-Information*, vol. 8, no. 6, 2019. [Online]. Available: <https://www.mdpi.com/2220-9964/8/6/270>
- [40] K. Pohl, G. Böckle, and F. J. v. d. Linden, *Software Product Line Engineering: Foundations, Principles and Techniques*. Secaucus, NJ, USA: Springer-Verlag New York, Inc., 2005.
- [41] G. James, D. Witten, T. Hastie, and R. Tibshirani, *An Introduction to Statistical Learning: with Applications in R*. Springer, 2013.
- [42] J. Olivier, *Business Math: A Step-by-step Handbook*. Open Textbooks, 2021. [Online]. Available: <https://mds.marshall.edu/oa-textbooks/552>
- [43] M. Anderson, “Calculating and interpreting percentage changes for economic analysis,” *Applied Economics Teaching Resources (AETR)*, Agricultural and Applied Economics Association, vol. 1, no. 1, 2019.
- [44] I. J. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016, <http://www.deeplearningbook.org>.